MAKİNE ÖĞRENMESİ | TÜRKÇE DERS NOTLARI

04

PARAMETRİK YÖNTEMLER

Tam bölüm

kapsamı: 4.1 – 4.10

Açıklamalı Türkçe çeviri, özgün çizilmiş grafikler, formül açıklamaları ve çözümlü alıştırmalar

KAYNAK: Ethem Alpaydın, *Introduction to Machine Learning*, MIT Press (2014), Bölüm 4.

Kaynak, kullanıcı tarafından sağlanan üç metin dosyasıdır. Şekiller telifli kitabın sayfa görüntüleri yerine açıklama amaçlı yeniden çizilmiştir; sayısal grafikler farklı örneklem üretiminden ötürü özgün şekillerle birebir aynı olmayabilir.

Bu ders notu nasıl kullanılmalı?

Bu belge, sağlanan üç kaynak metnin Bölüm 4 (4.1–4.10) içeriğini Türkçeye aktarırken matematiksel notasyonu, denklem sırasını ve kitabın kavramsal örgüsünü korumak amacıyla hazırlanmıştır. Kaynakta yer alan açıklamalar genişletilmiş, öğrencilerin başlangıç seviyesine uygun olarak ek sayısal örnekler ve türetimler sunulmuştur. Kaynak metin PDF'nin metin çıkarımı olduğundan bazı semboller bozulmuştu; bu semboller denklemin anlamına göre yeniden yazılmıştır.

Açıklama ve öğretim notu

Okuma rehberi: *Türkçe aktarım* paragrafları kaynak bölümün sırasını takip eder. Renkli *açıklama* ve *örnek* alanları ders anlatımı için eklenen öğretici içeriktir. "Yeniden çizim" grafiklerinde amaç orijinal şeklin bilimsel mesajını göstermek, piksellerini kopyalamak değildir.

İçindekiler

4 Parametrik Yöntemler **1**

4.1 Giriş (Introduction) . . . 1
4.2 Maksimum Olabilirlik Tahmini (Maximum Likelihood Estimation) . . . 2
4.2.1 Bernoulli Dağılımı (Bernoulli Density) . . . 3
4.2.2 Multinomial Dağılım (Multinomial Density) . . . 3
4.2.3 Gaussian (Normal) Yoğunluk . . . 4
4.3 Bir Tahmin Ediciyi Değerlendirmek: Yanlılık ve Varyans . . . 4
4.3.1 Gaussian varyans MLE tahmininin yanlı olması . . . 5
4.3.2 Ortalama karesel hatanın ayrıştırılması . . . 6
4.4 Bayesçi Tahmin Edici (The Bayes' Estimator) . . . 6
4.4.1 Gaussian önsel ile Gaussian gözlemin birleşimi . . . 7
4.5 Parametrik Sınıflandırma (Parametric Classification) . . . 8
4.5.1 Otomobil müşterileri örneği ve parametre öğrenimi . . . 8
4.5.2 Eşit olmayan varyanslar ve reddetme kararı . . . 10
4.6 Regresyon (Regression) . . . 11
4.6.1 Gaussian gürültüden en küçük karelere . . . 11
4.6.2 Doğrusal regresyon (Linear Regression) . . . 12
4.6.3 Polinom regresyonu (Polynomial Regression) . . . 13
4.6.4 Göreli kareli hata ve R^2 . . . 13
4.7 Model Karmaşıklığını Ayarlamak: Yanlılık/Varyans İkilemi . . . 14
4.7.1 Bias ve varyansı kontrollü deneyde ölçmek . . . 14
4.7.2 Basitten karmaşığa: underfitting ve overfitting . . . 15
4.8 Model Seçim Yöntemleri (Model Selection Procedures) . . . 17
4.8.1 Doğrulama ve çapraz doğrulama . . . 17
4.8.2 Düzenlileştirme (Regularization) . . . 18
4.8.3 AIC ve BIC . . . 19
4.8.4 Yapısal Risk Minimizasyonu (SRM) . . . 19
4.8.5 Minimum Açıklama Uzunluğu (MDL) . . . 20
4.8.6 Bayesçi model seçimi . . . 20
4.9 Notlar (Notes) . . . 21
4.10 Alıştırmalar (Exercises) – Türkçe Çeviri ve Çözümler . . . 22

Ünite 4 – Hızlı Tekrar ve Ders Kontrol Listesi **27**

Parametrik Yöntemler

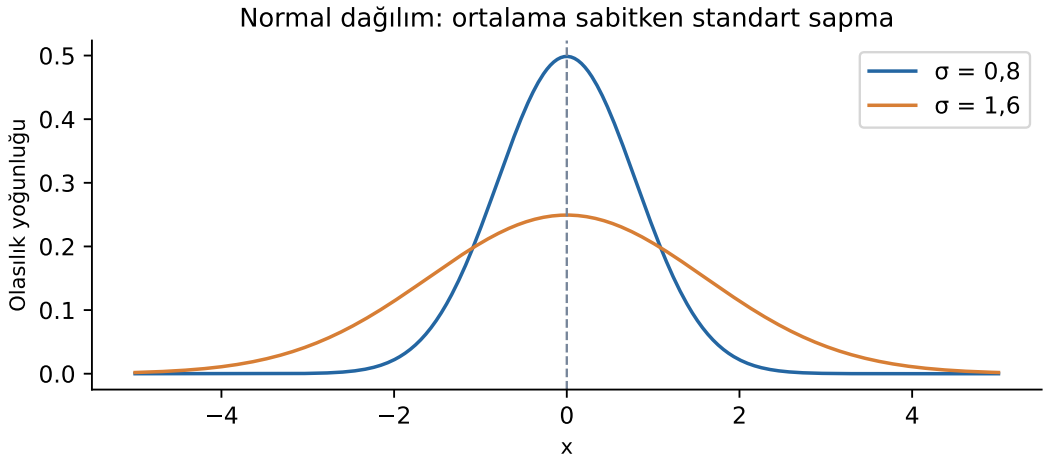
Belirsizliği olasılıklarla ifade ederek en iyi kararın nasıl verildiğini önceki bölümde öğrendik. Bu bölümde, o olasılıkları eğitim verisinden *nasıl tahmin edeceğimizi* inceleyeceğiz. Önce sınıflandırma ve regresyon için parametrik modelleri ele alıyor, ardından yanlılık-varyans ikilemini ve karmaşıklığı kontrol eden model seçim yöntemlerini tartışıyoruz. Yarı parametrik ve parametrik olmayan yöntemler kitabın sonraki bölümlerinde işlenecektir.

4.1 Giriş (Introduction)

Türkçe aktarım. Bir **istatistik**, bir örneklemden hesaplanan herhangi bir değerdir. İstatistiksel çıkarımda, örneklemin sağladığı bilgiye dayanarak karar veririz. Parametrik yaklaşımda örneklemin, örneğin Gaussian gibi *bilinen bir model ailesine* ait dağılımdan geldiğini varsayarız. Bu yaklaşımın avantajı dağılımın az sayıdaki parametreyle tanımlanmasıdır. Gaussian dağılımda bunlar ortalama ve varyanstır. Parametreler tahmin edildiğinde, varsayılan aile içindeki dağılım belirlenir.

Örneklemden parametre tahminlerini elde eder, bunları varsaydığımız dağılıma yerleştirir ve sonra tahmini dağılımla karar veririz. Burada ana parametre öğrenme tekniğimiz **maximum likelihood estimation (MLE)** olacaktır. Bayesçi tahmini de tanıtacağız; ayrıntısı Bölüm 16'dadır.

Genel bir yoğunluk tahmini problemi olan $p(x)$ ile başlarız. Sınıflandırmada bu yoğunluklar $p(x \mid C_i)$ sınıf-koşullu yoğunlukları ve $P(C_i)$ sınıf önselleridir; bunlardan $P(C_i \mid x)$ sonsalları bulunur. Regresyonda ise $p(y \mid x)$ ile ilgileniriz. Bu bölümde x bir boyutludur; çok değişkenli durumlar Bölüm 5'te ele alınır.



Açıklama ve öğretim notu

Örneğin boy dağılımını $\mathcal{N}(170, 25)$ şeklinde modelliyorsak ortalama 170, varyans 25, standart sapma 5'tir. Verilerden bu iki sayıyı öğrenmek, parametreleri öğrenmektir. Parametrik yöntem *bütün gerçek veri dağılımlarının normal olduğunu söylemez*; dağılım ailesi bir modelleme varsayımıdır.

4.2 Maksimum Olabilirlik Tahmini (Maximum Likelihood Estimation)

Türkçe aktarım. Birbirinden bağımsız ve aynı dağılımlı (iid) bir örneklemimiz olsun:

$$X = \{x_t\}_{t=1}^{N}, \qquad x_t \sim p(x \mid \theta).$$

θ, olasılık dağılımını tanımlayan parametrelerdir. Verinin gözlenmesini en olası kılan θ değerini arıyoruz. Bağımsız gözlemlerin ortak olabilirliği her birinin yoğunluk/olasılık değerlerinin çarpımıdır:

$$\ell(\theta \mid X) \equiv p(X \mid \theta) = \prod_{t=1}^{N} p(x_t \mid \theta). \tag{4.1}$$

Olabilirliği en yüksek yapan parametre MLE tahminidir. Logaritma, maksimumun yerini değiştirmez ama çarpımı toplama dönüştürür:

$$L(\theta \mid X) = \log \ell(\theta \mid X) = \sum_{t=1}^{N} \log p(x_t \mid \theta). \tag{4.2}$$

İki sınıflı durumlarda Bernoulli, $K > 2$ sınıfta multinomial/kategorik, sayısal girdiler için sıklıkla Gaussian modellerini kullanacağız.

Adım adım örnek

Bir paranın 10 atışında 7 kez yazı geldiğini düşünelim. Yazı olasılığı p'nin deneyle uyumlu tahmini $\hat{p} = 7/10 = 0.7$ olur. Burada *olasılık* seçilmiş p altında veriyi;

olabilirlik gözlenen veri sabitken farklı p değerlerini karşılaştırır.

4.2.1 Bernoulli Dağılımı (Bernoulli Density)

Türkçe aktarım. Bernoulli değişkeni bir olayın gerçekleşmesi için 1, gerçekleşmemesi için 0 değerini alır. Başarı olasılığı p, başarısızlık olasılığı $1-p$'dir:

$$P(x) = p^x (1-p)^{1-x}, \qquad x \in \{0,1\}. \tag{4.3}$$

Beklenen değer ve varyans:

$$\begin{aligned} E[X] &= 1 \cdot p + 0 \cdot (1-p) = p, \\ \mathrm{Var}(X) &= p(1-p). \end{aligned}$$

Bir iid örneklemde $x_t \in \{0,1\}$ olsun. Log-olabilirlik:

$$\begin{aligned} L(p \mid X) &= \log \prod_t p^{x_t} (1-p)^{1-x_t} \\ &= \Big(\sum_t x_t \Big) \log p + \Big(N - \sum_t x_t \Big) \log (1-p). \end{aligned}$$

Bu ifadeyi p'ye göre türevleyip sıfıra eşitlemek $\hat{p}$ tahminini verir:

$$\boxed{\hat{p} = \frac{\sum_t x_t}{N}.} \tag{4.4}$$

Şapka işareti, gerçek parametreden farklı olarak tahmin değerini belirtir. Başarı sayısının deney sayısına oranı, aynı zamanda Bernoulli örneklem ortalamasıdır. Tahmin de örnekleme bağlı rastgele değişkendir: yeni örneklemler farklı $\hat{p}$ değerleri üretebilir; N büyüdüğünde bunların değişkenliği tipik olarak küçülür.

Adım adım örnek

$X = (1,0,1,1,0)$ için $N = 5$ ve üç başarı var. Olabilirlik $\ell(p) = p^3(1-p)^2$ ve log-olabilirlik $3\log p + 2\log(1-p)$ olur.

$$\frac{dL}{dp} = \frac{3}{p} - \frac{2}{1-p} = 0 \;\Rightarrow\; 3(1-p) = 2p \;\Rightarrow\; \boxed{\hat{p} = 0.6}.$$

Böylece formülün türev yoluyla da aynı sonucu verdiğini görüyoruz.

4.2.2 Multinomial Dağılım (Multinomial Density)

Türkçe aktarım. Bernoulli'nin genellemesinde sonuç, birbirini dışlayan ve bütün olasılıkları kapsayan K durumdan biridir. Bunların olasılıkları p_i ve $\sum_i p_i = 1$ olsun. Sonuç i ise $x_i = 1$, değilse $x_i = 0$ olan gösterge değişkenlerini kullanırız:

$$P(x_1, \ldots, x_K) = \prod_{i=1}^{K} p_i^{x_i}. \tag{4.5}$$

N bağımsız deneyden t'sinin sonucunu x_i^t ile kodlayalım; her t için $\sum_i x_i^t = 1$'dir. i kategorisinin MLE tahmini:

$$\boxed{\hat{p}_i = \frac{\sum_t x_i^t}{N}.} \tag{4.6}$$

İstenen sınıfın görülme sayısı toplam gözlem sayısına bölünür. Bu sonuç her göstergeyi Bernoulli düşünerek ya da $\sum p_i = 1$ kısıtı altında log-olabilirliği en büyük yaparak elde edilir. (Tek deneyin K durumdan birini vermesi kategorik dağılım; N deneyin sınıf sayımlarını modellemek multinomial dağılımdır.)

Adım adım örnek

20 meyvenin 10'u elma, 6'sı muz, 4'ü portakal olsun. $\hat{p}_{\text{elma}} = 10/20 = 0.5$, $\hat{p}_{\text{muz}} = 0.3$, $\hat{p}_{\text{portakal}} = 0.2$ bulunur. Toplamları 1'dir. Elma için gösterge vektörü $(1, 0, 0)$, portakal için $(0, 0, 1)$ olur.

4.2.3 Gaussian (Normal) Yoğunluk

Türkçe aktarım. Ortalaması μ, varyansı σ^2 olan bir Gaussian değişkeni $X \sim \mathcal{N}(\mu, \sigma^2)$ ile gösterilir. Yoğunluğu:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \quad -\infty < x < \infty. \tag{4.7}$$

Örneklem bu dağılımdan geliyorsa log-olabilirlik:

$$L(\mu, \sigma \mid X) = -\frac{N}{2}\log(2\pi) - N\log\sigma - \frac{\sum_t (x_t - \mu)^2}{2\sigma^2}.$$

Log-olabilirliğin μ ve σ üzerindeki kısmi türevlerini sıfıra eşitleyince:

$$\boxed{m = \frac{\sum_t x_t}{N}, \qquad s^2 = \frac{\sum_t (x_t - m)^2}{N}.} \tag{4.8}$$

Anakütle parametreleri genellikle Yunan harfleriyle (μ, σ), örneklem tahminleri Latin harfleriyle (m, s) veya şapkalı gösterimle $(\hat{\mu})$ yazılır.

Adım adım örnek

$X = (60, 70, 80)$ için $m = (60+70+80)/3 = 70$. Kareli sapmalar $100, 0, 100$'dür. Gaussian MLE varyansı $s^2 = 200/3 = 66.67$ ve standart sapma $s \approx 8.16$ bulunur. **Neden $N-1$ değil?** Çünkü bu maksimum olabilirlik tahminidir; yansız varyans tahmini sonraki bölümde ele alınacaktır.

4.3 Bir Tahmin Ediciyi Değerlendirmek: Yanlılık ve Varyans

Türkçe aktarım. X, bilinmeyen θ parametresiyle belirlenen anakütleden örneklem, $d = d(X)$ de tahmin edici olsun. Tek örneklemde kareli tahmin hatası $(d(X) - \theta)^2$'dir. Tahmin edici rastgele olduğu için farklı örneklemler üzerindeki beklenen değerini inceleriz:

$$r(d, \theta) = E[(d(X) - \theta)^2]. \tag{4.9}$$

Tahmin edicinin yanlılığı:

$$b_\theta(d) = E[d(X)] - \theta. \tag{4.10}$$

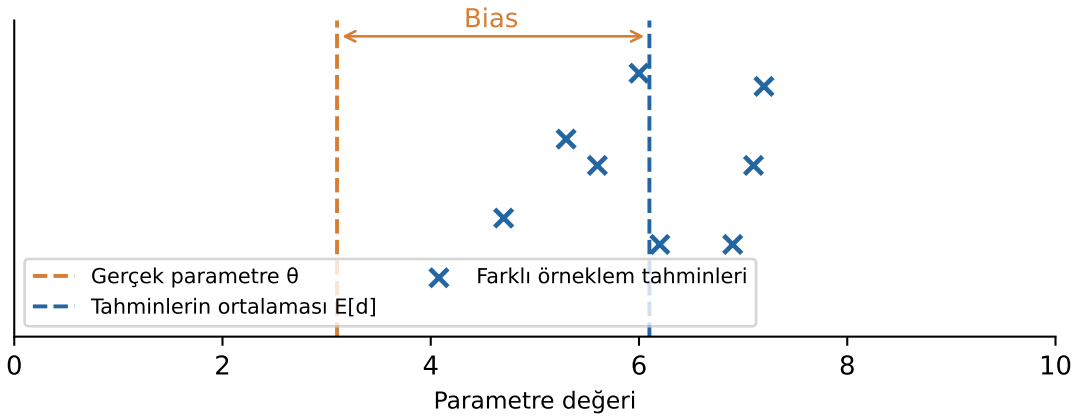
Her θ için yanlılık sıfırsa tahmin edici *yansızdır*. Ortalama μ olan iid gözlemlerde $m = \sum x_t/N$, gerçek ortalamanın yansız tahminidir:

$$E[m] = E\left[\frac{1}{N}\sum_t x_t\right] = \frac{1}{N}\sum_t E[x_t] = \mu.$$

Bu, tek bir örneklem ortalamasının mutlaka μ'ye eşit olacağı anlamına gelmez. Ancak örneklem ortalaması tutarlı bir tahmin edicidir:

$$\text{Var}(m) = \text{Var}\left(\frac{\sum_t x_t}{N}\right) = \frac{\sigma^2}{N} \xrightarrow[N\to\infty]{} 0.$$

N büyüdükçe tahminlerin örneklemler arasındaki dalgalanması azalır.



Şekil 4.1'in yeniden çizimi: Gerçek değer ile ortalama tahmin arasındaki uzaklık bias; ayrı veri kümelerinin tahminlerinin dağılımı varyanstır.

4.3.1 Gaussian varyans MLE tahmininin yanlı olması

Kitaptaki s^2 tahmini:

$$s^2 = \frac{\sum_t (x_t - m)^2}{N} = \frac{\sum_t x_t^2 - Nm^2}{N}.$$

$E[X^2] = \text{Var}(X) + (E[X])^2$ olduğundan $E[x_t^2] = \sigma^2 + \mu^2$ ve $E[m^2] = \sigma^2/N + \mu^2$. Bunları yerine koyarsak:

$$\begin{aligned} E[s^2] &= \frac{N(\sigma^2 + \mu^2) - N(\sigma^2/N + \mu^2)}{N} \\ &= \frac{N-1}{N}\sigma^2 \neq \sigma^2. \end{aligned}$$

Demek ki s^2 yanlıdır. Yansız örneklem varyansı:

$$\boxed{s^2_{\text{yansız}} = \frac{\sum_t (x_t - m)^2}{N-1}}$$

olur. N büyüdükçe fark ihmal edilebilir duruma gelir; bu, asimptotik yansızlığa örnektir.

Adım adım örnek

$X = (60, 70, 80)$ için $m = 70$ ve kareli sapma toplamı 200'dür. MLE varyansı $200/3 = 66.67$; yansız örneklem varyansı ise $200/(3-1) = 100$ olur. $N-1$ ifadesi ortalamanın aynı örneklemden öğrenilmesiyle kalan serbestlik derecesinden gelir.

4.3.2 Ortalama karesel hatanın ayrıştırılması

Türkçe aktarım. Ortalama karesel hata, sıfır ekleyerek yeniden düzenlenebilir:

$$\begin{aligned} r(d,\theta) &= E[(d-\theta)^2] \\ &= E[(d-E[d]+E[d]-\theta)^2] \\ &= E[(d-E[d])^2] + (E[d]-\theta)^2, \end{aligned}$$

çünkü $E[d-E[d]] = 0$ ve çapraz terimin beklenen değeri sıfırdır. İlk terim varyans, ikinci terim yanlılığın karesidir:

$$\boxed{r(d,\theta) = \mathrm{Var}(d) + b_\theta(d)^2.} \tag{4.11–4.12}$$

Açıklama ve öğretim notu

Önemli ayrım: Yanlılık tahminlerin *ortalama konumunu*, varyans farklı eğitim örneklemlerindeki *yayılımını* gösterir. Bir tahmin edici yansız olsa bile yüksek varyansı nedeniyle büyük toplam hataya sahip olabilir.

Adım adım örnek

Gerçek parametre $\theta = 10$, tahmin edicinin beklenen değeri $E[d] = 12$ ve varyansı $\mathrm{Var}(d) = 4$ olsun. Bias $12 - 10 = 2$, bias$^2 = 4$ ve $\boxed{\mathrm{MSE} = 4 + 4 = 8}$ olur.

4.4 Bayesçi Tahmin Edici (The Bayes' Estimator)

Türkçe aktarım. Örneklemi görmeden önce θ hakkında bir bilgiye sahip olabiliriz. Özellikle örneklem küçük olduğunda bu bilgi önemlidir. Parametrenin kesin değerini bilmiyorsak θ'yı rastgele değişken sayar, önsel yoğunluk $p(\theta)$ tanımlarız.

Örneğin parametrenin

$$P\left(-1.64 < \frac{\theta-\mu}{\sigma} < 1.64\right) \approx 0.9, \qquad \mu = 7, \quad 1.64\sigma = 2.$$

Bu durumda $\sigma = 2/1.64$ ve $p(\theta) = \mathcal{N}(7, (2/1.64)^2)$ seçilebilir.

Önsel yoğunluk veri görülmeden olası parametreleri, olabilirlik $p(X \mid \theta)$ verinin sağladığı bilgiyi gösterir. İkisi Bayes kuralıyla birleştirilir:

$$p(\theta \mid X) = \frac{p(X \mid \theta)p(\theta)}{p(X)} = \frac{p(X \mid \theta)p(\theta)}{\int p(X \mid \theta')p(\theta')\,d\theta'}. \tag{4.13}$$

Sonsal yoğunluk $p(\theta \mid X)$, veriler görüldükten sonra parametre hakkında ne düşündü-

ğümüzü gösterir. Yeni bir x için tahminsel dağılım tüm olası parametrelerden ağırlıklı ortalama ile hesaplanır:

$$p(x \mid X) = \int p(x \mid \theta) p(\theta \mid X)\, d\theta.$$

Regresyondaki $g(x \mid \theta)$ tahmin fonksiyonu için parametreler üzerinden ortalama tahmin:

$$\hat{y} = \int g(x \mid \theta) p(\theta \mid X)\, d\theta.$$

Tam integrasyon zor olabilir. Sonsal yoğunluk tek bir dar tepeye sahipse bunun en yüksek noktasıyla yaklaşım yapılır:

$$\boxed{\theta_{\text{MAP}} = \arg\max_{\theta} p(\theta \mid X).} \tag{4.14}$$

Böylece $p(x \mid X) \approx p(x \mid \theta_{\text{MAP}})$ ve $\hat{y}_{\text{MAP}} = g(x \mid \theta_{\text{MAP}})$ kullanılır. Önsel yoğunluk ilgili parametreler için sabitse MAP, MLE'ye karşılık gelir:

$$\boxed{\theta_{\text{ML}} = \arg\max_{\theta} p(X \mid \theta).} \tag{4.15}$$

Bayesçi nokta tahmin edicisinin başka seçeneği sonsal ortalamadır:

$$\boxed{\theta_{\text{Bayes}} = E[\theta \mid X] = \int \theta p(\theta \mid X)\, d\theta.} \tag{4.16}$$

Kareli hata altında bir rastgele değişkenin en iyi sabit tahmini ortalamasıdır: $E[\theta] = \mu$ için

$$E[(\theta - c)^2] = E[(\theta - \mu)^2] + (\mu - c)^2. \tag{4.17}$$

İkinci terim $c = \mu$ olduğunda sıfırdır. Normal sonsal dağılımda ortalama ve tepe noktası aynı olduğundan Bayes ve MAP nokta tahminleri eşit olur.

4.4.1 Gaussian önsel ile Gaussian gözlemin birleşimi

Türkçe aktarım. $x_t \sim \mathcal{N}(\theta, \sigma^2)$ ve $\theta \sim \mathcal{N}(\mu_0, \sigma_0^2)$ olsun. μ_0, σ_0^2 ve σ^2 biliniyorsa olabilirlik ve önsel normal yoğunluklardır; sonsal da normaldir. Sonsal ortalama:

$$\boxed{E[\theta \mid X] = \frac{N/\sigma^2}{N/\sigma^2 + 1/\sigma_0^2}\, m + \frac{1/\sigma_0^2}{N/\sigma^2 + 1/\sigma_0^2}\, \mu_0.} \tag{4.18}$$

Bu, örneklem ortalaması m ve önsel ortalama μ_0'ın ağırlıklı ortalamasıdır. Örneklem sayısı artınca veri ağırlığı artar. Önsel varyans küçükse veya gözlem azsa önsel bilgi daha etkilidir. MAP ve Bayes nokta tahminleri sonsal dağılımın bütün belirsizlik bilgisini taşımaz; integral zor olduğunda Monte Carlo ve yaklaştırma yöntemleri kullanılabilir.

Adım adım örnek

Ürünün eski kayıtlarına göre ortalama ağırlığı $\mu_0 = 7$ g, önsel varyans $\sigma_0^2 = 1$ olsun. Dört yeni ölçüm $(8, 9, 10, 9)$ g ve bilinen ölçüm varyansı $\sigma^2 = 4$ olsun. $m = 9$

ve $N/\sigma^2 = 1$, $1/\sigma_0^2 = 1$ olduğundan:

$$\theta_{\text{Bayes}} = \frac{1}{2}(9) + \frac{1}{2}(7) = \boxed{8\ \text{g}}.$$

Aynı ortalamalı 16 yeni ölçüm olsaydı veri ağırlığı $4/5$ olurdu: $\theta_{\text{Bayes}} = (4/5)9 + (1/5)7 = 8.6$ g. Veri arttıkça tahmin 9'a yaklaşır.

Karşılaştırma: MLE yalnızca olabilirliği en büyük yapar; MAP sonsal yoğunluğun tepesini seçer; bu bölümün Bayes tahmin edicisi karesel kayıp altında sonsal ortalamayı kullanır. Aynı yöntem değildirler ve farklı koşullarda farklı sonuç üretebilirler.

4.5 Parametrik Sınıflandırma (Parametric Classification)

Türkçe aktarım. Bölüm 3'te Bayes kuralıyla sınıf sonsal olasılıkları:

$$P(C_i \mid x) = \frac{p(x \mid C_i)P(C_i)}{p(x)} = \frac{p(x \mid C_i)P(C_i)}{\sum_{k=1}^{K} p(x \mid C_k)P(C_k)}. \tag{4.19}$$

Sınıflandırma için $g_i(x) = p(x \mid C_i)P(C_i)$ ayırıcı fonksiyonu kullanılabilir. Eşdeğer logaritmik ayırıcı:

$$g_i(x) = \log p(x \mid C_i) + \log P(C_i). \tag{4.20}$$

En büyük ayırıcı değeri veren sınıf seçilir. Sınıf-koşullu yoğunlukları Gaussian kabul edersek:

$$p(x \mid C_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left[-\frac{(x-\mu_i)^2}{2\sigma_i^2}\right]. \tag{4.21}$$

Buna göre logaritmik ayırıcı:

$$g_i(x) = -\frac{1}{2}\log(2\pi) - \log \sigma_i - \frac{(x-\mu_i)^2}{2\sigma_i^2} + \log P(C_i). \tag{4.22}$$

4.5.1 Otomobil müşterileri örneği ve parametre öğrenimi

Türkçe aktarım. K farklı otomobil modeli satan bir şirketin, müşteri seçimlerini etkileyen tek özelliğin yıllık gelir x olduğunu varsayalım. $P(C_i)$, i modelini satın alanların oranı; $p(x \mid C_i)$ ise o modeli alan müşterilerin gelir yoğunluğudur. Gelirler yaklaşık Gaussian ise her model için ayrı bir μ_i ve σ_i^2 kullanılabilir.

Bunlar bilinmiyorsa eğitim çiftlerinden $X = \{(x_t, r^t)\}_{t=1}^N$ hesaplanır:

$$X = \{(x_t, r^t)\}_{t=1}^N. \tag{4.23}$$

$$r_i^t = \begin{cases} 1, & x_t \in C_i, \\ 0, & x_t \in C_k,\ k \neq i. \end{cases} \tag{4.24}$$

$$\boxed{m_i = \frac{\sum_t x_t r_i^t}{\sum_t r_i^t}}. \tag{4.25}$$

$$\boxed{s_i^2 = \frac{\sum_t (x_t - m_i)^2 r_i^t}{\sum_t r_i^t}.} \tag{4.26}$$

$$\boxed{\hat{P}(C_i) = \frac{\sum_t r_i^t}{N}.} \tag{4.27}$$

Burada r_i^t, sadece ilgili sınıfa ait gözlemlerin hesaplamaya katılmasını sağlar.

Adım adım örnek

Ekonomik araç C_1 için gelirler $(20, 30, 40)$, lüks araç C_2 için $(60, 70, 80)$ olsun. Her sınıfta üç müşteri vardır. $m_1 = 30$, $m_2 = 70$ ve $s_1^2 = s_2^2 = (100 + 0 + 100)/3 \approx 66.67$ bulunur. Altı müşterinin yarısı her sınıfta olduğundan $\hat{P}(C_1) = \hat{P}(C_2) = 0.5$'tir.

Parametrelerin tahminlerini ayırıcı fonksiyona koyunca:

$$g_i(x) = -\frac{1}{2}\log(2\pi) - \log s_i - \frac{(x - m_i)^2}{2s_i^2} + \log \hat{P}(C_i). \tag{4.28}$$

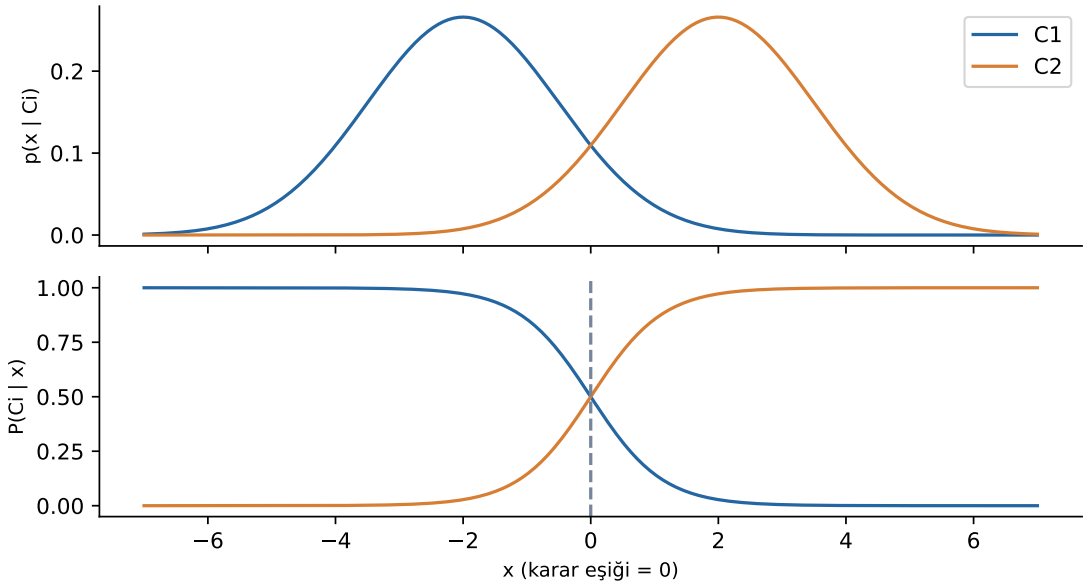
İlk terim bütün sınıflarda aynıdır ve karar açısından çıkarılabilir. Önsel olasılıklar eşitse son terim de kaldırılabilir. Varyanslar da eşit olduğunda geriye karar açısından eşdeğer biçim kalır:

$$g_i(x) = -(x - m_i)^2. \tag{4.29}$$

Böylece x, ortalaması en yakın sınıfa atanır. İki sınıfta eşit karar koşulundan:

$$(x - m_1)^2 = (x - m_2)^2 \quad \Rightarrow \quad \boxed{x_{\text{eşik}} = \frac{m_1 + m_2}{2}}.$$

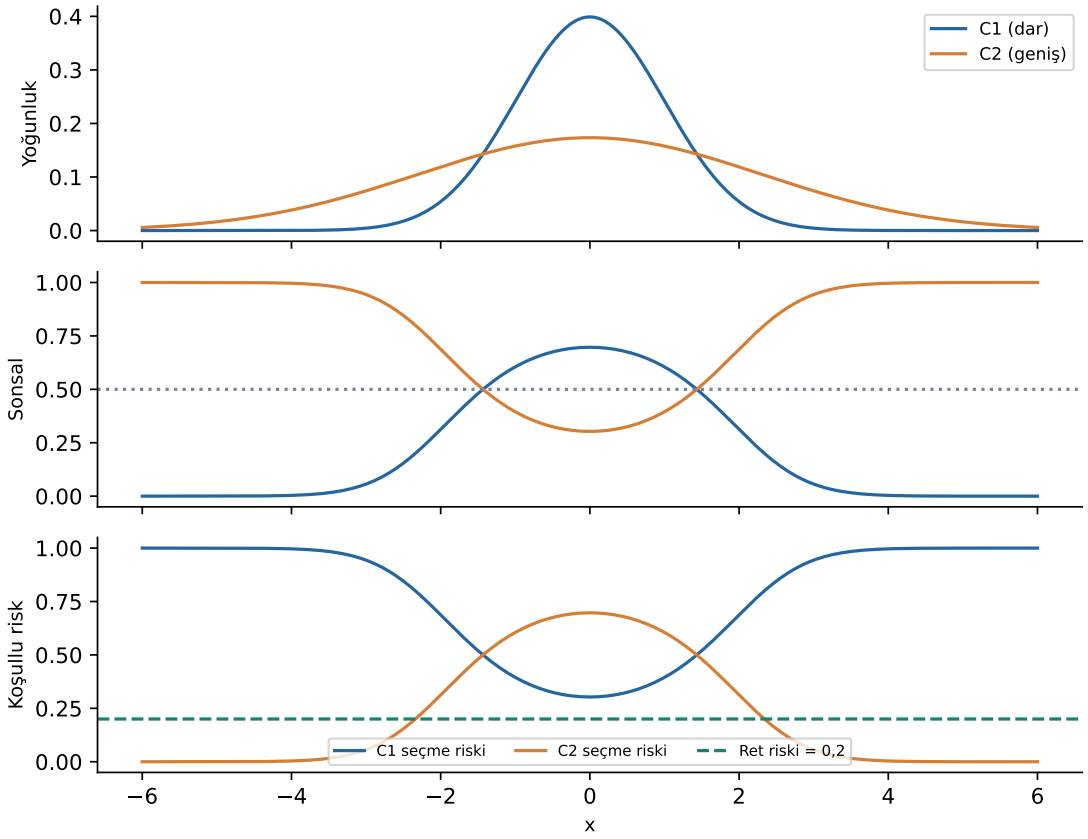
Örnekte eşik $(30 + 70)/2 = 50$'dir. Geliri 45 olan müşterinin sınıf ortalamalarına uzaklıkları 15 ve 25 olduğundan C_1 seçilir.



Şekil 4.2'nin yeniden çizimi: Eşit varyans ve eşit önseller altında olabilirlikler ve sonsal olasılıklar tek bir noktada kesişir. Örnek ortalamalar -2 ve 2 seçilmiştir.

4.5.2 Eşit olmayan varyanslar ve reddetme kararı

Türkçe aktarım. Varyanslar farklıysa iki sınıfın ayırıcı fonksiyonlarının eşitlenmesi ikinci dereceden bir denklem verebilir ve iki karar eşiği oluşabilir (kitabın Şekil 4.3 örneği). Önsel olasılıklar farklı olduğunda karar sınırı, diğer koşullar eşitken, daha az olası sınıfın ortalamasına doğru kayma eğilimindedir. Şekilde ayrıca yanlış sınıflandırma yerine *karar vermemeyi* seçen bir reddetme eylemi için $\lambda = 0.2$ risk eğrisi gösterilir.



Şekil 4.3'ün mesajını yeniden gösteren üç panel. İki sınıf farklı yayılıma sahiptir; sonsal olasılıklar ve koşullu riskler karşılaştırılır. Buradaki parametreler yeniden çizim içindir.

Bu bölümde MLE ile parametre öğrendik; ortalamalar için önsel bilgimiz varsa Bayesçi tahmini de kullanabiliriz. Ancak sürekli girdilerde Gaussian varsayımını kontrol etmeden kullanmamalıyız. Histogramın tek tepeli ve yaklaşık simetrik olması yararlı bir başlangıç kontrolüdür; gerektiğinde normallik sınamaları yapılmalıdır. Buradaki yaklaşım *yoğunluk temelli sınıflandırma*dır: yoğunlukları tahmin eder, Bayes kuralını uygular, ayırıcı fonksiyonu kurarız. Sonraki bölümlerde yoğunlukları ara adım olarak tahmin etmeden doğrudan ayırıcı öğrenen yöntemler görülecektir.

Açıklama ve öğretim notu

Dağılım varsayımının önemi: Eğer gerçekte $p(x \mid C_i)$ normal değilse Gaussian modeliyle bulunan eşikler güvenilir olmayabilir. Verinin şekline, uç değerlere ve sınıf başına örneklem sayısına bakmak gerekir. Şekil 4.3 için *her parametre seçimi iki eşik vermez*; köklerin sayısı diskriminanta bağlıdır.

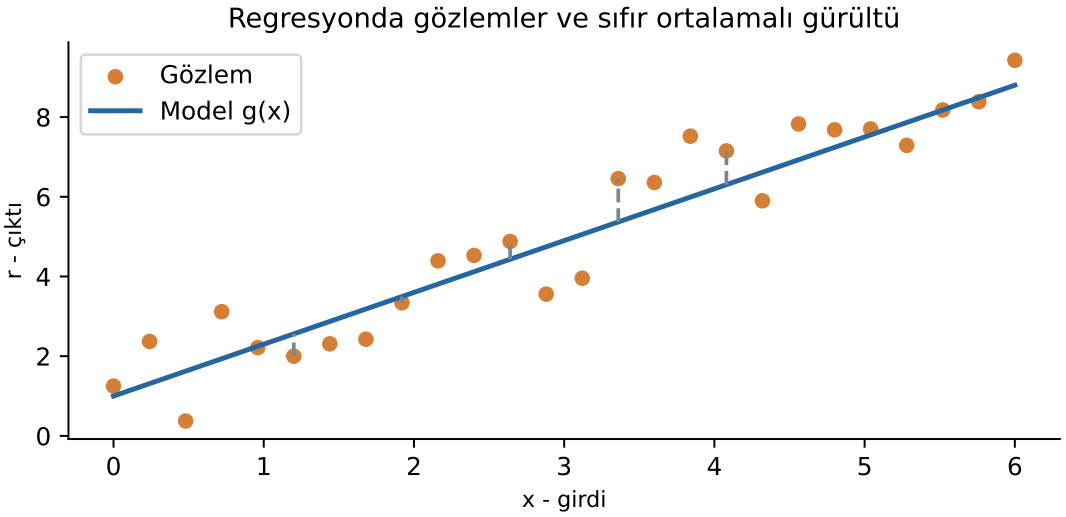
4.6 Regresyon (Regression)

Türkçe aktarım. Regresyonda sayısal çıktı (bağımlı değişken) r'yi girdinin (bağımsız değişken) fonksiyonu olarak yazmak isteriz. Gerçek çıktı, bilinmeyen deterministik bir fonksiyon ve rastgele gürültünün toplamı olsun:

$$r = f(x) + \varepsilon.$$

Bilinmeyen $f(x)$, parametreleri θ olan $g(x \mid \theta)$ ile yaklaşık temsil edilir. Gürültü sıfır ortalamalı, sabit varyanslı Gaussian ise $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ve:

$$p(r \mid x) = \mathcal{N}(g(x \mid \theta), \sigma^2). \tag{4.30}$$



Şekil 4.4'ün yeniden çizimi: Doğrusal modelin etrafına Gaussian gürültü eklenmiş gözlemler. Dikey uzaklıklar hata terimlerini temsil eder.

4.6.1 Gaussian gürültüden en küçük karelere

Türkçe aktarım. Model parametrelerini yine MLE ile öğreniriz. Eğitim çiftleri bilinmeyen ortak dağılımdan gelir ve $p(x, r) = p(r \mid x)p(x)$ yazılabilir. İid veri için:

$$\begin{aligned} L(\theta \mid X) &= \log \prod_t p(x_t, r^t) \\ &= \log \prod_t p(r^t \mid x_t) + \log \prod_t p(x_t). \end{aligned}$$

θ'ya bağlı olmayan son terim parametre optimizasyonunda dikkate alınmaz. Gaussian modelden:

$$L(\theta \mid X) = \log \prod_{t=1}^{N} \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(r^t - g(x_t \mid \theta))^2}{2\sigma^2}\right]. \tag{4.31}$$

Logaritması:

$$L(\theta \mid X) = -N \log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_t (r^t - g(x_t \mid \theta))^2.$$

σ^2 bu aşamada sabit alındığında olabilirliği en büyük yapmak aşağıdaki kareli hata toplamını en küçük yapmaktır:

$$\boxed{E(\theta \mid X) = \frac{1}{2}\sum_{t=1}^{N}(r^t - g(x_t \mid \theta))^2.} \tag{4.32}$$

Bunu minimize eden parametrelere *en küçük kareler tahmini* denir. Olasılık yoğunluğundaki üstel yapı nedeniyle maksimum log-olabilirlik problemi hata fonksiyonunu minimize etme problemine dönüştürülebilir.

Adım adım örnek

Gerçek değerler $(10, 20, 30)$, tahminler $(9, 22, 28)$ olsun. Hatalar $(1, -2, 2)$, kareleri $(1, 4, 4)$ ve toplamları $SSE = 9$'dur. Kitabın fonksiyonu $E = SSE/2 = 4.5$; ortalama karesel hata $MSE = SSE/3 = 3$'tür. Bu üçü eğitim örnek sayısı sabitken aynı parametre minimumuna sahiptir.

4.6.2 Doğrusal regresyon (Linear Regression)

Türkçe aktarım. Bir boyutlu doğrusal model:

$$g(x_t \mid w_1, w_0) = w_1 x_t + w_0.$$

Kareli hata E'yi sırasıyla w_0 ve w_1'e göre türevleyip sıfıra eşitleyince iki normal denklem elde edilir:

$$\sum_t r^t = N w_0 + w_1 \sum_t x_t, \qquad \sum_t r^t x_t = w_0 \sum_t x_t + w_1 \sum_t x_t^2.$$

Bunları matrisle yazalım:

$$Aw = y, \qquad A = \begin{bmatrix} N & \sum x_t \\ \sum x_t & \sum x_t^2 \end{bmatrix}, \quad w = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}, \quad y = \begin{bmatrix} \sum r^t \\ \sum r^t x_t \end{bmatrix}.$$

A terslenebilirse $w = A^{-1}y$ çözümü kullanılır.

Adım adım örnek

Doğrusal regresyonu sıfırdan hesaplayalım. Veri: $(x, r) = (1, 2), (2, 3), (3, 5)$. $N = 3$, $\sum x = 6$, $\sum r = 10$, $\sum x^2 = 14$, $\sum xr = 23$.

$$\begin{cases} 3w_0 + 6w_1 = 10, \\ 6w_0 + 14w_1 = 23. \end{cases}$$

İlk denklemi ikiyle çarpıp ikinciden çıkarınca $2w_1 = 3$, yani $w_1 = 1.5$ olur. İlk denklemde yerine koyarsak $w_0 = 1/3$. Sonuç:

$$\boxed{\hat{r} = 1.5x + \frac{1}{3}}.$$

Tahminler $(1.833, 3.333, 4.833)$; kareli hatalar $(1/36, 1/9, 1/36)$, toplam $SSE = 1/6$ ve $MSE = 1/18 \approx 0.0556$'dır.

4.6.3 Polinom regresyonu (Polynomial Regression)

Türkçe aktarım. Daha genel model k dereceli polinomdur:

$$g(x_t \mid w_k, \ldots, w_0) = w_k x_t^k + \cdots + w_2 x_t^2 + w_1 x_t + w_0.$$

Fonksiyon x'in polinomu olsa da *ağırlıklar* w_i açısından doğrusaldır. Türevler $k+1$ bilinmeyenli $k+1$ denklem üretir. Matris A'nın (i,j) girdisi $\sum_t x_t^{i+j}$ (indisler $0, \ldots, k$); y'nin i'inci girdisi $\sum_t r^t x_t^i$'dir. Bunun pratik gösterimi tasarım matrisiyle verilir:

$$D = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^k \\ 1 & x_2 & x_2^2 & \cdots & x_2^k \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_N & x_N^2 & \cdots & x_N^k \end{bmatrix}, \qquad r = \begin{bmatrix} r^1 \\ r^2 \\ \vdots \\ r^N \end{bmatrix}.$$

$A = D^T D$ ve $y = D^T r$ olduğundan:

$$\boxed{w = (D^T D)^{-1} D^T r.} \tag{4.33}$$

Bu gösterim $D^T D$ terslenebilir olduğunda geçerlidir. Hesaplamada doğrudan ters almak yerine kararlı en küçük kareler çözücüleri tercih edilir.

Adım adım örnek

Veri noktaları $(1,1), (2,4), (3,9)$ olsun. İkinci dereceli $g(x) = w_2 x^2 + w_1 x + w_0$, $w_2 = 1$, $w_1 = w_0 = 0$ ile bütün noktaları tam karşılar: $g(x) = x^2$. Düz bir doğru, bu üç farklı noktayı aynı anda tam karşılayamaz. Ancak dereceyi daha da artırmak veride gürültü varsa zararlı olabilir.

4.6.4 Göreli kareli hata ve R^2

Türkçe aktarım. Gaussian hata varsayımında en küçük karelerle MLE eşdeğerdir. Regresyon başarısını değerlendiren diğer ölçü *relative square error* (RSE) olarak tanımlanır:

$$\boxed{E_{\text{RSE}} = \frac{\sum_t [r^t - g(x_t \mid \theta)]^2}{\sum_t (r^t - \bar{r})^2}.} \tag{4.34}$$

RSE yaklaşık 1 ise model sürekli çıktı ortalamasını tahmin etmek kadar iyidir; 0'a yaklaştıkça daha başarılı uyum vardır. *Belirleme katsayısı (coefficient of determination)*:

$$\boxed{R^2 = 1 - E_{\text{RSE}}}.$$

İyi uyum için R^2'nin 1'e yakın olması istenir. Değerlendirme bölmesine göre R^2 negatif de olabilir; bu, modelin temel ortalama tahmininden daha kötü olduğunu gösterir.

Adım adım örnek

Doğrusal regresyon örneğinde $SSE = 1/6$, $\bar{r} = 10/3$ ve toplam kareli sapma $SST = 14/3$'tür. $RSE = (1/6)/(14/3) = 1/28 \approx 0.0357$. Bu nedenle $\boxed{R^2 = 27/28 \approx 0.9643}$ olur.

Türkçe aktarım. En iyi genelleme için model karmaşıklığını veri karmaşıklığına uygun seçmeliyiz. Polinom regresyonunda ayarlanacak karmaşıklık parametresi polinom derecesidir. En iyi derece, genelleme hatasını azaltan derecedir; yalnızca eğitim hatasını en aza indiren değil.

4.7 Model Karmaşıklığını Ayarlamak: Yanlılık/Varyans İkilemi

Türkçe aktarım. Örneklemimiz $X = \{(x_t, r^t)\}$ bilinmeyen $p(x, r)$ ortak yoğunluğundan gelsin; bu örneklemden $g(\cdot)$ tahmin edicisini oluşturalım. Belirli x için karesel tahmin hatası:

$$E[(r - g(x))^2 \mid x] = \underbrace{E[(r - E[r \mid x])^2 \mid x]}_{\text{Gürültü}} + \underbrace{(E[r \mid x] - g(x))^2}_{\text{Kareli model hatası}}. \tag{4.35}$$

İlk terim r'nin x koşulundaki varyansıdır; seçilen g'den bağımsız, bu modelde σ^2'ye eşit olan azaltılamaz gürültüdür. İkinci terim tahminin gerçek regresyon fonksiyonu $E[r \mid x]$'ten uzaklığıdır ve eğitim veri kümesi değiştikçe farklılaşabilir.

Bu yüzden bütün olası aynı boyuttaki eğitim veri kümeleri üzerinde ortalama alırız. Bölüm 4.3'teki ayrıştırmadan:

$$E_X[(E[r \mid x] - g(x))^2] = \underbrace{(E[r \mid x] - E_X[g(x)])^2}_{\text{Bias}^2} + \underbrace{E_X[(g(x) - E_X[g(x)])^2]}_{\text{Variance}}. \tag{4.36}$$

Böylece regresyonda sabit x için beklenen kareli hata:

$$\boxed{\text{Hata} = \text{Bias}^2 + \text{Variance} + \text{Gürültü}.}$$

Açıklama ve öğretim notu

Bias modelin eğitim örneklemleri arasında ortalama tahmininin gerçeğe uzaklığı, **variance** ise bu farklı örneklemlerle eğitildiğinde tahminlerin birbirinden ne kadar saptığıdır. **Noise** seçilen girdilerle açıklanamayan rastgeleliktir. Aynı hata ayrıştırması 0/1 sınıflandırma kaybına doğrudan taşınamaz (Bölüm 4.9).

4.7.1 Bias ve varyansı kontrollü deneyde ölçmek

Türkçe aktarım. Öğretici bir deneyde bilinen f fonksiyonundan gürültü ekleyerek M farklı X_i veri kümesi üretir ve her birinden g_i modeli eğitiriz. Gerçek hayatta f ve

gürültü parametreleri bilinmediği için böyle bir doğrudan karşılaştırma çoğu zaman yapılamaz. Modellerin ortalama tahmini:

$$\bar{g}(x) = \frac{1}{M}\sum_{i=1}^{M} g_i(x).$$

Bir ölçüm ızgarası $x_1, \ldots, x_N$ üzerinde kareli bias ve varyans yaklaşık olarak:

$$\widehat{\text{Bias}^2} = \frac{1}{N}\sum_{t}[\bar{g}(x_t) - f(x_t)]^2,$$

$$\widehat{\text{Variance}} = \frac{1}{NM}\sum_{t}\sum_{i}[g_i(x_t) - \bar{g}(x_t)]^2.$$

Adım adım örnek

Beş bağımsız eğitimin belirli $x = 2$ noktasındaki tahminleri $(6, 7, 5, 6, 8)$ ve gerçek $f(2) = 7$ olsun. Ortalama tahmin $\bar{g}(2) = 6.4$, kareli bias $(6.4-7)^2 = 0.36$'dır. Kareli sapmalar $(0.16, 0.36, 1.96, 0.16, 2.56)$ toplamı 5.20 olduğundan varyans $5.20/5 = 1.04$'tür.

4.7.2 Basitten karmaşığa: underfitting ve overfitting

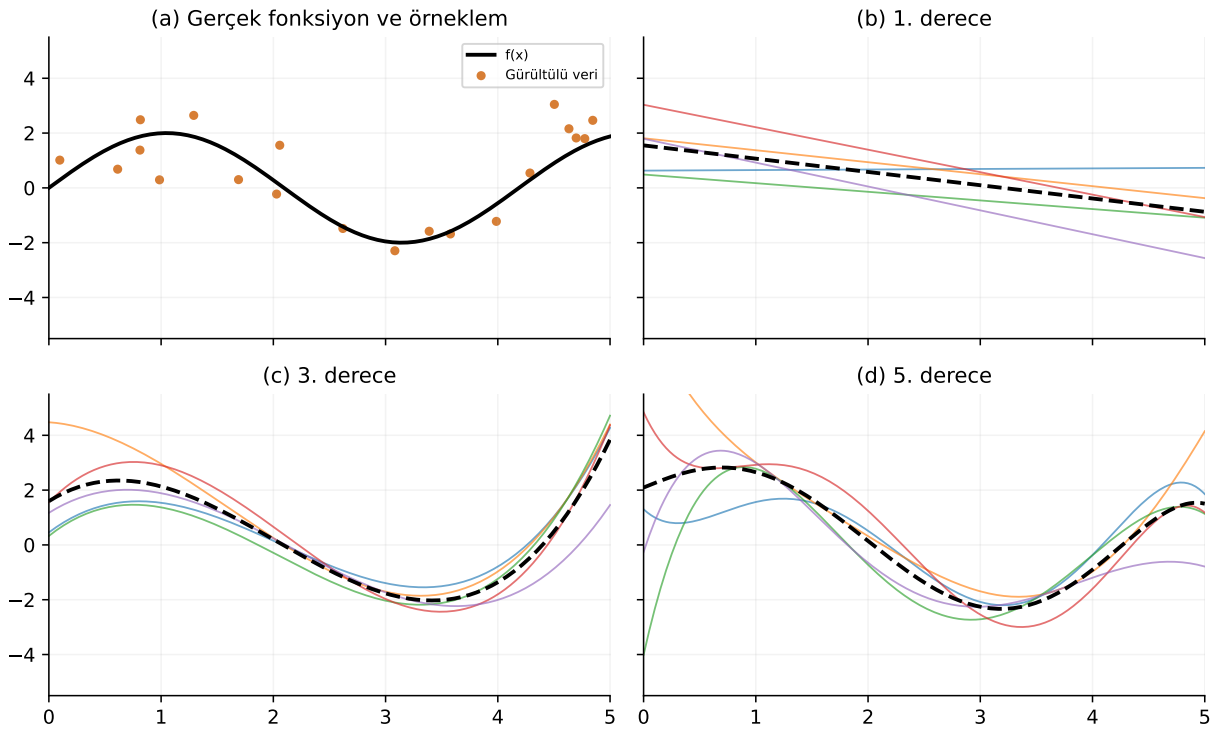
Türkçe aktarım. En basit model $g_i(x) = 2$ sabitidir: veri kullanılmadığından farklı örneklemlerde aynı tahmini verir, varyansı sıfırdır; ancak gerçek $f(x)$ yaklaşık 2 değilse bias'ı yüksektir. Sabit 2 yerine her örneklemin ortalamasını kullanmak:

$$g_i(x) = \frac{1}{N}\sum_{t} r_{ti}$$

genellikle bias'ı azaltır ama farklı örneklemlerin ortalamaları farklı olduğu için varyansı artırır. Çoğu durumda toplam hata düşebilir.

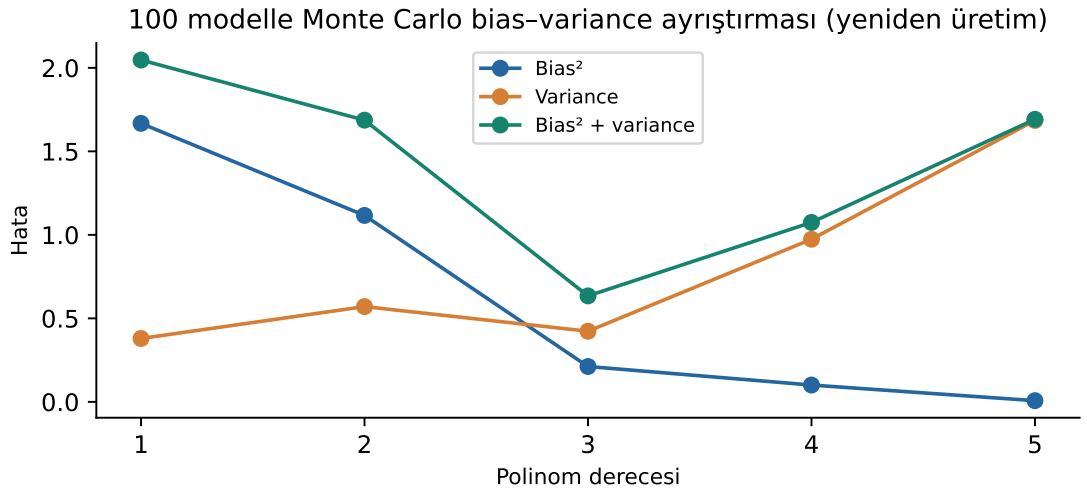
Polinom derecesi artınca model küçük veri değişimlerine daha hassas olabilir ve varyans yükselir. Buna karşılık daha esnek model gerçek fonksiyona daha iyi uyabilir; bias düşer. Bu *bias/variance dilemma* yalnızca polinomlara değil genel öğrenme sistemlerine uygulanır. Bias'ı düşürmek esneklik gerektirir ama yüksek varyans riski taşır; varyansı küçük tutmak ise modelin gereğinden basit kalmasına yol açabilir.

Model sınıfı gerçek fonksiyonu yakalayamayacak kadar sınırlıysa **underfitting**; model eğitimdeki gürültüyü de takip edecek kadar esnekse **overfitting** görülebilir. Buradaki istatistiksel bias ile Bölüm 2'deki *inductive bias* farklı ama ilişkili kavramlardır. Varyans eğitim verisi arttıkça genellikle sınırlandırılabilir. Küçük hata için uygun model varsayımları ve yeterli örneklem birlikte gereklidir.



Şekil 4.5'in deneyinin yeniden üretimi: $f(x) = 2\sin(1.5x)$, Gaussian gürültü $\mathcal{N}(0, 1)$, her biri 20 gözlemli beş veri kümesi. 1., 3. ve 5. derece polinomlar karşılaştırılır; örnekleme farklı olduğu için eğriler kitabın sayfasıyla tam aynı değildir.

Türkçe aktarım. Şekil 4.5'te 1. derece fonksiyon çoğu eğriyi yakalayamayabilir (yüksek bias), 3. derece dengeli temsil sunabilir, 5. derece ise özellikle verinin seyrek olduğu uçlarda değişken olabilir. Bu eğilim Şekil 4.6'da 100 modelle ölçülür: 1. derecede en küçük varyans, 5. derecede en küçük bias, toplam hatada ise 3. derece minimumdur.



Şekil 4.6'nın fikrini gösteren Monte Carlo yeniden üretimi (100 eğitim örneklemi). Model derecesi büyürken bias ile varyans karşıt yönde davranabilir. Burada gösterilen sayılar yeniden simülasyona aittir.

Varyansı yüksek ancak düşük bias'lı modellerin tahminlerini ortalamak bazı koşullarda varyansı azaltabilir. Model birleştirme (ensemble) yöntemleri kitabın 17. bölü-

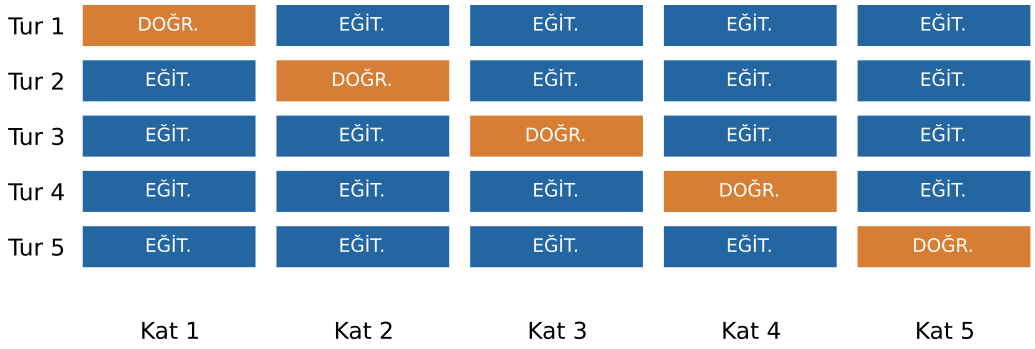
münde ele alınacaktır. Ortalamanın faydası modellerin hata korelasyonuna bağlıdır; her durumda garantili değildir.

4.8 Model Seçim Yöntemleri (Model Selection Procedures)

Türkçe aktarım. Model karmaşıklığını ince ayarlamak için farklı yöntemler vardır. Pratikte en uygun karmaşıklığı bulmanın temel yolu doğrulama temelli seçimdir. Gerçek bias ve varyansı çoğu durumda hesaplayamayız, ama toplam tahmin hatasını ölçebiliriz. Verileri eğitim ve doğrulama bölümlerine ayırır; farklı karmaşıklıktaki modelleri eğitimde öğrenir ve doğrulamada ölçeriz. Eğitim hatası karmaşıklık arttıkça çoğunlukla düşerken doğrulama hatası bir noktadan sonra sabitlenebilir veya artabilir. Bu dönüş noktası, uygun karmaşıklığı gösterebilir.

4.8.1 Doğrulama ve çapraz doğrulama

Kitabın ilk anlattığı tek eğitim-doğrulama ayrımı *hold-out validation* olarak da bilinir. *K-fold cross-validation* bu işlemi birkaç farklı bölmeyle tekrarlar. Her model ayarı için aynı değerlendirme prosedürünü kullanmak gerekir.

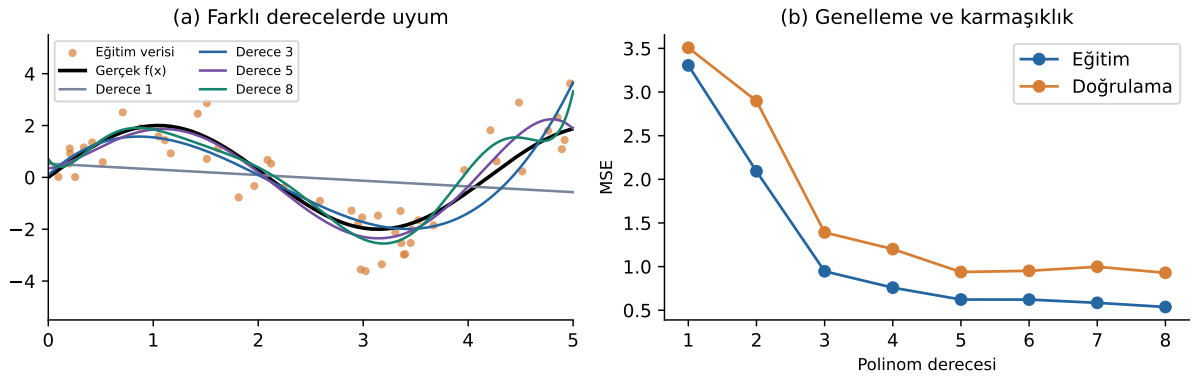


Ek öğretici çizim: 5-fold çapraz doğrulamada her turda ayrı bir parça doğrulamaya ayrılır; diğer dört parça model öğreniminde kullanılır.

Adım adım örnek

5-fold doğrulamadaki MSE değerleri $4, 5, 3, 4, 6$ olsun. Ortalama CV hatası $\bar{E}_{CV} = (4+5+3+4+6)/5 = \boxed{4.4}$'tür. Aynı işlem farklı polinom dereceleri veya düzenleştirme katsayıları için yapılır; düşük ortalama doğrulama hatasına sahip aday seçilir.

Türkçe aktarım. Şekil 4.6 gerçek fonksiyon bilindiği için bias ve varyansı ayrıştırabilir. Gerçek problemlerde doğrulama hatası bu toplamın, ayrıca gürültüyü de içeren bir göstergesidir; doğru modelde dahi sıfır olmayabilir. Şekil 4.7'de daha büyük örneklem kullanıldığından doğrulama hatası keskin V şeklinde değildir: veri artışı yüksek derece modellerin varyansını azaltabilir. Beşinci derece polinom bile verinin bol olduğu bölgelerde daha düzenli, uçlarda daha güvensiz davranabilir.



Şekil 4.7 deneyine benzer yeniden üretim: 50 eğitim ve 50 doğrulama örneğiyle 1.–8. derece polinomlar. Kaynak deneyde dirsek 3. derecededir; yeniden simülasyondaki minimum derece rasgeleliğe bağlı değişebilir.

Açıklama ve öğretim notu

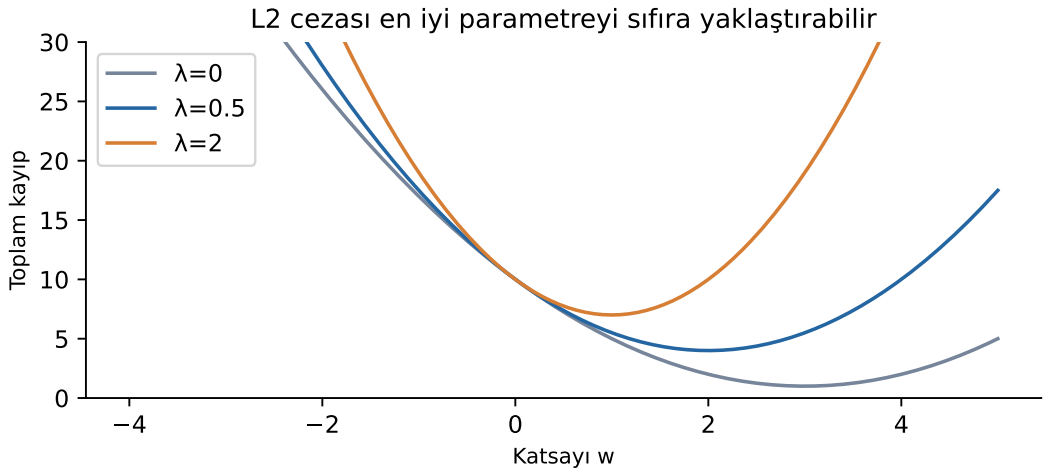
Veri sızıntısından kaçınma: Ayrı bir test kümesi varsa, model/hyperparametre seçimi sırasında test kümesine bakılmaz. Ön işleme (ölçekleme, eksik değer doldurma, özellik seçimi) çapraz doğrulamanın her eğitim katı içinde öğrenilir ve ilgili doğrulama katına uygulanır. Son model seçildikten sonra ayrılmış test kümesi yalnızca nihai değerlendirme içindir.

4.8.2 Düzenlileştirme (Regularization)

Türkçe aktarım. Bir başka yöntem, hataya model karmaşıklığını cezalandıran ikinci bir terim eklemektir:

$$E' = \text{Veri üzerindeki hata} + \lambda \cdot \text{Model karmaşıklığı}. \tag{4.37}$$

λ ceza teriminin ağırlığını belirler. Bu genişletilmiş hata fonksiyonunu en aza indirmek karmaşık modelleri caydırabilir, yüksek varyansı azaltabilir. λ çok büyük seçilirse fazla basit model ve yüksek bias riski doğar. λ da çapraz doğrulama ile ayarlanabilir.



Ek çizim: Basitleştirilmiş bir katsayının karesini cezalandırmak, optimizasyonun seçtiği katsa-

yıyı sıfıra yaklaştırabilir.

Adım adım örnek

A modeli için eğitim hata değeri 2 ve karmaşıklık cezası 30; B modeli için sırasıyla 5 ve 2 olsun. $\lambda = 0.1$ iken $E'_A = 2 + 0.1(30) = 5$, $E'_B = 5 + 0.1(2) = 5.2$ ve A seçilir. $\lambda = 1$ iken $E'_A = 32$, $E'_B = 7$; B seçilir. Ceza büyüdükçe tercihin değiştiği görülür.

4.8.3 AIC ve BIC

Türkçe aktarım. Genişletilmiş hata, yeni veri hatasının bir tahmini gibi de düşünülebilir: ilk terim eğitim hatası, ikinci terim eğitim ile test arasındaki iyimser farkı karşılayan düzeltmedir. *Akaike information criterion* (AIC) ve *Bayesian information criterion* (BIC), doğrulama bölmesi ayırmadan model uyumu ile karmaşıklığı dengeleyen kriterlerdir. Modelin serbest parametre sayısı, örneklem büyüklüğü ve hata gürültüsü düzeyi bu dengeyle ilişkilidir. k dereceli polinomda katsayı sayısı $d = k + 1$'dir; bazı doğrusal olmayan modellerde *etkin* parametre sayısı kullanılır.

Bu konuyu tamamlamak için standart bilgi kriteri biçimlerini yazalım (kaynak paragraf formülleri açmamıştır):

$$\boxed{AIC = 2d - 2\log \hat{L}}, \qquad \boxed{BIC = d\log N - 2\log \hat{L}}.$$

Burada $\hat{L}$ maksimum olabilirlik, d parametre sayısı, N gözlem sayısıdır. İki kriterde de küçük değer tercih edilir. N büyüdüğünde BIC'deki $d\log N$ toplam cezası, AIC'nin $2d$ cezasından büyük olabilir. Gözlem başına ölçüt ile toplam ölçütü birbirine karıştırmamak gerekir.

Adım adım örnek

$N = 100$ için A modelinin $d = 3$ ve $\log \hat{L} = -120$; B modelinin $d = 8$ ve $\log \hat{L} = -115$ olsun. $AIC_A = 6 + 240 = 246$; $AIC_B = 16 + 230 = 246$: eşit. $BIC_A = 3\log 100 + 240 \approx 253.82$; $BIC_B = 8\log 100 + 230 \approx 266.84$. BIC burada daha basit A'yı tercih eder.

4.8.4 Yapısal Risk Minimizasyonu (SRM)

Türkçe aktarım. *Structural risk minimization* (SRM), karmaşıklık açısından sıralanan bir model ailesi kullanır. Giderek yüksek dereceli polinomlar bunun örneğidir. Karmaşıklık çoğunlukla serbest parametre sayısıyla ölçülür; *VC dimension* da model kapasitesini inceleyen başka bir ölçüdür. Farklı, genellikle azalan λ_i ceza düzeyleriyle giderek daha esnek modeller elde edilebilir. SRM modelin ampirik hatasını ve karmaşıklıktan gelen genelleme riskini birlikte ele alır.

Açıklama ve öğretim notu

Örnek bir sıralama: 1., 2., 3., 4. dereceden polinomlar. Eğitim hataları $(15, 9, 5, 4)$, karmaşıklık cezaları $(1, 2, 3, 6)$ olsun. Toplam ölçütler $(16, 11, 8, 10)$'dur; 3. derece seçilir. Bu sayılar öğretici amaçlıdır, kaynak şeklinin ölçümleri değildir.

4.8.5 Minimum Açıklama Uzunluğu (MDL)

Türkçe aktarım. *Minimum description length* (MDL), bilgi kuramına dayalı bir ölçüttür. Bir veri kümesinin Kolmogorov karmaşıklığı, veriyi tanımlayan en kısa açıklamanın uzunluğudur. Çok sayıda sıfırdan oluşan bir diziyi "n adet sıfır" diye kısa tanımlayabiliriz; bütünüyle rastgele bir dizide verinin kendisinden çok daha kısa açıklama elde etmek genelde mümkün değildir. Modele iyi uyum varsa veri yerine modelin tanımını ve kalan hataları kodlayabiliriz. Dolayısıyla amaç hem iyi uyum hem kısa açıklama sunan modeli seçmektir.

$$\boxed{L(\text{model ve veri}) = L(\text{model}) + L(\text{veri} \mid \text{model})}.$$

Çok karmaşık modelin kendi kod uzunluğu büyük; çok basit modelin ise açıklayamadığı verinin kod uzunluğu büyük olabilir. MDL aradaki dengeyi arar.

4.8.6 Bayesçi model seçimi

Türkçe aktarım. Modellerin uygunluğu hakkında önsel bilgi varsa $p(\text{model})$ dağılımı tanımlanır. Bayes kuralı:

$$p(\text{model} \mid \text{data}) = \frac{p(\text{data} \mid \text{model})p(\text{model})}{p(\text{data})}. \tag{4.38}$$

Sonsal model olasılığı hem önsel inancı hem verinin sağladığı olabilirlik kanıtını içerir. En yüksek sonsala sahip model seçilebilir veya modeller tahminleri sonsal olasılıklarıyla ağırlıklandırılarak birleştirilebilir. Model seçiminin ayrıntıları Bölüm 16'dadır.

Adım adım örnek

İki modelin önselleri $P(M_1) = 0.7$, $P(M_2) = 0.3$, veri olabilirlikleri $p(D \mid M_1) = 0.4$, $p(D \mid M_2) = 0.6$ olsun. $p(D) = 0.4(0.7) + 0.6(0.3) = 0.46$; dolayısıyla $P(M_1 \mid D) = 0.28/0.46 \approx 0.609$, $P(M_2 \mid D) = 0.18/0.46 \approx 0.391$. Veri M_2 altında daha olası olsa da önsellerle birlikte M_1 tercih edilir.

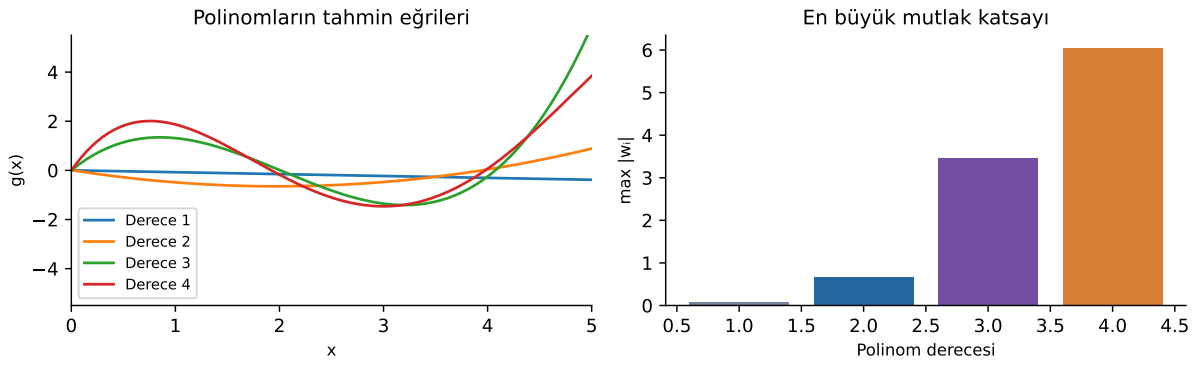
Bayes model seçim denkleminin logaritması:

$$\log p(\text{model} \mid \text{data}) = \log p(\text{data} \mid \text{model}) + \log p(\text{model}) - c. \tag{4.39}$$

$c = \log p(\text{data})$ normalleştirme terimidir. Negatif logaritmalarla düşündüğümüzde veri uyumsuzluğu ve önselden gelen parametre cezası, regularization benzeri bir biçim verir. Örneğin Gaussian ağırlık önseli $w_i \sim \mathcal{N}(0, 1/\lambda)$ altında, hata ve önselin ölçeklerini uygun seçerek:

$$\boxed{E = \sum_t [r^t - g(x_t \mid w)]^2 + \lambda \sum_i w_i^2.} \tag{4.40}$$

Böylece katsayılar hem veri hatasını düşürmeye çalışır hem sıfıra çok uzaklaşmamak için cezalandırılır. Büyük dereceli polinomlarda katsayı büyüklükleri ve salınımlar artabilir; ceza aşırı dalgalanmayı sınırlayabilir. Önsel varyans küçüldüğünde sıfıra yakın katsayıları daha güçlü bekliyoruz demektir. Kitap bu bağı 16. bölümde ayrıntılandırır.



Şekil 4.8'de verilen katsayı vektörleriyle üretilen yeniden çizim. Dereceler 1–4; her basamakta bazı katsayıların mutlak büyüklükleri artmaktadır.

Kaynakta verilen ağırlık vektörleri sırasıyla:

$$
\begin{aligned}
k=1: &\quad [-0.0769,\ 0.0016]^T,\\
k=2: &\quad [0.1682,\ -0.6657,\ 0.0080]^T,\\
k=3: &\quad [0.4238,\ -2.5778,\ 3.4675,\ -0.0002]^T,\\
k=4: &\quad [-0.1093,\ 1.4356,\ -5.5007,\ 6.0454,\ -0.0019]^T.
\end{aligned}
$$

Türkçe aktarım. Occam'ın usturası doğrultusunda basit modelleri ödüllendiren önseller seçilirse Bayes yaklaşımı, regularization, SRM ve MDL, karmaşıklık–uyum dengesi açısından birbirine yakın fikirler taşır. Ancak farklı ölçütleri *matematiksel olarak her koşulda tam eşdeğer* saymak doğru değildir. Cross-validation model/parametre hakkında belirli bir önsel dağılım varsaymaz ve yeterli doğrulama verisi olduğunda güçlü bir seçim aracıdır. Verinin az olduğu durumlarda düzenlileştirme veya bilgiye dayalı diğer yöntemler yardımcı olabilir.

Kısa karşılaştırma: CV yeni veri üzerindeki hatayı tekrar bölmelerle ölçer; düzenlileştirme eğitim hedefini değiştirir; AIC/BIC uyumla parametre sayısını dengeler; SRM karmaşıklığa göre sıralı sınıfları ele alır; MDL kısa açıklamayı ödüllendirir; Bayesçi seçim önseli ve model kanıtını birleştirir.

4.9 Notlar (Notes)

Türkçe aktarım. Kaynakta maksimum olabilirlik ve Bayes tahmini için Ross (1987); parametrik sınıflandırma için MacLachlan (1992), Devroye–Györfi–Lugosi (1996), Webb–Copsey (2011), Duda–Hart–Stork (2001); tek değişkenli normal dağılım testleri için Rencher (1995) önerilir. Geman–Bienenstock–Doursat (1992), öğrenme modellerinde bias/variance ayrıştırmasını tartışır.

Bu bölümdeki *hata* = *bias*^{2} + *variance* + *noise* ayrıştırması, regresyondaki kareli hata kaybı için doğrudandır. Sınıflandırmada $0/1$ kaybı aynı şekilde bölünmez: Hata sınıf kararının sınırı geçmesiyle oluşur. Örneğin gerçek $P(C_1 \mid x) = 0.7$ iken tahmin 0.8 ise Bayes sınıf kararı değişmez; 0.5 eşiğinin altına, örneğin 0.4'e düşerse karar değişir. Bu, olasılık tahmininin kusursuz olduğu anlamına gelmez; sadece 0/1 kararının aynı kaldığını söyler. Sınıflandırma için farklı bias/variance tanımları Friedman (1997)

tarafından incelenmiştir.

Açıklama ve öğretim notu

Regresyonda çıktı ile tahmin arasındaki büyüklük önemlidir: 100 yerine 101 ve 150 tahminleri farklı MSE üretir. Sınıflandırmanın $0/1$ kaybı ise öncelikle doğru sınıfa atanıp atanmadığına bakar. Kalibre olasılıkların kalitesini incelemek için gerektiğinde Brier score veya log loss gibi ek ölçütler kullanılabilir; bu son ölçütler kaynak paragrafını açıklamak için eklenmiştir.

4.10 Alıştırmalar (Exercises) – Türkçe Çeviri ve Çözümler

Bu kısımda orijinal bölümdeki 10 alıştırma, orijinalde sağlanan çözüm bilgileri ve ek öğretici çözümler birleştirilmiştir. Sorulardaki sayısal kod örnekleri, kitabın isteğini yerine getirmek için hazırlanmış özgün uygulamalardır.

Alıştırma 1. Bernoulli örneklemi üretme

Soru (çeviri): Verilen p parametresi ile Bernoulli örneklemi üreten bir kod ve örneklemden $\hat{p}$ hesaplayan kod yazınız.

Çözüm. Bir rastgele $u \sim U(0,1)$ üretiriz. $u < p$ ise $x = 1$, değilse $x = 0$ alırız. Ardından $\hat{p} = \sum x_t / N$ kullanılır. Aşağıdaki Python programı yalnızca standart kütüphaneyi gerektirir:

```
import random
random.seed(42)
p, N = 0.7, 100
X = [1 if random.random() < p else 0 for _ in range(N)]
p_hat = sum(X) / N
print('p =', p, 'estimated p =', p_hat)
```

N artırıldığında tahminin kararlılığı tipik olarak artar. Tek deneyde $\hat{p}$ mutlaka gerçek değere eşit değildir.

Alıştırma 2. Multinomial log-olabilirlik türetimi

Soru (çeviri): Multinomial örneklemin log-olabilirliğini yazınız ve (4.6)'yı gösteriniz.

Çözüm. n_i sınıf i sayısı ve $\sum_i n_i = N$ olsun. Parametrelere bağlı log-olabilirlik $L(p) = \sum_i n_i \log p_i$'dir (parametreye bağlı olmayan sayım katsayısı ihmal edilir). $\sum_i p_i = 1$ kısıtıyla:

$$\mathcal{L} = \sum_i n_i \log p_i + \alpha \left(\sum_i p_i - 1 \right).$$

$$\frac{\partial \mathcal{L}}{\partial p_i} = \frac{n_i}{p_i} + \alpha = 0 \quad \Rightarrow \quad p_i = -\frac{n_i}{\alpha}.$$

$$\sum_i p_i = 1 \Rightarrow -\frac{N}{\alpha} = 1 \Rightarrow \alpha = -N.$$

$$\boxed{\hat{p}_i = \frac{n_i}{N} = \frac{\sum_t x_i^t}{N}}.$$

Böylece (4.6) gösterilmiş olur.

Alıştırma 3. Gaussian örneklem ve Bayes tahmini

Soru (çeviri): Verilen μ ve σ ile normal örneklem üretiniz; örneklemden m ve s hesaplayınız. μ'ye önsel dağılım tanımlayarak Bayes tahmin edicisiyle de yapınız.
Çözüm. Gaussian örneklem gauss(μ, σ) ile üretilir. $m = \sum x/N$, $s = \sqrt{\sum (x-m)^2/N}$'dir. Önsel $\mu \sim \mathcal{N}(\mu_0, \sigma_0^2)$ ve bilinen gözlem varyansı σ^2 seçelim:

$$\hat{\mu}_{Bayes} = \frac{(N/\sigma^2)m + (1/\sigma_0^2)\mu_0}{N/\sigma^2 + 1/\sigma_0^2}.$$

```
import random, math
random.seed(42)
mu, sigma, N = 7, 2, 100
X = [random.gauss(mu, sigma) for _ in range(N)]
m = sum(X) / N
s = math.sqrt(sum((x - m)**2 for x in X) / N)
mu0, prior_var = 6, 1
bayes = ((N / sigma**2) * m + mu0 / prior_var) / \
        (N / sigma**2 + 1 / prior_var)
print('MLE mean:', m, 'MLE std:', s, 'Bayes mean:', bayes)
```

Bayes tahmini gözleme ve önsele ağırlık verir. N büyüdüğünde, diğer değerler sabitken önselin etkisi azalır.

Alıştırma 4. İki Gaussian sınıfının Bayes karar noktaları

Soru (çeviri): $p(x \mid C_1) = \mathcal{N}(\mu_1, \sigma_1^2)$, $p(x \mid C_2) = \mathcal{N}(\mu_2, \sigma_2^2)$ ve $P(C_1), P(C_2)$ verildiğinde Bayes ayırıcı noktaları analitik olarak hesaplayınız.
Çözüm. Karar sınırı $P(C_1 \mid x) = P(C_2 \mid x)$ ya da eşdeğer olarak $p(x \mid C_1)P(C_1) = p(x \mid C_2)P(C_2)$ ile bulunur. Gaussian ifadeleri yazıp logaritma alınır:

$$-\log \sigma_1 - \frac{(x-\mu_1)^2}{2\sigma_1^2} + \log P(C_1) = -\log \sigma_2 - \frac{(x-\mu_2)^2}{2\sigma_2^2} + \log P(C_2).$$

Terimleri açıp düzenleyince $ax^2 + bx + c = 0$ çıkar:

$$\begin{aligned} a &= \frac{1}{2\sigma_2^2} - \frac{1}{2\sigma_1^2}, \\ b &= \frac{\mu_1}{\sigma_1^2} - \frac{\mu_2}{\sigma_2^2}, \\ c &= \frac{\mu_2^2}{2\sigma_2^2} - \frac{\mu_1^2}{2\sigma_1^2} + \log \frac{\sigma_2}{\sigma_1} + \log \frac{P(C_1)}{P(C_2)}. \end{aligned}$$

$$\boxed{x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}} \qquad (a \neq 0).$$

Eşit varyansta $a = 0$ olur ve birinci dereceli denklem çözülür (dejenere durumlar hariç tek eşik). Farklı varyansta gerçek eşiklerin sayısı diskriminanta bağlıdır.

Adım adım örnek

$\mu_1 = \mu_2 = 0$, $\sigma_1 = 1$, $\sigma_2 = 2$, eşit önseller için $\log 2 - 3x^2/8 = 0$ olur. $x^2 = 8 \log 2/3$ ve $\boxed{x \approx \pm 1.36}$ bulunur. Merkezde C_1, iki yanda daha geniş dağılımlı C_2 seçilir.

Alıştırma 5. Gaussian olabilirlik oranı

Soru (çeviri): Gaussian sınıf-koşullu yoğunluklar için $p(x \mid C_1)/p(x \mid C_2)$ olabilirlik oranını bulunuz.

Çözüm. Gaussian yoğunluklarının oranı:

$$\frac{p(x \mid C_1)}{p(x \mid C_2)} = \frac{\sigma_2}{\sigma_1} \exp\left[-\frac{(x-\mu_1)^2}{2\sigma_1^2} + \frac{(x-\mu_2)^2}{2\sigma_2^2}\right].$$

Eşit varyans ($\sigma_1^2 = \sigma_2^2 = \sigma^2$) için $\sigma_2/\sigma_1 = 1$ olur. Kareler açılır:

$$\frac{p(x \mid C_1)}{p(x \mid C_2)} = \exp\left(\frac{\mu_1 - \mu_2}{\sigma^2} x + \frac{\mu_2^2 - \mu_1^2}{2\sigma^2}\right).$$

$$\boxed{\frac{p(x \mid C_1)}{p(x \mid C_2)} = \exp(wx + w_0)}, \quad w = \frac{\mu_1 - \mu_2}{\sigma^2}, \quad w_0 = \frac{\mu_2^2 - \mu_1^2}{2\sigma^2}.$$

Eşit varyansta *log-olabilirlik oranı* x'in doğrusal fonksiyonudur.

Alıştırma 6. Farklı varyanslarda sınıflandırma simülasyonu

Soru (çeviri): Farklı varyanslı iki sınıftan normal örneklemler üretiniz, parametrik sınıflandırmadan ayırıcı noktaları tahmin ediniz ve teorik değerlerle karşılaştırınız.

Çözüm. İlk sınıfı $\mathcal{N}(0,1)$, ikinciyi $\mathcal{N}(0,4)$, önselleri eşit alalım. Teorik eşikler önceki alıştırmadaki gibi ± 1.36'dır. Örneklemden $\hat{\mu}_i$, $\hat{\sigma}_i^2$ ve $\hat{P}(C_i)$ öğrenilip Alıştırma 4'teki a, b, c'ye yerleştirilir. Örnek Python uygulaması:

```
import random, math
random.seed(19)
a = [random.gauss(0, 1) for _ in range(500)]
b = [random.gauss(0, 2) for _ in range(500)]
def mean_var(xs):
    m = sum(xs) / len(xs)
    v = sum((x-m)**2 for x in xs) / len(xs)
    return m, v
m1, v1 = mean_var(a)
m2, v2 = mean_var(b)
A = 1/(2*v2) - 1/(2*v1)
B = m1/v1 - m2/v2
C = m2*m2/(2*v2) - m1*m1/(2*v1) + \
    math.log(math.sqrt(v2)/math.sqrt(v1))
disc = B*B - 4*A*C
roots = [(-B - math.sqrt(disc))/(2*A),
         (-B + math.sqrt(disc))/(2*A)] if disc > = 0 else []
print('Estimated cutoffs:', roots)
```

Burada eşit sayıda sınıf örneği üretildiğinden önsel oranının logaritması sıfırdır. Teorik değerlerle aradaki fark örneklem rastgeleliğinden kaynaklanır.

Alıştırma 7. Doğrusal ve polinom regresyonu karşılaştırma

Soru (çeviri): Doğrusal bir modele sıfır ortalamalı Gaussian gürültü ekleyip örneklem üretiniz. Yarısını eğitim, yarısını doğrulama için ayırınız. Doğrusal regresyonu öğrenip doğrulama hatasını bulunuz; 2. ve 3. derece polinomlarla tekrarlayınız.
Çözüm. Gerçek fonksiyon $f(x) = 2x + 1$, gürültü $\varepsilon \sim \mathcal{N}(0, 0.25)$ seçilebilir. Eğitim bölümünde dereceler $1, 2, 3$ için polinom fit edilir, doğrulama hatası $MSE = \sum(r - \hat{r})^2 / N_{val}$ hesaplanır. Kod:

```
import numpy as np
rng = np.random.default_rng(42)
x = rng.uniform(-2, 2, 100)
y = 2*x + 1 + rng.normal(0, 0.5, 100)
ids = rng.permutation(100)
tr, va = ids[:50], ids[50:]
for degree in (1, 2, 3):
    w = np.polyfit(x[tr], y[tr], degree)
    pred = np.polyval(w, x[va])
    mse = np.mean((y[va] - pred)**2)
    print(degree, mse)
```

Gerçek fonksiyon 1. derece olduğundan yüksek dereceler temsil açısından gerekli değildir. Hangisinin doğrulamada iyi çıktığı örneklem ve gürültüye bağlıdır.

Alıştırma 8. Az veri varsa neden basit model seçilir?

Soru (çeviri): Küçük örneklemde varyans, bias'tan daha baskın olabilir. Fazla basit olduğunu bildiğimiz modelin daha iyi olduğu bir örnek veriniz.
Çözüm. Gerçek $f(x) = x^2$ olsa bile yalnızca beş gürültülü nokta varsa 4. derece polinom bu noktaları tam karşılayıp gürültüyü de ezberleyebilir. 1. derece doğru sistematik hata (bias) taşır fakat veri değiştiğinde çok daha kararlı olabilir. Böyle bir örneklemde doğrulama/genelleme hatası daha basit modelde küçük çıkabilir. Daha fazla veri olursa doğru karmaşıklıktaki 2. derece model tercih edilebilir.

Alıştırma 9. Sabit, ilk örnek, ortalama ve minimum tahmini

Soru (çeviri): Her x için $g_i(x) = r_i^1$ yani sırasız örneklemdeki ilk çıktıyı tahmin olarak kullanalım. Bunun bias/varyansını sabit $g_i(x) = 2$ ve örneklem ortalaması $g_i(x) = \sum_t r_{ti}/N$ ile karşılaştırınız. Veri sıralıysa $g_i(x) = \min_t r_{ti}$ için ne söylenir?
Çözüm. Sabit 2 hiçbir veri noktasına bağlı olmadığından varyansı sıfır, gerçek fonksiyon 2'den uzaksa bias'ı büyüktür. İlk gözlem tahmini bir rastgele çıktının varyansını taşır; yalnızca bir gözleme dayandığı için dalgalanmaya açıktır. Örneklem ortalaması, iid ve sonlu varyans varsayımında çıktı varyansını $1/N$ oranında küçültür:

$$\mathrm{Var}(\bar{r}) = \frac{\mathrm{Var}(r)}{N}.$$

İlk gözlem ve ortalama tahmin edicileri sabit x için aynı *beklenen* çıktı ortalamasını hedefler; gerçek regresyon fonksiyonu x ile değişiyorsa ikisinin de bias'ı olabilir.

Minimum değer tahmin edicisi $\min r_t$ ise çoğunlukla aşağı yönlü sapma üretir; tam bias/varyansı dağılıma, gözlem sayısına ve sıralama tanımına bağlıdır.

Alıştırma 10. λ'nın bias ve varyansa etkisi

Soru (çeviri): Denklem (4.40)'da λ değiştirilirse bias ve varyans nasıl etkilenir?
Çözüm. Kaynak çözümüne göre λ düzgünlüğü kontrol eder: büyük λ güçlü düzleştirme/regularization getirerek varyansı azaltabilir ama bias'ı artırabilir. Küçük λ esnekliğe izin vererek bias'ı azaltabilir ama varyans yüksek kalabilir. Bu ilişki tipik eğilimdir, her veri/model için mutlak bir garanti değildir. λ çapraz doğrulamayla seçilmelidir.

Ünite 4 – Hızlı Tekrar ve Ders Kontrol Listesi

Konu	Hatırlanacak ifade
Parametrik yöntem	Dağılım ailesini seç, az sayıda parametresini öğren.
MLE	$\hat{\theta} = \arg\max_\theta p(X \mid \theta)$; çarpımı log ile toplama dönüştür.
Bernoulli	$\hat{p} = \sum x_t / N$, $E[X] = p$, $\text{Var}(X) = p(1-p)$.
Multinomial	$\hat{p}_i = n_i / N$; kategori olasılıkları toplamı 1.
Gaussian MLE	$m = \sum x_t / N$, $s^2 = \sum (x_t - m)^2 / N$.
Yansız varyans	$\sum (x_t - m)^2 / (N-1)$; MLE ile aynı değildir.
Bias/variance	$\text{MSE} = \text{Var}(d) + \text{Bias}(d)^2$ (parametre tahmininde).
Bayes tahmini	Önsel $\times$ olabilirlik $\propto$ sonsal; MAP tepe, Bayes tahmini sonsal ortalama.
Parametrik sınıflandırma	$P(C_i \mid x) \propto p(x \mid C_i) P(C_i)$; sınıf dağılımlarının parametrelerini öğren.
En küçük kareler	Gaussian sabit varyanslı gürültü varsayımında MLE, SSE minimizasyonuna dönüşür.
Regresyon doğruluğu	$RSE = SSE/SST$ ve $R^2 = 1 - RSE$.
Genelleme	$\text{MSE}(x) = \text{Bias}^2(x) + \text{Var}(x) + \text{Noise}(x)$ (regresyon).
Model seçimi	CV, regularization, AIC/BIC, SRM, MDL, Bayesçi seçim.

Öğrenci projesine önerilen sıra: (1) Problem ve veri kümesi, (2) eğitim/doğrulama/test ayrımı, (3) eğitim verisi içinde ön işleme, (4) birden fazla aday model, (5) uygun metrik ve K-fold çapraz doğrulama, (6) hiperparametre/karmaşıklık seçimi, (7) seçilen modelin son test ölçümü, (8) bulguların ve sınırlamaların raporlanması. Bu sıra, bölümün *genelleme hatasını azaltan modeli seçme* fikrinin pratik uygulamasıdır.

Kaynak ve atıf: Alpaydın, E. (2014). *Introduction to Machine Learning*. MIT Press. Bölüm 4: “Parametric Methods”, s. 65–90. İçerik kullanıcı tarafından sağlanan üç metin dosyasının Türkçe aktarımı ve ders anlatımı amacıyla hazırlanan ek açıklamalardan oluşur. Grafikler özgün olarak yeniden çizilmiştir.

Not: Kaynak alıştırma bölümünde açıklama veya çözüm sunulmayan maddeler için burada ek çözüm üretilmiştir. İlave sayısal örnekler kitaptan doğrudan alıntı değildir.