MAKİNE ÖĞRENMESİ · KAPSAMLI DERS SUNUMU

5. ÜNİTE
Çok Değişkenli Yöntemler



5.1–5.8 • Temel kavramlar • Şekiller • Çözümlü örnekler

Kaynak: Ethem Alpaydın (2014), Introduction to Machine Learning, Bölüm 5

Bu ünitede neler öğreneceğiz?

Hedef: Birden fazla özelliği aynı modelde kullanabilmek.

İstatistiksel temel

Veri matrisi • ortalama vektörü • varyans • kovaryans • korelasyon • eksik veriler

Olasılık ve sınıflandırma

Çok değişkenli normal dağılım • Mahalanobis uzaklığı • QDA • LDA • Naive Bayes • RDA

Sayısal tahmin

Çoklu doğrusal regresyon • hata fonksiyonu • normal denklemler • polinom ve taban fonksiyonları

ANA FİKİR Öğrenme sırası: Veriyi tanı → dağılımı modelle → sınıflandır / tahmin et.

Ders boyunca kullanacağımız semboller

Sembol	Anlamı	Örnek
N	Gözlem sayısı	N = 4 öğrenci
d	Özellik sayısı	d = 3 özellik
K	Sınıf sayısı	K = 2 sınıf
μ, m	Gerçek / örneklem ortalama vektörü	m = (2, 70)
Σ, S	Gerçek / örneklem kovaryans matrisi	2 × 2 matris
C_i, $P(C_i)$	Sınıf ve önsel olasılık	P(Spam) = 0,4
$g_i(x)$	Sınıf puanı / ayırt edici fonksiyon	En büyük puanı seç

Not: Üst simge ^{T}, matrisin transpozu anlamına gelir.

5.1

Çok Değişkenli Veri

Bir satır gözlem, her sütun bir özellik.

Tek değişkenli ve çok değişkenli model

Tek değişkenli

Sınav notunu sadece çalışma saatinden tahmin edelim.

$y = f(x_1)$

x_1: Haftalık çalışma süresi

Çok değişkenli

Sınav notunu çalışma süresi, devam ve ödev ortalamasından tahmin edelim.

$y = f(x_1, x_2, x_3)$

x_2: Devam oranı x_3: Ödev notu

Birden fazla özellik, daha zengin bilgi sağlayabilir.

Örnek veri kümesi: dört öğrenci

Öğrenci	Çalışma saati x_1	Devam (%) x_2	Önceki not x_3
1	2	60	50
2	4	75	65
3	6	90	80
4	8	95	90

N = 4 satır (gözlem) ve d = 3 sütun (özellik).

Veri matrisi X nasıl okunur?

$$X = [(2,60,50); (4,75,65); (6,90,80); (8,95,90)]$$

X, 4 × 3 boyutlu bir veri matrisidir.

- 1. satır = 1. öğrencinin üç özelliği
- 2. sütun = bütün öğrencilerin devam oranı: (60,75,90,95)
- Gözlem vektörü $x^{(1)} = (2,60,50)^T$

Sınıflandırma mı, regresyon mu?

Sınıflandırma (Classification)

Çıktı, kategorik bir sınıftır.

Örnek: Geçti / Kaldı

$y \in \{\text{Başarılı, Başarısız}\}$

Regresyon (Regression)

Çıktı, sürekli sayısal bir değerdir.

Örnek: Sınav notu = 82,5

$y \in \mathbb{R}$

Aynı giriş özellikleri farklı öğrenme problemlerinde kullanılabilir.

Sayısal, kategorik ve ölçek farkları

Bir özelliğin türünü tanımak, doğru ön işleme için gereklidir.

Sayısal özellik

Yaş: 23 yıl. Gelir: 80.000 TL. Ölçekleri farklıdır; karşılaştırmadan önce standartlaştırma gerekebilir.

Kategorik özellik

Medeni durum: Bekâr / Evli. Sayısal büyüklük olarak değil, kategori olarak ele alınır.

Önemli varsayım

Gözlemlerin bağımsız olması, aynı gözlem içindeki özelliklerin birbirinden bağımsız olduğu anlamına GELMEZ.

ANA FİKİR Özellik vektörü x = (x_1, x_2, ..., x_d).

5.2

Parametre Tahmini

Veriyi ortalama, varyans, kovaryans ve korelasyonla özetleme.

Ortalama vektörü (Mean Vector)

$$\mu = E[x] = (\mu_1, \mu_2, \ldots, \mu_d)^T$$

Her özellik sütununun ortalamasını ayrı ayrı alırız.

- μ_1: birinci özelliğin ortalaması
- μ_2: ikinci özelliğin ortalaması
- d boyutta d elemanlı bir ortalama vektörü bulunur.

Ortalama vektörü: öğrenciler

Çalışma saati: 1, 2, 3 | Not: 50, 70, 90

1

Çalışma ortalaması = (1 + 2 + 3) / 3 = 2

2

Not ortalaması = (50 + 70 + 90) / 3 = 70

3

Ortalama vektörü $m = (2,70)^T$

Ortalama vektörü, iki boyutlu dağılımın merkezini gösterir.

Varyans ve kovaryans

Varyans: tek değişken

$\mathrm{Var}(X) = E[(X - \mu)^2]$

Bir özelliğin kendi ortalamasından ne kadar uzaklaştığını ölçer.

Örnek: (69,70,71) ile (30,70,110) aynı ortalamaya ama farklı varyansa sahiptir.

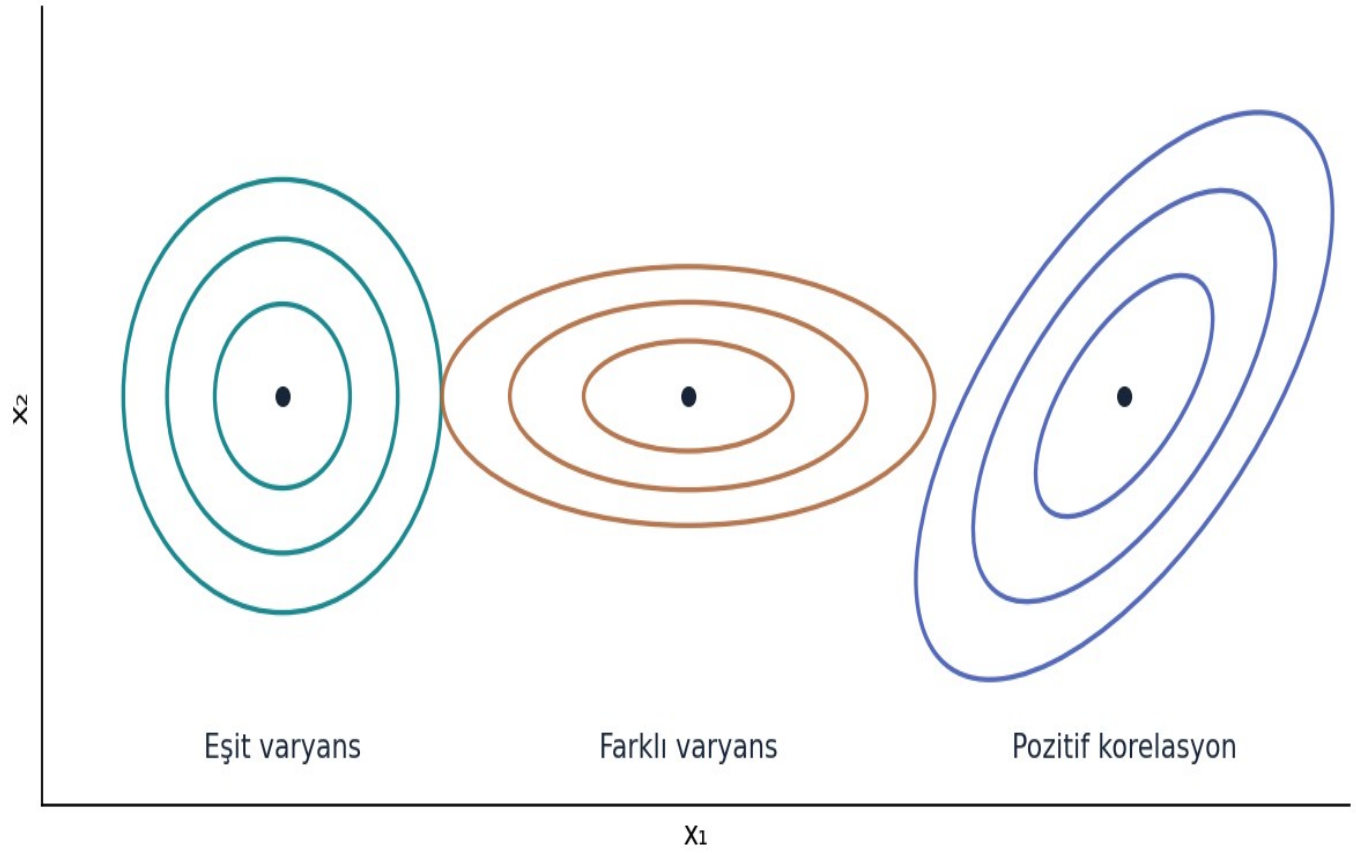
Kovaryans: iki değişken

$\mathrm{Cov}(X,Y) = E[(X - \mu_x)(Y - \mu_y)]$

Pozitif: Birlikte artma eğilimi
Negatif: Ters yönlü değişim
Sıfır: Doğrusal birlikte değişim yok

Cov(X,Y) = Cov(Y,X); Cov(X,X) = Var(X).

Ek grafik: kovaryans neyi değiştirir?



Grafik nasıl okunur?

1. Dairesel kontur: varyanslar eşit, kovaryans 0.
2. Yatay / dikey elips: varyanslar farklı.
3. Eğik elips: iki özellik arasında korelasyon var.

Dağılımın uzanma yönünü kovaryans, yayılımını varyans belirler.

KAYNAK ŞEKLİN YORUMU

Kovaryans matrisi Σ

$$\Sigma = [[\mathrm{Var}(X_1), \mathrm{Cov}(X_1,X_2)]; [\mathrm{Cov}(X_2,X_1), \mathrm{Var}(X_2)]]$$

Köşegende varyans, diğer hücrelerde kovaryans bulunur.

- Örnek: Σ = [[4,3],[3,9]]
- $\mathrm{Var}(X_1) = 4$, $\mathrm{Var}(X_2) = 9$, $\mathrm{Cov}(X_1,X_2) = 3$
- Matris simetriktir; üst sağ ve alt sol elemanlar eşittir.

Korelasyon: ölçü biriminden bağımsız ilişki

$$\rho_{ij} = \mathrm{Cov}(X_i, X_j) / (\sigma_i \sigma_j)$$

Korelasyon −1 ile +1 arasındadır.

- ρ = +1: mükemmel pozitif doğrusal ilişki
- ρ = −1: mükemmel negatif doğrusal ilişki
- ρ = 0: doğrusal ilişki yok; bağımsızlık her zaman çıkmaz.

Korelasyon: tek hesapta üç kavram

$Var(X_1) = 4$, $Var(X_2) = 9$, $Cov(X_1,X_2) = 3$

1

Standart sapma $\sigma_1 = \sqrt{4} = 2$

2

Standart sapma $\sigma_2 = \sqrt{9} = 3$

3

Korelasyon $\rho = 3 / (2 \times 3) = 0{,}5$

Sonuç: Orta büyüklükte pozitif doğrusal ilişki.

Örneklemde parametre tahmini

$$m_i = \Sigma_t x_i^{(t)} / N$$

Ortalama ve kovaryans gözlemlerden hesaplanır.

- Varyans: $s_i^2 = \Sigma_t (x_i^{(t)} - m_i)^2 / N$
- Kovaryans: $s_{ij} = \Sigma_t (x_i^{(t)} - m_i)(x_j^{(t)} - m_j) / N$
- Bu formüller ML tahminidir; klasik yanlı olmayan örneklem varyansında $N-1$ vardır.

Kovaryans örneği: başlangıç verileri

Gözlem	X_1	X_2	$X_1 - m_1$	$X_2 - m_2$
1	1	2	−1	−1
2	2	4	0	1
3	3	3	1	0

Önce ortalamalar: $m_1 = (1+2+3)/3 = 2$, $m_2 = (2+4+3)/3 = 3$.

Kovaryans örneği: varyanslar

Merkezlenmiş veriler: (−1,−1), (0,1), (1,0)

1

$$s_1^2 = [\,(-1)^2 + 0^2 + 1^2\,] / 3$$

2

$$s_1^2 = (1 + 0 + 1) / 3 = 2/3$$

3

$$s_2^2 = [\,(-1)^2 + 1^2 + 0^2\,] / 3 = 2/3$$

Her iki sütunun tahmini varyansı 2/3.

Kovaryans örneği: kovaryans

Önce her gözlemdeki iki sapmayı çarpalım.

1. Gözlem 1: $(-1) \times (-1) = 1$
2. Gözlem 2: $0 \times 1 = 0$
3. Gözlem 3: $1 \times 0 = 0$
4. $s_{12} = (1 + 0 + 0) / 3 = 1/3$

Kovaryans pozitiftir.

Kovaryans örneği: matris ve korelasyon

Artık $s_1^2 = s_2^2 = 2/3$ ve $s_{12} = 1/3$ biliyoruz.

1 $S = [[2/3, 1/3], [1/3, 2/3]]$

2 $s_1 = \sqrt{(2/3)}, s_2 = \sqrt{(2/3)}$

3 $r_{12} = (1/3) / [\sqrt{(2/3)} \times \sqrt{(2/3)}]$

4 $r_{12} = (1/3) / (2/3) = 0{,}5$

Pozitif korelasyon var; N−1 kullanılsa da korelasyon değişmez.

Kısa kontrol: kovaryans matrisi

SORU

$\Sigma = [[9, -3], [-3, 4]]$ ise standart sapmalar ve korelasyon nedir?

ÇÖZÜM / CEVAP

$\sigma_1 = 3$, $\sigma_2 = 2$; $\rho = -3/(3\times2) = -0{,}5$.

5.3

Eksik Değerlerin Tahmini

Eksik veriyi silmek yerine, hangi bilgilerle tamamlayabiliriz?

Eksik veri (Missing Value) nedir?

Bir gözlem var ama özelliklerden birinin değeri bilinmiyor.

Kayıt silme

Eksik değer içeren gözlemi tamamen çıkarırız. Az verili çalışmalarda ciddi bilgi kaybı oluşabilir.

Imputation

Eksik değeri ortalama, mod veya tahmin modeliyle doldururuz.

Eksiklik göstergesi

Değerin eksik olması da anlam taşıyabilir. İkinci bir özellik (eksik = 1 / var = 0) eklenebilir.

ANA FİKİR Yöntem seçimi, verinin türüne ve neden eksik olduğuna bağlıdır.

Eksik değer örneği: önce ve sonra

Öğrenci	Yaş	Orijinal not	Ortalamayla doldurma
A	20	70	70
B	22	80	80
C	24	Eksik	80
D	26	90	90

Görülen notların ortalaması = (70 + 80 + 90)/3 = 80.

Eksik notu regresyonla doldurma

Çalışma saati x = 6; öğrenilmiş regresyon: y = 10x + 30

1. Bilinen özelliği bul: x = 6 saat

2. Regresyon formülünde yerine koy: 10 × 6 + 30

3. Tahmin edilen not: 60 + 30 = 90

4. Ortalama yöntemi: (50 + 70 + 110)/3 ≈ 76,67

Regresyon, diğer sütunların verdiği bilgiyi kullanır.

Eksiklik bilgi taşır mı?

Eksik ≠ sıfır

Gelir açıklanmaması ile gelirin 0 TL olması aynı şey değildir.

İki sütun kullanılabilir:

GelirTahmini = ...
GelirEksik = 1 / 0

Veri sızıntısı (Data Leakage)

Ortalama, mod veya imputasyon modeli SADECE eğitim seti üzerinde öğrenilir.

Validation ve test verilerinde eğitim setinde öğrenilen dönüşüm uygulanır.

Test kümesinin ortalamasını kullanmak, performans ölçümüne geleceğe ait bilgi karıştırır.

Kontrol: eksik değer stratejisi

SORU

Veri kümesindeki “Şehir” değişkeni kategorik; “Gelir” sayısaldır. Basit doldurma seçenekleri nelerdir?

ÇÖZÜM / CEVAP

Şehir → en sık görülen kategori (mod); Gelir → eğitim kümesi ortalaması veya tahmin modeli.

5.4

Çok Değişkenli Normal Dağılım

Dağılımın merkezini μ, şeklini ve yönünü Σ belirler.

Şekil 5.1 — İki değişkenli normal dağılım

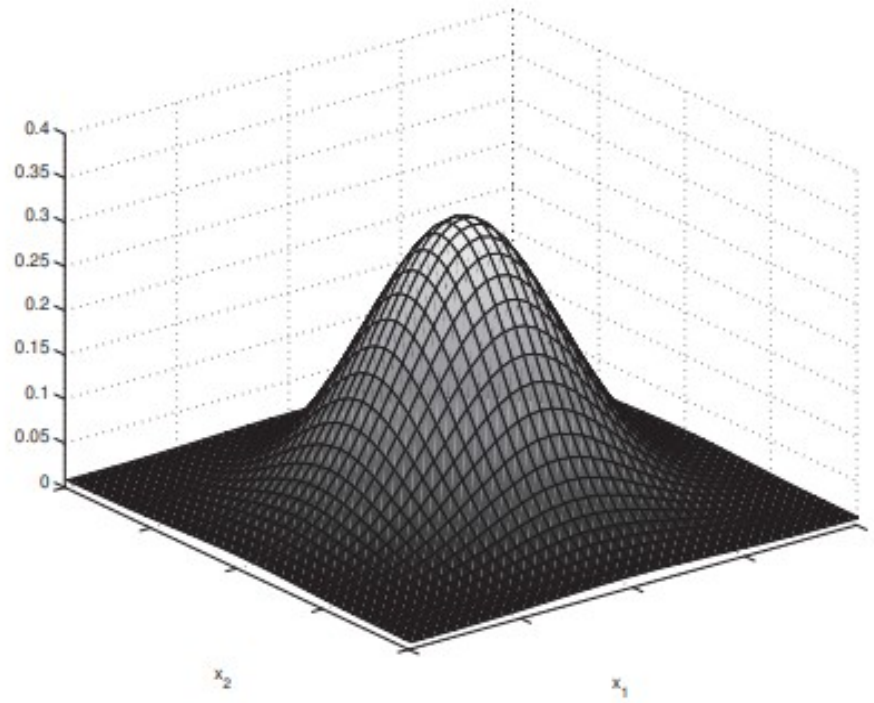


Figure 5.1 Bivariate normal distribution.

Grafik nasıl okunur?

1. Yatay eksenler: x_1 ve x_2 özellikleri.
2. Dikey eksen: $p(x_1, x_2)$, olasılık yoğunluğu.
3. En yüksek nokta merkez çevresindedir; tek nokta olasılığı değildir.

Tepe, yüksek olasılık yoğunluğunu; yayılım, kovaryans yapısını gösterir.

Çok değişkenli Gaussian yoğunluğu

$$p(x) = \exp[-\tfrac{1}{2}(x-\mu)^{T}\Sigma^{-1}(x-\mu)] \,/\, [(2\pi)^{d/2}\ |\Sigma|^{1/2}]$$

$x \sim N_d(\mu, \Sigma)$ ile gösterilir.

- μ: dağılımın merkezi (ortalama vektörü)
- Σ: dağılımın şekli, ölçeği ve yönelimi
- Σ^{-1}: kovaryans matrisinin tersi; $|\Sigma|$: determinant

Formüldeki iki ana bileşen

Ölçek / normalleştirme

$1 / [(2\pi)^{(d/2)} \sqrt{|\Sigma|}]$

Yoğunluk fonksiyonunun tüm uzaydaki integralinin 1 olmasını sağlar.

Dağılımın ne kadar yaygın olduğunu etkiler.

Uzaklık / üstel bölüm

$\exp[-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)]$

Bir noktanın merkeze kovaryans yapısı açısından uzaklığını içerir.

Uzak noktaların yoğunluğu düşer.

Dağılımın merkezden uzaklaştıkça azaldığını düşün.

Mahalanobis uzaklığı

$$D_M^2(x, \mu) = (x-\mu)^T \Sigma^{-1} (x-\mu)$$

Varyans ve kovaryansı hesaba katan uzaklık.

- Öklid: $D_E = \sqrt{\Sigma_i (x_i - \mu_i)^2}$
- Mahalanobis: $D_M = \sqrt{[(x-\mu)^T \Sigma^{-1} (x-\mu)]}$
- Büyük varyanslı yöndeki aynı ham sapma daha az sıra dışı olabilir.

Mahalanobis: örnek başlangıcı

$\mu = (0,0)^T$; $\Sigma = \mathrm{diag}(1,9)$; $x = (1,3)^T$

1

Öklid: $D_E = \sqrt{(1^2 + 3^2)} = \sqrt{10} \approx 3{,}16$

2

Kovaryansın tersi: $\Sigma^{-1} = \mathrm{diag}(1, 1/9)$

3

Önce merkez farkı: $x - \mu = (1,3)^T$

Her yöndeki standart sapma farklıdır: $\sigma_1 = 1$, $\sigma_2 = 3$.

Mahalanobis: matris çarpımı

$$(x-\mu)^T\Sigma^{-1}(x-\mu) = [1,3]\ \mathrm{diag}(1,1/9)\ [1,3]^T$$

1. Sol çarpım: $[1,3] \times \mathrm{diag}(1,1/9) = [1,1/3]$

2. Son çarpım: $[1,1/3] \times [1,3]^T$

3. $D_M^2 = (1 \times 1) + ((1/3) \times 3) = 2$

4. $D_M = \sqrt{2} \approx 1,41$

D_E = 3,16 ve D_M = 1,41 farklı ölçeklerin uzaklık ölçüleridir.

Şekil 5.2 — Eş yoğunluk konturları

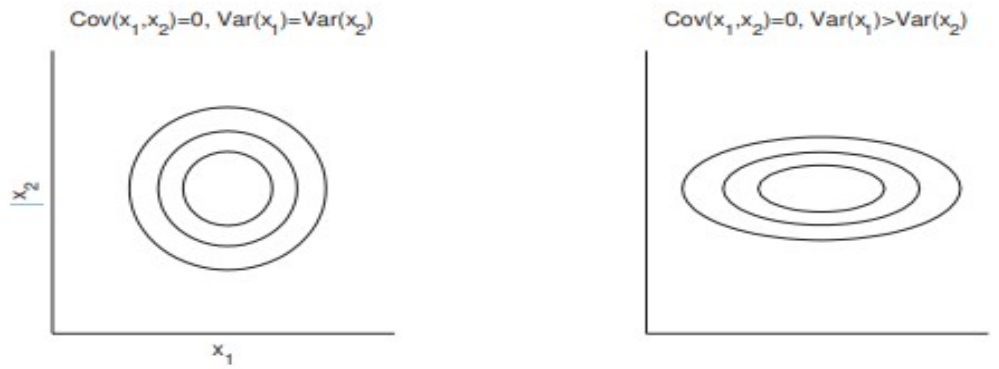


Figure 5.2 Isoprobability contour plot of the bivariate normal distribution. Its center is given by the mean, and its shape and orientation depend on the covariance matrix.

Grafik nasıl okunur?

1. Sol üst: Cov = 0, $Var_1 = Var_2$ → daire.
2. Sağ üst: Cov = 0, $Var_1 > Var_2$ → yatay elips.
3. Alt: pozitif Cov → yükselen; negatif Cov → alçalan eğim.

Daire / elipsin biçimi varyansa, eğimi kovaryansa bağlıdır.

İki değişkenin kovaryans matrisi

$$\Sigma = [[\sigma_1^2, \rho\sigma_1\sigma_2], [\rho\sigma_1\sigma_2, \sigma_2^2]]$$

Beş parametre: μ_1, μ_2, σ_1^2, σ_2^2, ρ.

- $\rho > 0$: pozitif eğimli elips
- $\rho < 0$: negatif eğimli elips
- $\rho = 0$: Gaussian durumda bağımsız bileşenler

Z-normalizasyonu ve elips denklemi

$$z_i = (x_i - \mu_i)/\sigma_i$$

Standartlaştırılmış birimlerle karşılaştırma yaparız.

- Örnek 1: (80−70)/10 = 1
- Örnek 2: (180−160)/20 = 1
- Eş yoğunluk: $z_1^2 - 2\rho z_1 z_2 + z_2^2 = \text{sabit}$

İki değişkenli normal yoğunluk

$$p(x_1,x_2) = \exp[-(z_1^2-2\rho z_1 z_2+z_2^2)/(2(1-\rho^2))] \,/\, [2\pi\sigma_1\sigma_2\sqrt{(1-\rho^2)}]$$

İki değişkeni birlikte ele alan yoğunluk.

- Çapraz terim $-2\rho z_1 z_2$ korelasyonu dikkate alır.
- $-1 < \rho < 1$ ise terslenebilir, normal bir kovaryans matrisi vardır.
- Kaynakta bir satırda + işareti görülse de doğru elips ifadesinde − kullanılır.

Determinant: tekil matris nasıl tanınır?

İki boyutlu matris: det([[a,b],[c,d]]) = ad − bc

1

$\Sigma_1 = [[4,2],[2,4]] \rightarrow |\Sigma_1| = 16 - 4 = 12$

2

$\Sigma_2 = [[4,8],[8,16]] \rightarrow |\Sigma_2| = 64 - 64 = 0$

3

$|\Sigma_2| = 0$ olduğu için Σ_2 tekildir; sıradan ters matrisi yoktur.

Tam doğrusal bağımlılık veya sıfır varyans, tekilliğe yol açabilir.

Normal dağılımın önemli özellikleri

Bağımsız bileşenler

Eğer Σ köşegense ve x çok değişkenli normalse, özellikler bağımsızdır.

$p(x) = \prod p_i(x_i)$

Ortak yoğunluk, tek değişkenli yoğunlukların çarpımıdır.

Alt dağılımlar

$x \sim N_d(\mu,\Sigma)$ ise her bir bileşen tek değişkenli normaldir.

Her k boyutlu alt küme k değişkenli normaldir.

Tersi her zaman doğru değildir.

“Her bileşen normal” demek “ortak dağılım çok değişkenli normal” demek değildir.

Doğrusal izdüşüm de normaldir

$$w^T x \sim N(w^T \mu, w^T \Sigma w)$$

d boyutlu normal dağılımı tek boyuta yansıtabiliriz.

- Ortalama: $E[w^T x] = w^T \mu$
- Varyans: $Var(w^T x) = w^T \Sigma w$
- Genel k boyutlu dönüşüm: $W^T x \sim N_k(W^T \mu, W^T \Sigma W)$

İzdüşüm örneği: yeni ortalama

$\mu = (2,3)^T$; $\Sigma = [[1,0.5],[0.5,1]]$; $w = (1,1)^T$

1

Yeni değişken: $Y = w^T x = X_1 + X_2$

2

Ortalama: $E[Y] = w^T \mu = [1,1]\ [2,3]^T$

3

$E[Y] = 1 \times 2 + 1 \times 3 = 5$

Yeni tek boyutlu normal dağılımın ortalaması 5.

İzdüşüm örneği: yeni varyans

$\Sigma = [[1,0.5],[0.5,1]]$ ve $w = (1,1)^T$

1. $\Sigma w = [[1,0.5],[0.5,1]]\ [1,1]^T = [1.5,1.5]^T$
2. $w^T \Sigma w = [1,1]\ [1.5,1.5]^T$
3. $\mathrm{Var}(Y) = 1.5 + 1.5 = 3$
4. Sonuç: $Y \sim N(5,3)$

Bu örnek, boyut azaltmanın matematiksel temelini gösterir.

Kontrol: korelasyon ve dağılım

SORU

ρ = +1 ise determinant ne olur? ρ = 0 ise Gaussian durumda bileşenler için ne söylenir?

ÇÖZÜM / CEVAP

ρ = ±1 → det(Σ)=0 (tekil). ρ=0 → iki değişkenli Gaussian durumda bağımsızlık.

5.5

Çok Değişkenli Sınıflandırma

Dağılımları sınıflara göre modelle, Bayes puanlarını karşılaştır.

Araç alımından sınıflandırma örneği

Özellikler

$x = (\text{Yaş, Gelir})^T$

C_1: Ekonomik otomobil
C_2: Lüks otomobil

Bir müşteri bir vektördür.

Sınıf parametreleri

$\mu_1 = (25,30000)^T$
$\mu_2 = (45,90000)^T$

Σ_i: i. grupta yaş/gelir varyansı ve aralarındaki kovaryans.

Soru: Yeni müşteri hangi sınıfa ait olma bakımından daha olası?

Sınıfa koşullu Gaussian yoğunluk

$$p(x|C_i) = \exp[-\tfrac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i)] / [(2\pi)^{d/2}\sqrt{|\Sigma_i|}]$$

Her sınıfın ortalama ve kovaryansını ayrı modelleyebiliriz.

- $P(C_i)$: sınıfın önsel olasılığı
- $p(x|C_i)$: o sınıfa özgü veri yoğunluğu
- $P(C_i|x)$: gözlemin sınıfa ait sonsal olasılığı

Bayes ayırt edici fonksiyonu

$$g_i(x) = \log p(x|C_i) + \log P(C_i)$$

En yüksek $g_i(x)$ değerini veren sınıf seçilir.

- Bayes: $P(C_i|x) = p(x|C_i)P(C_i)/p(x)$
- $p(x)$ bütün sınıflarda ortaktır; sınıf kıyaslamasından çıkar.
- Logaritma çarpımları toplam hâline getirir.

Gaussian ayırt edici fonksiyon

$$g_i = -\tfrac{1}{2}\log|\Sigma_i| - \tfrac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) + \log P(C_i)$$

Tüm sınıflara ortak olan $-(d/2)\log(2\pi)$ çıkarıldı.

- Determinant: sınıfın yoğunluk ölçeği
- Mahalanobis terimi: merkeze göre uzaklık
- Önsel: sınıfın baştan ne kadar olası olduğu

Sınıfa özgü parametreleri öğrenme

$$\hat{P}(C_i)=n_i/N \; ; \; m_i=(\Sigma_t \, r_i^{(t)} x^{(t)})/n_i$$

$r_i^{(t)} = 1$ ise gözlem i. sınıfa aittir.

- $n_i = \Sigma_t \, r_i^{(t)}$, sınıftaki örnek sayısıdır.
- $S_i = (1/n_i) \, \Sigma_t \, r_i^{(t)} (x^{(t)} - m_i)(x^{(t)} - m_i)^T$
- Her sınıf için ortalama ve kovaryans ayrı tahmin edilir.

Araba müşterisi: eğitim verileri

Müşteri	Yaş	Gelir (bin TL)	Sınıf
1	20	30	Ekonomik
2	25	40	Ekonomik
3	30	50	Ekonomik
4	40	80	Lüks
5	45	90	Lüks
6	50	100	Lüks

Her sınıfta 3 gözlem: $\hat{P}(C_1)=\hat{P}(C_2)=3/6=0{,}5$.

Araba müşterisi: sınıf ortalamaları

C_1 = 3 ekonomik; C_2 = 3 lüks müşteri

1. m_1 yaş = (20+25+30)/3 = 25
2. m_1 gelir = (30+40+50)/3 = 40
3. m_2 yaş = (40+45+50)/3 = 45
4. m_2 gelir = (80+90+100)/3 = 90

$m_1 = (25,40)^T$ ve $m_2 = (45,90)^T$; gelir bin TL cinsindedir.

Araba müşterisi: kovaryans kontrolü

Ekonomik grup: (20,30), (25,40), (30,50); m_1=(25,40)

1. Ortalamadan farklar: (−5,−10), (0,0), (5,10)

2. Yaş varyansı = (25+0+25)/3 ≈ 16,67

3. Gelir varyansı = (100+0+100)/3 ≈ 66,67

4. Kovaryans = (50+0+50)/3 ≈ 33,33

S_1 = [[16,67,33,33],[33,33,66,67]], determinantı 0 → tekil.

QDA — Karesel Ayırt Edici Analiz

$$g_i(x) = x^T W_i x + w_i^T x + w_{i0}$$

Her sınıfın kendi kovaryansı vardır: S_1, S_2, …

- $W_i = -\frac{1}{2} S_i^{-1}$; $w_i = S_i^{-1} m_i$
- $x^T S_i^{-1} x$ ifadesi karesel terimler oluşturur.
- Karar sınırı genellikle eğriseldir.

Şekil 5.3 — Farklı kovaryanslar (QDA)

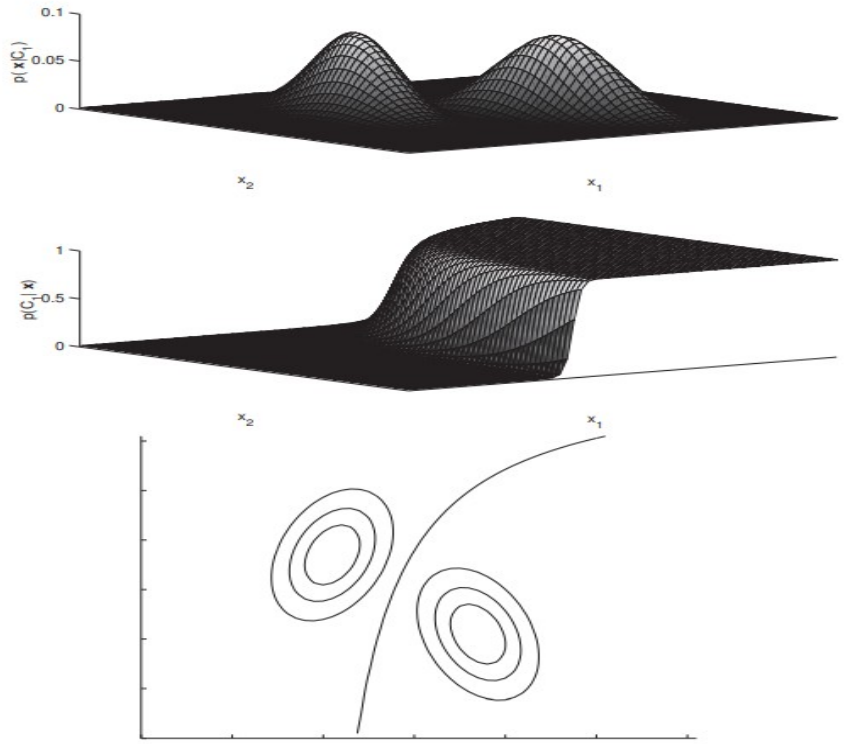


Figure 5.3 Classes have different covariance matrices. Likelihood densities and the posterior probability for one of the classes (top). Class distributions are indicated by isoprobability contours and the discriminant is drawn (bottom).

3 grafiğin anlamı

1. Üst yüzey: iki sınıfa ait koşullu olasılık yoğunlukları.
2. Orta yüzey: bir sınıfın sonsal olasılığı (0–1).
3. Alt şekil: iki elips grubu ve eğrisel ayırt edici sınır.

Her sınıfın S_i matrisi farklıysa karar sınırı eğrisel olabilir.

QDA: esneklik ve maliyet

Avantaj

Sınıfların farklı yönlere yayılmasını öğrenebilir.

Her sınıfın elips şekli ayrı olabilir.

Eğrisel karar sınırları üretebilir.

Risk

Her sınıfa ayrı kovaryans öğrenilir.

Parametre sayısı: $K \times d(d+1)/2$

d büyük, örnek sayısı küçükse S_i tekil veya kararsız olabilir.

Örnek: K=3 ve d=10 için 3×55=165 kovaryans parametresi.

LDA — Ortak Kovaryans Varsayımı

$$S = \Sigma_i \hat{P}(C_i) S_i$$

Her sınıfın merkezi farklı, kovaryansı ortak kabul edilir.

- $g_i(x) = -\frac{1}{2}(x-m_i)^T S^{-1}(x-m_i) + \log \hat{P}(C_i)$
- Ortak $x^T S^{-1} x$ terimi sınıflar arasında gider.
- Kalan ayırt edici fonksiyon doğrusal olur.

LDA neden düz sınır çizer?

$$g_i(x) = w_i^T x + w_{i0}$$

$$w_i = S^{-1} m_i;\ w_{i0} = -\tfrac{1}{2} m_i^T S^{-1} m_i + \log \hat{P}(C_i)$$

- İki sınıfın sınırında $g_1(x) = g_2(x)$.
- $(w_1 - w_2)^T x + (w_{10} - w_{20}) = 0$
- İki boyutta doğru, d boyutta hiperdüzlem.

Şekil 5.4 — Ortak kovaryans (LDA)

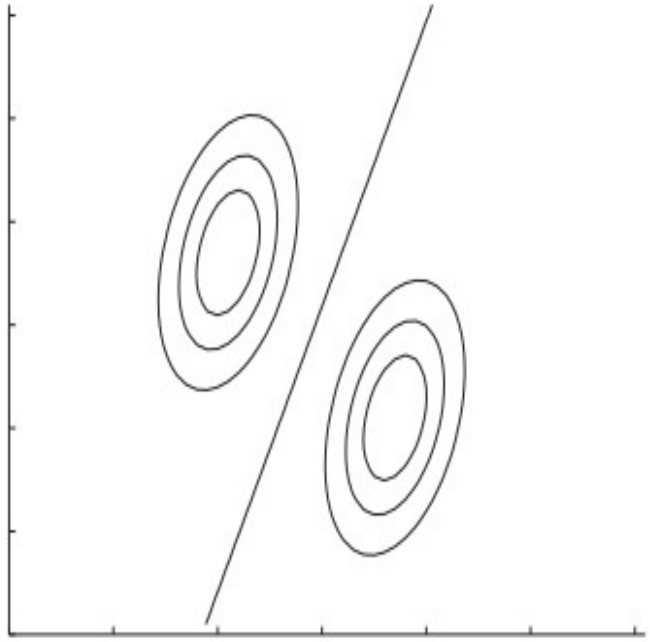


Figure 5.4 Covariances may be arbitary but shared by both classes.

Grafik nasıl okunur?

1. Elipslerin şekli ve eğimi aynıdır.
2. Merkezleri farklıdır; farklı sınıfları gösterir.
3. Ortadaki düz çizgi: doğrusal ayırt edici sınır.

Ortak kovaryans + farklı merkezler → doğrusal karar sınırı.

LDA örneği: Mahalanobis karşılaştır

$m_1=(1,3)$, $m_2=(3,1)$, $S=I$, $x=(1{,}5;2{,}5)$, önseller eşit

1 $D_1^2 = (1{,}5-1)^2 + (2{,}5-3)^2$

2 $D_1^2 = 0{,}25 + 0{,}25 = 0{,}50$

3 $D_2^2 = (1{,}5-3)^2 + (2{,}5-1)^2$

4 $D_2^2 = 2{,}25 + 2{,}25 = 4{,}50$

$0{,}50 < 4{,}50$ olduğundan gözlem C_1 seçilir.

Önsel olasılıklar sonucu değiştirir mi?

Önceki x aynı; $P(C_1)=0,1$ ve $P(C_2)=0,9$ olsun.

1

$$g_1 = -\tfrac{1}{2}(0,50) + \ln(0,1) = -0,25 - 2,303 = -2,553$$

2

$$g_2 = -\tfrac{1}{2}(4,50) + \ln(0,9) = -2,25 - 0,105 = -2,355$$

3

$g_2 > g_1$ olduğundan sınıf C_2 seçilir.

Önsel olasılıklar karar sınırını daha az olası sınıfa doğru kaydırabilir.

Ortak köşegen kovaryans (Gaussian Naive Bayes özel durumu)

$$S = \text{diag}(s_1^2, s_2^2, \ldots, s_d^2)$$

Köşegen dışı kovaryanslar sıfır kabul edilir.

- $g_i = -\frac{1}{2} \Sigma_j ((x_j - m_{ij})/s_j)^2 + \log \hat{P}(C_i)$
- Özellikler sınıfa koşullu bağımsız kabul edilir.
- Ortak köşegende yalnızca d varyans parametresi vardır.

Şekil 5.5 — Köşegen kovaryans

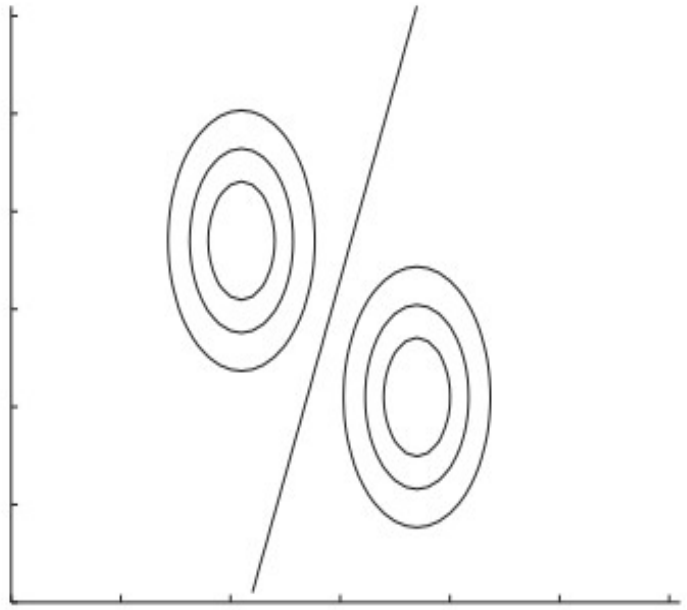


Figure 5.5 All classes have equal, diagonal covariance matrices, but variances are not equal.

Grafik nasıl okunur?

1. $Cov(X_1,X_2)=0$ varsayılır.
2. $Var(X_1)$ ile $Var(X_2)$ eşit olmak zorunda değildir.
3. Ortak kovaryans nedeniyle karar sınırı yine doğrusaldır.

Farklı özellik varyansları, eksenlere paralel elipsler üretir.

Eşit varyans ve en yakın ortalama

$$S = s^2 I \Rightarrow g_i(x) = -||x-m_i||^2/(2s^2) + \log \hat{P}(C_i)$$

Önsel olasılıklar eşitse en yakın ortalamaya gideriz.

- Mahalanobis uzaklığı, ortak ölçekli Öklid uzaklığına iner.
- Dağılımın eş yoğunluk eğrileri daireseldir.
- Öğrenilen kovaryans parametresi yalnızca s^2 olur.

Şekil 5.6 — Eşit varyanslı sınıflar

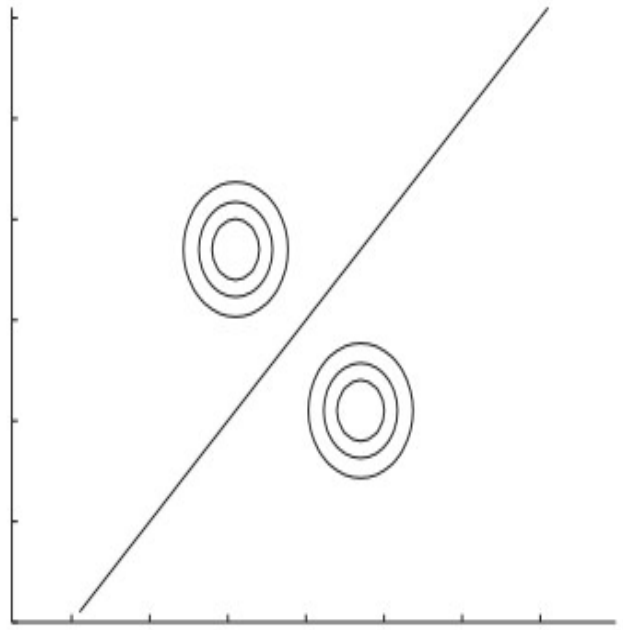


Figure 5.6 All classes have equal, diagonal covariance matrices of equal variances on both dimensions.

Grafik nasıl okunur?

1. Bütün özelliklerin varyansı eşittir.
2. İki sınıfın dağılım genişliği aynıdır.
3. Sınır, eşit önsellerde merkezlere eşit uzaklıktaki doğru olur.

İki boyutta küresel Gaussian, dairesel kontur oluşturur.

En yakın ortalama: adım adım

$m_1=(2,3)$, $m_2=(8,7)$, $x=(3,4)$

1 $D_1 = \sqrt{[(3-2)^2+(4-3)^2]}$

2 $D_1 = \sqrt{(1+1)} = \sqrt{2} \approx 1{,}41$

3 $D_2 = \sqrt{[(3-8)^2+(4-7)^2]}$

4 $D_2 = \sqrt{(25+9)} = \sqrt{34} \approx 5{,}83$

En yakın sınıf merkezi $m_1 \rightarrow C_1$ seçilir.

En yakın ortalama: noktasal çarpım bağı

$$-||x-m_i||^2 = -x^Tx + 2m_i^Tx - m_i^Tm_i$$

Sınıflar arasında ortak $-x^Tx$ terimi çıkarılır.

- Pozitif ölçekle: $g_i(x) = m_i^Tx - \frac{1}{2}||m_i||^2$
- Normlar benzerse yaklaşık olarak $g_i(x) \approx m_i^Tx$
- Bu yaklaşım, prototip / template matching fikrine bağlanır.

QDA mı, LDA mı?

QDA: ayrı Σ_i

Elipsler birbirinden farklı olabilir.

Karesel karar sınırı.

Daha çok kovaryans parametresi.

Daha fazla veriye ihtiyaç duyabilir.

LDA: ortak Σ

Elipslerin şekli ve yönü ortak.

Doğrusal karar sınırı.

Daha az kovaryans parametresi.

Az veriyle daha kararlı olabilir.

Her zaman birinin daha iyi olduğunu söyleyemeyiz: çapraz doğrulamayla karşılaştırırız.

5.6

Model Karmaşıklığı

Daha çok esneklik, daha fazla parametre ve daha çok veri ihtiyacı.

Tablo 5.1 — Kovaryans varsayımları

Varsayım	Matris biçimi	Parametre sayısı
Ortak, küresel	$S_i = s^2 I$	1
Ortak, köşegen	$S_i = \text{diag}(s_1^2,\ldots,s_d^2)$	d
Ortak, genel	$S_i = S$	d(d+1)/2
Sınıfa özel, genel	Her sınıfta farklı S_i	K d(d+1)/2

Özellik ve sınıf sayısı yükseldikçe genel QDA daha pahalı hâle gelir.

Şekil 5.7 — Aynı veri, farklı sınırlar

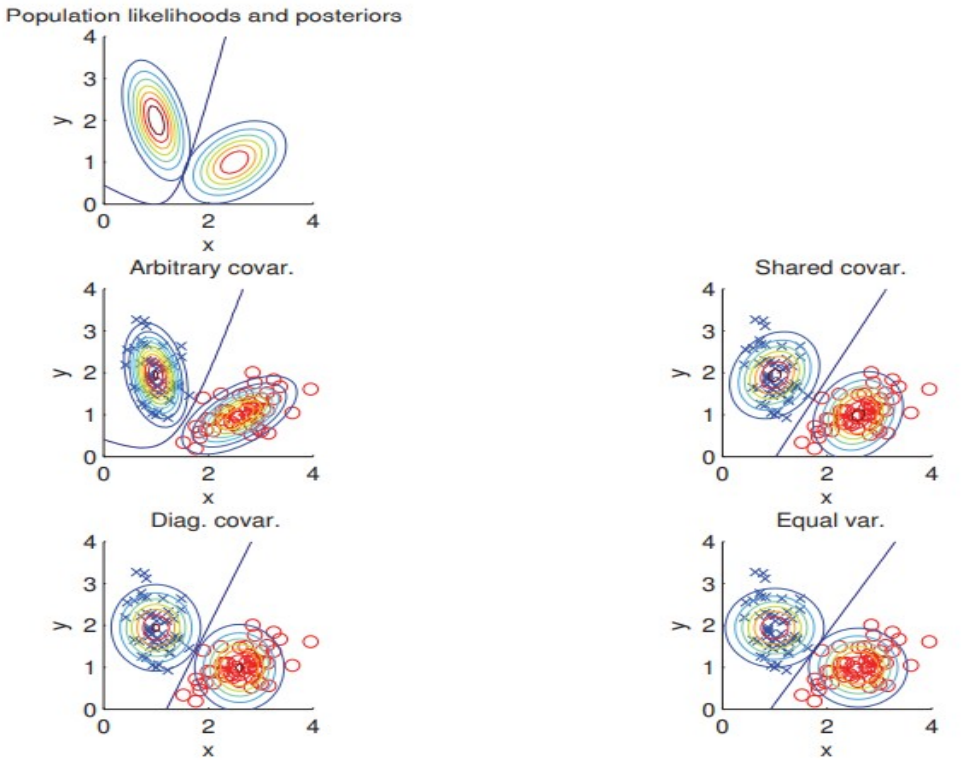


Figure 5.7 Different cases of the covariance matrices fitted to the same data lead to different boundaries.

Grafik nasıl okunur?

1. Üst: kuramsal olasılıklar ve sonsal sınır.
2. Arbitrary: her sınıfa ayrı Σ_i → eğrisel sınır.
3. Shared / diagonal / equal: gittikçe güçlü kısıtlar.

Kısıtlar değiştikçe aynı veri için tahmin edilen sınır da değişir.

Bias–variance dengesi

Basit model

Az parametre

Daha yüksek yanlılık riski (underfitting)

Genellikle daha düşük tahmin varyansı

Örnek: ortak küresel kovaryans

Esnek model

Çok parametre

Daha düşük yapısal kısıt

Küçük veride yüksek varyans / overfitting riski

Örnek: sınıfa özgü genel Σ_i

En iyi varsayımı test kümesiyle seçmeyiz; validation veya çapraz doğrulama kullanırız.

RDA — Düzenlileştirilmiş Ayırt Edici Analiz

$$S_i' = \alpha s^2 I + \beta S + (1-\alpha-\beta) S_i$$

Üç kovaryans varsayımının ağırlıklı birleşimi.

- $\alpha=0, \beta=0 \rightarrow$ QDA: $S_i'=S_i$
- $\alpha=0, \beta=1 \rightarrow$ LDA: $S_i'=S$
- $\alpha=1, \beta=0 \rightarrow$ küresel: $S_i'=s^2 I$

RDA örneği: hangi ağırlıklar?

α = 0,2; β = 0,3; üçüncü katsayı 1−α−β

1. $1 - 0{,}2 - 0{,}3 = 0{,}5$

2. $S_i = [[4,2],[2,9]]$; $S = [[5,1],[1,5]]$

3. $s^2I = [[4,0],[0,4]]$

4. $S_i' = 0{,}2(s^2I) + 0{,}3S + 0{,}5S_i$

Bütün ağırlıklar sıfırdan büyük ve toplamları 1.

RDA örneği: üç çarpım

$S_i' = 0{,}2(s^2I) + 0{,}3S + 0{,}5S_i$

1. $0{,}2(s^2I) = [[0{,}8;0],[0;0{,}8]]$
2. $0{,}3S = [[1{,}5;0{,}3],[0{,}3;1{,}5]]$
3. $0{,}5S_i = [[2;1],[1;4{,}5]]$
4. Terimleri hücre hücre topla → $[[4{,}3;1{,}3],[1{,}3;6{,}8]]$

S_i' = [[4,3, 1,3],[1,3, 6,8]] (ondalık virgüllerle).

Normalize etmek neden önemli?

Ham Öklid uzaklığı

A kişisi: 20 yaş, 30.000 TL
B kişisi: 25 yaş, 80.000 TL

$D = \sqrt{(5^2 + 50.000^2)}$

Gelir sayısal olarak uzaklığı domine eder.

Z-normalizasyonu

$z = (x - \mu)/\sigma$

Her özelliğin ortalamasını 0, standart sapmasını 1 yapar.

Ancak z-normalizasyonu korelasyonu ortadan kaldırmaz.

Korelasyon önemliyse Mahalanobis uzaklığı daha uygun olabilir.

Kontrol: model karmaşıklığı

SORU

K = 3 sınıf ve d = 10 özellik için ortak tam kovaryans ve sınıfa özgü tam kovaryans kaç parametre gerektirir?

ÇÖZÜM / CEVAP

Ortak: 10×11/2=55. Sınıfa özgü: 3×55=165 kovaryans parametresi.

5.7

Ayrık Özellikler

Sayı olmayan özelliklerle olasılıksal sınıflandırma.

Ayrık veri türleri

İkili / Bernoulli

E-postada “bedava” var mı?

1 = Evet
0 = Hayır

$p_{ij} = P(x_j=1 \mid C_i)$

Çok kategorili

Renk ∈ {Kırmızı, Mavi, Yeşil, Siyah}

Bir özellik birçok değerden birini alabilir.

Gösterge değişkenleriyle temsil edilir.

Ayrık veriyi Gaussian varsayımı yerine uygun olasılık modeliyle açıklarız.

Bernoulli Naive Bayes

$$p(x|C_i) = \prod_j p_{ij}^{x_j} (1-p_{ij})^{1-x_j}$$

Özellikler ikili ve sınıfa koşullu bağımsızdır.

- $x_j=1$ ise p_{ij} çarpılır.
- $x_j=0$ ise $(1-p_{ij})$ çarpılır.
- Ayırt edici puan, logaritma ile toplam hâline gelir.

Spam örneği: öğrenilmiş olasılıklar

Olasılık	Spam	Normal
P(bedava=1 | Sınıf)	0,80	0,10
P(ödül=1 | Sınıf)	0,60	0,05
P(Sınıf)	0,40	0,60

Yeni e-postada her iki kelime de mevcut: x = (1,1).

Spam sınıflandırma: koşullu yoğunluk

İki kelime var → x=(1,1)

1. $p(x|\text{Spam}) = 0{,}8 \times 0{,}6 = 0{,}48$

2. $p(x|\text{Normal}) = 0{,}1 \times 0{,}05 = 0{,}005$

3. Önsel ile çarp: Spam → $0{,}48 \times 0{,}4 = 0{,}192$

4. Önsel ile çarp: Normal → $0{,}005 \times 0{,}6 = 0{,}003$

Sınıf skoru daha büyük: Spam.

Spam sınıflandırma: sonsal olasılık

Spam için ağırlık 0,192; Normal için 0,003

1. Payda = 0,192 + 0,003 = 0,195

2. $P(\text{Spam}|x) = 0{,}192 / 0{,}195$

3. $P(\text{Spam}|x) \approx 0{,}9846$

4. $P(\text{Normal}|x) \approx 0{,}0154$

Varsayımlara göre e-postanın spam olasılığı yaklaşık %98,46.

Bag of Words: haberleri vektöre çevirme

Haber	futbol	seçim	ekonomi
Futbol takımı galip geldi	1	0	0
Seçim ve ekonomi tartışıldı	0	1	1
Futbol ekonomisi büyüyor	1	0	1

Kelime sırası ve cümle yapısı kaybolur; yalnızca kelimenin varlığı tutulur.

Bernoulli parametre tahmini

$$\hat{p}_{ij} = (\Sigma_t x_j^{(t)} r_i^{(t)}) / (\Sigma_t r_i^{(t)})$$

i. sınıf içindeki j. kelime görülme oranı.

- Bir kelime tüm sınıflarda eşit sık görülüyorsa ayırt ediciliği düşüktür.
- Belge sınıflandırma, spam filtreleme ve bazı biyoinformatik görevlerinde kullanılır.
- Pratikte sıfır olasılıklara karşı Laplace yumuşatma yararlıdır.

One-Hot Encoding: renk özelliği

Renk	Kırmızı	Mavi	Yeşil	Siyah
Kırmızı	1	0	0	0
Mavi	0	1	0	0
Yeşil	0	0	1	0
Siyah	0	0	0	1

Örnek: Mavi → (0,1,0,0); aynı değişkende yalnızca bir gösterge 1 olur.

Çok kategorili Naive Bayes

$$p(x|C_i) = \Pi_j \Pi_k p_{ijk}^{z_{jk}}$$

z_{jk}=1 ise x_j, k. kategoriyi almıştır.

- $p_{ijk} = P(x_j = v_k \mid C_i)$
- $g_i(x) = \Sigma_j \Sigma_k z_{jk} \log(p_{ijk}) + \log P(C_i)$
- $\hat{p}_{ijk} = \Sigma_t (z_{jk}^{(t)} r_i^{(t)}) / \Sigma_t r_i^{(t)}$

5.8

Çok Değişkenli Regresyon

Birden çok özellikten tek bir sürekli çıktıyı tahmin etme.

Çoklu doğrusal regresyon modeli

$$r = w_0 + w_1x_1 + w_2x_2 + \ldots + w_d\ x_d + \varepsilon$$

Ağırlıklar, her özelliğin tahmine katkısını belirler.

- w_0: sabit terim (intercept)
- w_j: j. özelliğin katsayısı
- ε: hata/gürültü terimi

Sınav notu tahmini

Model: $\hat{y} = 10 + 5x_1 + 0{,}3x_2 + 2x_3$

1. $x_1 = 6$ saat; $x_2 = \%80$ devam; $x_3 = 4$ ödev

2. $\hat{y} = 10 + 5\times6 + 0{,}3\times80 + 2\times4$

3. $\hat{y} = 10 + 30 + 24 + 8 = 72$

4. Gerçek not 75 ise hata $e = 75 - 72 = 3$

Hata küçüldükçe tahmin gerçek değere yaklaşır.

Hata fonksiyonu: en küçük kareler

$$E(w) = \tfrac{1}{2} \Sigma_t (r^{(t)} - \hat{y}^{(t)})^2$$

Gaussian sabit varyanslı gürültü altında ML ile ilişkilidir.

- MSE = $(1/N)\, \Sigma_t (r^{(t)} - \hat{y}^{(t)})^2$
- $E(w) = (N/2) \times \text{MSE}$
- İki fonksiyon aynı w parametrelerinde minimize edilir.

Normal denklem: türevden matris çözümüne

$$X^T X w = X^T r$$

Hata fonksiyonunu katsayılara göre türevleyip sıfıra eşitleriz.

- X: ilk sütunu 1 olan tasarım matrisi
- w: katsayı vektörü $(w_0, w_1, \ldots, w_d)^T$
- Ters varsa: $w = (X^T X)^{-1} X^T r$

Regresyon örneği: veri tablosu

Gözlem	x_1	x_2	Gerçek r
1	0	0	1
2	1	0	3
3	0	1	4
4	1	1	6

Model: $\hat{y} = w_0 + w_1x_1 + w_2x_2$. Katsayıları bulalım.

Normal denklemler: X ve r

Tablodaki 4 gözlem, 2 özellik ve 1 sabit terim içerir.

1. X satır 1 = (1,0,0); satır 2 = (1,1,0)

2. X satır 3 = (1,0,1); satır 4 = (1,1,1)

3. $r = (1,3,4,6)^T$

4. X: 4×3; w: 3×1; r: 4×1

Xw çarpımı 4×1 tahmin vektörü verir.

Normal denklemler: X^TX

X = [(1,0,0); (1,1,0); (1,0,1); (1,1,1)]

1. X^TX: 3×3 bir matristir.

2. (1,1) hücresi = 1+1+1+1 = 4

3. (1,2) hücresi = 0+1+0+1 = 2

4. Sonuç: X^TX = [[4,2,2],[2,2,1],[2,1,2]]

Her hücre ilgili sütunların iç çarpımıdır.

Normal denklemler: $X^T r$

$r = (1,3,4,6)^T$

1. 1. eleman: 1+3+4+6 = 14

2. 2. eleman: 0+3+0+6 = 9

3. 3. eleman: 0+0+4+6 = 10

4. Sonuç: $X^T r = (14,9,10)^T$

Artık $X^T X w = X^T r$ için tüm sayıları biliyoruz.

Denklem sistemini yazalım

$$[4\ 2\ 2;\ 2\ 2\ 1;\ 2\ 1\ 2]\ w = [14;\ 9;\ 10]$$

Matris eşitliği üç doğrusal denklem üretir.

- $4w_0 + 2w_1 + 2w_2 = 14$
- $2w_0 + 2w_1 + w_2 = 9$
- $2w_0 + w_1 + 2w_2 = 10$

Katsayı çözümü: w_1 ve w_2

Üç denklemi eliminasyonla çözebiliriz.

1 2. denklemi 2 ile çarp; 1. denklemi çıkar.

2 $(4w_0+4w_1+2w_2) - (4w_0+2w_1+2w_2) = 18-14$

3 $2w_1 = 4 \Rightarrow w_1 = 2$

4 3. denklemi 2 ile çarp; 1. denklemi çıkar → $2w_2 = 6$

Sonuç: $w_1 = 2$, $w_2 = 3$.

Katsayı çözümü: w_0 ve model

Bulunan $w_1 = 2$, $w_2 = 3$ ilk denklemde kullanılır.

1 $4w_0 + 2(2) + 2(3) = 14$

2 $4w_0 + 4 + 6 = 14$

3 $4w_0 = 4 \Rightarrow w_0 = 1$

4 Öğrenilmiş model: $\hat{y} = 1 + 2x_1 + 3x_2$

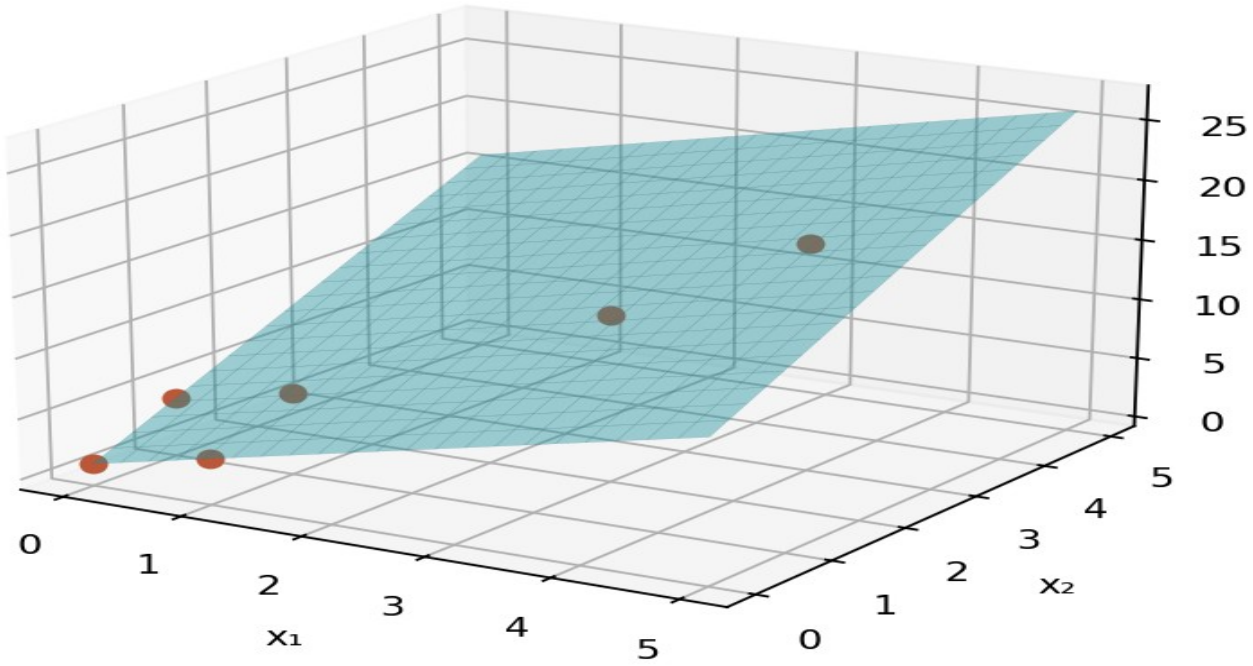
$w = (1,2,3)^T$.

Tahmin kontrolü ve MSE

Gözlem	Gerçek	Model hesabı	Tahmin
1	1	1+2×0+3×0	1
2	3	1+2×1+3×0	3
3	4	1+2×0+3×1	4
4	6	1+2×1+3×1	6

Her hata 0 olduğundan eğitim kümesindeki MSE = (0+0+0+0)/4 = 0.

Ek grafik: doğrusal regresyon örneği



Grafik nasıl okunur?

1. Noktalar: gözlemler.
2. Doğru / düzlem: modelin tahmini.
3. Düşey fark: hata; kareleri toplanarak minimize edilir.

Gerçek değerler ve model tahminlerinin ne kadar yaklaştığı izlenebilir.

Polinom ve taban (basis) fonksiyonları

Polinom regresyon

$\hat{y} = w_0 + w_1 x + w_2 x^2$

$z_1 = x$, $z_2 = x^2$ tanımlarsak
$\hat{y} = w_0 + w_1 z_1 + w_2 z_2$

Katsayılara göre hâlâ doğrusal.

Genel taban fonksiyonları

$z_1 = \sin(x)$, $z_2 = \exp(x^2)$

$\hat{y} = w_0 + w_1 z_1 + w_2 z_2$

Orijinal girdide doğrusal olmayan ilişki öğrenilebilir.

Aynı normal denklem yeni oluşturulan özellik matrisi X için kullanılabilir.

Katsayıları nasıl yorumlarız?

Katsayı işaretleri

Model: $\hat{y}=10+5x_1-3x_2+0{,}1x_3$

$w_1 > 0$: diğerleri sabitken tahmin artar.

$w_2 < 0$: diğerleri sabitken tahmin azalır.

Önemlilik ve ölçek

Özellikler farklı birimlerdeyse $|w_j|$ değerlerini doğrudan kıyaslamak yanıltıcıdır.

Katsayı işaretleri tek başına nedensel etki kanıtlamaz.

Birden fazla çıktı varsa ayrı regresyonlar veya ortak çok çıktılı modeller kurulabilir.

Kontrol: yeni girdiyle tahmin

SORU

Öğrenilmiş model $\hat{y} = 1 + 2x_1 + 3x_2$. Yeni öğrenci için $x_1=2$, $x_2=4$ ise tahmin nedir?

ÇÖZÜM / CEVAP

$\hat{y} = 1 + 2(2) + 3(4) = 1 + 4 + 12 = 17$.

Bölümün ana modellerini karşılaştıralım

Model	Kovaryans / özellik varsayımı	Çıktı
QDA	Her sınıfa ayrı genel S_i	Eğrisel sınır
LDA	Ortak genel S	Doğrusal sınır
Gaussian NB (özel)	Ortak köşegen S	Doğrusal sınır
En yakın ortalama	Ortak küresel s^2I	En yakın merkez
Bernoulli NB	Bağımsız ikili özellikler	Sınıf tahmini
Çoklu regresyon	Lineer özellik birleşimi	Sürekli sayı

Varyans varsayımları birer modelleme seçimi ve doğrulanması gereken yaklaşımlardır.

Bölümün akılda kalacak 6 fikri

Son tekrar: Aynı hikâyenin farklı matematiksel adımları.

Veri ve olasılık

1. X matrisi gözlemler × özellikler biçimindedir. 2. μ merkez, Σ yayılım ve bağımlılık yapısıdır.

Sınıflandırma

3. Mahalanobis ölçek ve kovaryansı önemser. 4. QDA / LDA / NB farklı kovaryans varsayımlarıdır.

Genelleme ve regresyon

5. Karmaşıklık validasyonla seçilir. 6. Regresyonda amaç kareli hatayı azaltmaktır.

ANA FİKİR Matematikteki her sembolün veride neyi temsil ettiğini açıklayabilmek hedefimiz.

Kaynakça ve sunum notu

Temel kaynak

Ethem Alpaydın (2014), Introduction to Machine Learning, MIT Press.
Bölüm 5.1–5.8, sayfa 93–111. Bölümdeki Şekil 5.1–5.7 kullanıcı tarafından sağlanan kaynak görsellerdir.

Bu sunumdaki öğretici katkılar

Türkçe açıklamalar; sınıf içi tekrar soruları; adım adım çözümlü ortalama, kovaryans, Mahalanobis, sınıflandırma, RDA, Naive Bayes ve regresyon örnekleri; ek açıklayıcı grafikler.

KAPSAM: 5.1–5.8 | 5.9 ve sonraki metinler sağlanmamıştır.