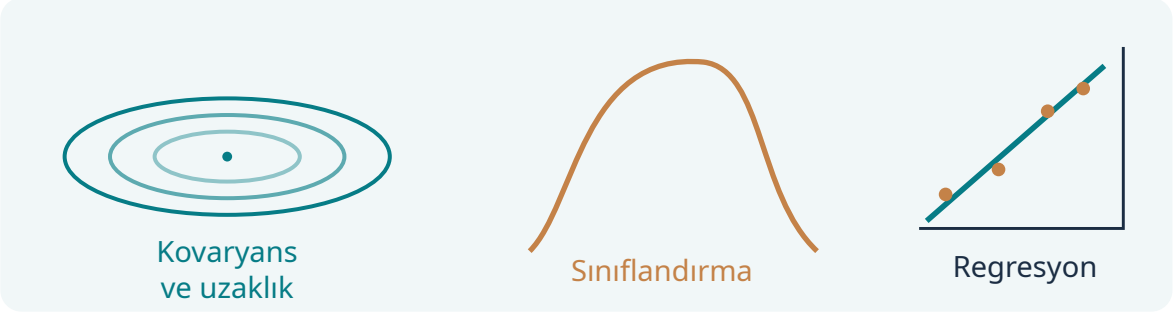
MAKİNE ÖĞRENMESİ · DERS NOTU

5. ÜNİTE

Çok Değişkenli Yöntemler

Multivariate Methods



Türkçe çeviri, açıklamalar ve uygulamalar
Bölümler **5.1–5.8** · Denklemler **5.1–5.39** · Kitaptan **7 özgün şekil** · Ek grafikler · Adım adım örnekler

Temel kaynak: Ethem Alpaydın, *Introduction to Machine Learning* (2014), MIT Press, Bölüm 5, s. 93–111.

Bu çalışma, kullanıcı tarafından paylaşılan 5.1–5.8 metinlerinden hazırlanmış açıklamalı Türkçe ders notudur. Kaynakta gönderilmeyen 5.9 ve sonrasını içermez.

Contents

5 Çok Değişkenli Yöntemlere Giriş 2

5.1 Çok Değişkenli Veri (Multivariate Data) 3

5.2 Parametre Tahmini (Parameter Estimation) 4

5.3 Eksik Değerlerin Tahmini (Estimation of Missing Values) 6

5.4 Çok Değişkenli Normal Dağılım (Multivariate Normal Distribution) 7

5.5 Çok Değişkenli Sınıflandırma (Multivariate Classification) 11

5.6 Model Karmaşıklığının Ayarlanması (Tuning Complexity) 18

5.7 Ayrık Özellikler (Discrete Features) 21

5.8 Çok Değişkenli Regresyon (Multivariate Regression) 23

Kavram sözlüğü ve karşılaştırma 26

Ders için tekrar soruları ve yanıtlar 27

Nasıl okunmalı? Bölüm metinleri Türkçeye anlam korunarak aktarılmış, önemli denklemler kaynak numaralarıyla gösterilmiş, ardından *Açıklama* ve *Çözümlü örnek* kısımları eklenmiştir. Grafiklerin altındaki Türkçe açıklamalar, yalnızca başlık çevirisi değil, neye bakılması gerektiğini de anlatır.

Simgeler: N gözlem sayısı; d özellik sayısı; K sınıf sayısı; x özellik vektörü; μ ortalama; Σ kovaryans; S tahmini kovaryans; C_i sınıf; $P(C_i)$ önsel sınıf olasılığı; $g_i(x)$ ayırt edici fonksiyon.

5 Çok Değişkenli Yöntemlere Giriş

Dördüncü bölümde sınıflandırma ve regresyon için parametrik yaklaşımı ele almıştık. Bu bölümde, birden fazla giriş değişkeni bulunan durumlara geçiyoruz. Çıktı bir sınıf kodu veya sürekli sayısal değer olabilir; farklı girişler sayısal ya da ayrık olabilir. Etiketli çok değişkenli örneklerden bu işlevlerin nasıl öğrenilebildiğini ve öğrenme modelinin karmaşıklığının veriye göre nasıl ayarlanabildiğini inceleyeceğiz.

Temel fikir. Tek değişkenli tahmin $y = f(x_1)$ iken çok değişkenli tahmin $y = f(x_1, x_2, \ldots, x_d)$ biçimindedir. Örneğin sınav notunu çalışma saati, devam oranı ve ödev performansından tahmin etmek çok değişkenli regresyon; “geçti/kaldı” sonucunu tahmin etmek çok değişkenli sınıflandırmadır.

5.1 Çok Değişkenli Veri (Multivariate Data)

Birçok uygulamada her birey veya olay hakkında birden fazla ölçüm yapılır. Bunlar bir **gözlem vektörü** oluşturur. Örneklem şu veri matrisiyle ifade edilebilir:

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(N)} & x_2^{(N)} & \cdots & x_d^{(N)} \end{bmatrix}.$$

Matriste d sütun, birey veya olaya ait d ölçümü temsil eder. Bunlar *girdiler, özellikler (features) veya nitelikler (attributes)* olarak da adlandırılır. N satır ise birbirinden bağımsız ve özdeş dağılımlı olduğu varsayılan gözlemlere karşılık gelir. Bu gözlemlere *örnek (example)* ya da *instance* denebilir.

Örneğin bir kredi başvurusunda müşterinin yaşı, medeni durumu ve yıllık geliri özellikler olabilir. Yaş yıl cinsinden, gelir para birimi cinsinden ölçüldüğünden ölçekler farklı olabilir. Yaş sayısal bir değişkendir; medeni durum ayrık veya kategoriktir. Genellikle özellikler arasında ilişki bulunur.

Çok değişkenli analiz, büyük bir veri kümesini az sayıda parametreyle özetlemek, veriyi keşfederek hipotez geliştirmek veya bir değişkenin değerini diğer değişkenlerden tahmin etmek için yapılabilir. Tahmin edilen değişken kategorikse **sınıflandırma**, sayısalsa **regresyon** problemi vardır.

Çözümlü örnek: Veri matrisini okuma. Dört öğrenci için üç özellik ölçülmüş olsun: haftalık çalışma saati, devam yüzdesi ve önceki sınav notu.

$$X = \begin{bmatrix} 2 & 60 & 50 \\ 4 & 75 & 65 \\ 6 & 90 & 80 \\ 8 & 95 & 90 \end{bmatrix}, \qquad N = 4, \quad d = 3.$$

Birinci satır $(2, 60, 50)$ bir öğrenciyi; ikinci sütun $(60, 75, 90, 95)^T$ ise bütün öğrencilerin devam yüzdelerini temsil eder. X'in boyutu 4×3'tür. Aynı girdilerle "başarılı/başarısız" sınıfı veya sayısal final notu tahmin edilebilir.

İnce ayrım. "Gözlemler bağımsızdır" varsayımı, her satırdaki özelliklerin birbirinden bağımsız olduğunu söylemez. Aynı kişinin yaşı ve geliri ilişkili olabilir. Ayrıca özellikler ilişkisiz olsa bile birlikte kullanımları faydalı olabilir; kaynak metnin "ilişki yoksa çok değişkenli analiz gerekmez" ifadesi genel bir zorunluluk değildir.

5.2 Parametre Tahmini (Parameter Estimation)

Ortalama vektörü

Ortalama vektörü μ, veri matrisindeki her sütunun beklenen değerini içerir:

$$E[x] = \mu = \begin{bmatrix} \mu_1 & \mu_2 & \cdots & \mu_d \end{bmatrix}^T. \tag{5.1}$$

Örneğin üç öğrencinin çalışma saatleri $(1, 2, 3)$ ve notları $(50, 70, 90)$ ise $\mu_1 = 2$, $\mu_2 = 70$ ve $\mu = (2, 70)^T$'dir. Ortalama, çok boyutlu uzayda verinin merkezini belirtir.

Varyans ve kovaryans

X_i değişkeninin varyansı σ_i^2 ile gösterilir. İki değişken arasındaki kovaryans:

$$\sigma_{ij} \equiv \mathrm{Cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)] = E[X_i X_j] - \mu_i \mu_j. \tag{5.2}$$

Kovaryans simetriktir: $\sigma_{ij} = \sigma_{ji}$. Aynı değişkenin kendisiyle kovaryansı, varyansına eşittir: $\sigma_{ii} = \sigma_i^2$. d değişken için d varyans ve $d(d-1)/2$ farklı değişken çifti kovaryansı vardır.

Bunları bir **kovaryans matrisi** Σ içinde toplarız:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_d^2 \end{bmatrix}.$$

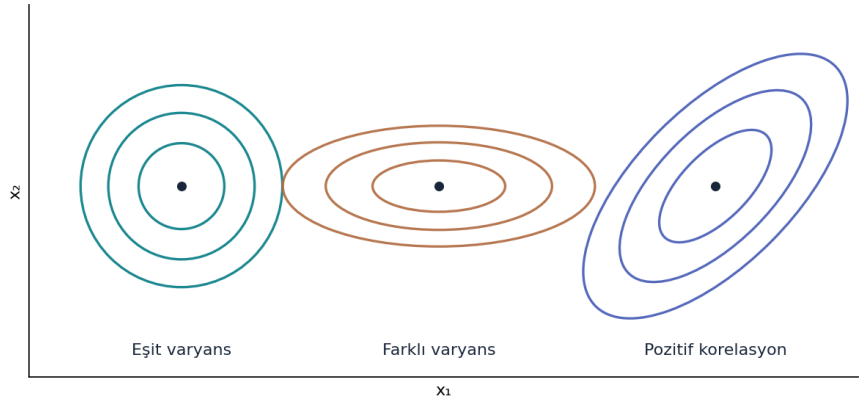
Köşegen elemanları varyans, köşegen dışı elemanlar kovaryanstır; matris simetriktir. Vektör-matris biçimi şöyledir:

$$\Sigma \equiv \mathrm{Cov}(X) = E[(X - \mu)(X - \mu)^T] = E[XX^T] - \mu\mu^T. \tag{5.3}$$

Doğrusal ilişkide iki değişken birlikte artıyorsa kovaryans pozitif, biri artarken öteki azalıyorsa negatiftir. Kovaryansın mutlak büyüklüğünün yorumlanması zordur; çünkü ölçü birimlerine bağlıdır. Bu nedenle -1 ile $+1$ arasında normalize edilen **korelasyon** kullanılır:

$$\mathrm{Corr}(X_i, X_j) = \rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}. \tag{5.4}$$

Bağımsız değişkenlerin kovaryansı ve korelasyonu sıfırdır. Ancak tersi her zaman doğru değildir: Doğrusal olmayan bir bağımlılık varken korelasyon sıfır olabilir.



Ek çizim. Eşit varyans dairesel kontur; farklı varyans eksen hizalı elips; pozitif korelasyon eğik elips oluşturur.

Örnek: Kovaryans ile korelasyonu ayırma. Var$(X_1) = 4$, Var$(X_2) = 9$, Cov$(X_1, X_2) = 3$ olsun. Standart sapmalar 2 ve 3'tür. Dolayısıyla $\rho = 3/(2 \cdot 3) = 0.5$. Kovaryansın değeri 3 iken standartlaştırılmış doğrusal ilişki 0.5'tir. X_2 metre yerine santimetreyle ölçülse kovaryans değişir, korelasyon değişmez.

Örneklemden tahmin

Çok değişkenli örneklemde ortalama, kovaryans ve korelasyon hesaplanabilir. Maksimum olabilirlik (ML) ortalama tahmin edicisi m'dir:

$$m = \frac{1}{N}\sum_{t=1}^{N} x^{(t)}, \qquad m_i = \frac{1}{N}\sum_{t=1}^{N} x_i^{(t)}. \tag{5.5}$$

Örneklem kovaryans matrisi S için varyans ve kovaryans ML tahminleri:

$$s_i^2 = \frac{1}{N}\sum_{t=1}^{N}(x_i^{(t)} - m_i)^2, \tag{5.6}$$

$$s_{ij} = \frac{1}{N}\sum_{t=1}^{N}(x_i^{(t)} - m_i)(x_j^{(t)} - m_j). \tag{5.7}$$

Bu tahminler istatistiksel olarak yanlıdır: Örneklem varyansının klasik yanlı olmayan biçiminde $N - 1$ ile bölünür. Kaynak, uygulamada iki seçim büyük fark oluşturuyorsa verinin yetersiz olabileceğini vurgular. Örneklem korelasyonu:

$$r_{ij} = \frac{s_{ij}}{s_i s_j}. \tag{5.8}$$

Bu katsayılardan **korelasyon matrisi** R oluşturulur.

Adım adım hesap: Üç gözlem $x^{(1)} = (1, 2)$, $x^{(2)} = (2, 4)$, $x^{(3)} = (3, 3)$ olsun.

1. Ortalamalar: $m_1 = (1 + 2 + 3)/3 = 2$; $m_2 = (2 + 4 + 3)/3 = 3$.
2. Merkezlenmiş vektörler: $(-1, -1)$, $(0, 1)$, $(1, 0)$.
3. Varyanslar: $s_1^2 = (1 + 0 + 1)/3 = 2/3$; $s_2^2 = (1 + 1 + 0)/3 = 2/3$.
4. Kovaryans: $s_{12} = [(-1)(-1) + (0)(1) + (1)(0)]/3 = 1/3$.
5. Matris: $S = \begin{bmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{bmatrix}$.
6. Korelasyon: $r_{12} = (1/3)/(2/3) = 0.5$.

Bu örnekte $N - 1$ ile bölünürse varyans ve kovaryans sayıları değişir, fakat korelasyon yine 0.5 kalır.

5.3 Eksik Değerlerin Tahmini (Estimation of Missing Values)

Gözlemlerde bazı özellik değerleri eksik olabilir. Bu gözlemleri tümüyle atmak bilgi kaybına neden olur; özellikle küçük veri kümelerinde buna katlanmak zor olabilir. Bu nedenle eksik girişleri tahmin ederek doldururuz. İşleme **imputation (eksik değer tamamlama)** denir.

Ortalama ve mod ile tamamlama

Sayısal bir değişkende eksik değerin yerine eldeki değerlerin ortalaması konabilir. Ayrık değişkenlerde ise en sık görülen, yani mod değeri kullanılabilir.

Örnek. Notlar $(70, 80, \text{eksik}, 90)$ ise görülen üç notun ortalaması $(70+80+90)/3 = 80$'dir; eksik kayıt 80 ile doldurulur. Kategorik bir "şehir" alanında en çok "İstanbul" görülüyorsa eksik değer bu modla tamamlanabilir. Ancak mod ataması gerçek değerin İstanbul olduğunu kanıtlamaz.

Regresyonla tamamlama

Daha bilgilendirici yaklaşım, eksik değişkeni diğer mevcut değişkenlerden tahmin etmektir. Tahmin edilen özellik sürekli ise regresyon, kategorik ise sınıflandırma modeli eğitilir; eğitim için o özelliğin gözlendiği kayıtlar kullanılır. Birden fazla değişken eksikse ortalamalarla başlanıp tahminler kararlı hâle gelene kadar işlem yinelemeli yürütülebilir. Özellikler güçlü biçimde ilişkili değilse regresyon yaklaşımı ortalamayla doldurmaya yakınlaşır.

Örnek. Çalışma saati $x = 6$ olan öğrencinin notu eksik olsun. Diğer öğrencilerden öğrenilmiş ilişki $\hat{y} = 10x + 30$ ise $\hat{y} = 10 \cdot 6 + 30 = 90$ tahmin edilir. Kullanılabilir notlar $(50, 70, 110)$ olsaydı ortalama ile tahmin yalnızca 76.67 olurdu. Regresyon diğer özellik bilgisini kullanır.

Eksikliğin kendisi bilgi taşıyabilir

Bazen bir özelliğin belirtilmemiş olması önemli bir ipucudur. Örneğin kredi kartı başvurusunda telefon numarasının verilmemesi bilgi taşıyabilir. Bu durumda eksiklik ayrı bir gösterge değeriyle kodlanıp modele dahil edilebilir.

$$M_j = \begin{cases} 1, & x_j \text{ eksikse,} \\ 0, & x_j \text{ gözlendiyse.} \end{cases}$$

Uygulama uyarısı. Eksik değer doldurmada öğrenilen ortalama, mod veya regresyon modeli *yalnızca eğitim verisiyle* belirlenmelidir. Test kümesinin istatistiklerini ön işleme sırasında kullanmak veri sızıntısına (data leakage) neden olur. Eksiklik mekanizmasına göre ortalama atama yanlılık da oluşturabilir.

5.4 Çok Değişkenli Normal Dağılım (Multivariate Normal Distribution)

d boyutlu x normal dağılıma sahipse ortak olasılık yoğunluğu:

$$p(x) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right]. \tag{5.9}$$

Gösterim $x \sim \mathcal{N}_d(\mu, \Sigma)$ biçimindedir. μ ortalama vektörü, Σ kovaryans matrisidir. Normal dağılımın çok değişkenli çan biçimli yoğunluğu **Şekil 5.1**'de gösterilmektedir.

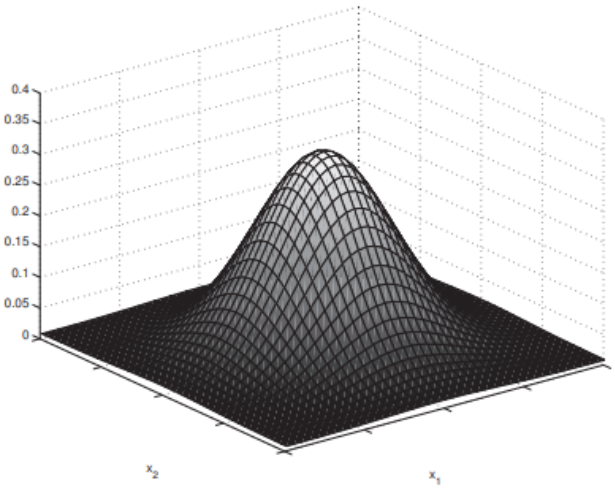


Figure 5.1 Bivariate normal distribution.

Şekil 5.1 (özgün). İki değişkenli normal dağılım. Yatay eksenler x_1, x_2; yükseklik $p(x_1, x_2)$ yoğunluğudur. En yüksek nokta ortalama vektörü çevresindedir.

> **Grafiği okuma.** Üç boyutlu yüzeyin yüksekliği tek bir noktadaki olasılık değildir. Sürekli dağılımda olasılık, bir bölge üzerinde yoğunluğun integraliyle hesaplanır. Merkez çevresindeki noktalar daha yüksek yoğunluk taşıyabilir.

Mahalanobis uzaklığı

Tek boyutta $(x-\mu)^2/\sigma^2$ ifadesi, ortalamaya uzaklığın standart sapmaya göre normalize edilmiş karesidir. Çok boyutta genel karşılığı:

$$D_M^2(x, \mu) = (x-\mu)^T\Sigma^{-1}(x-\mu). \tag{5.10}$$

Mahalanobis uzaklığının kendisi $D_M = \sqrt{D_M^2}$'dir. $D_M^2 = c^2$ eşitliği, merkezi μ olan ve biçimi/yönelimi Σ'ya bağlı bir hiperelipsoid tanımlar. Σ^{-1} nedeniyle varyansı büyük özellik daha az ağırlık alır; yüksek korelasyonlu değişkenlerden gelen tekrar eden bilginin katkısı da ayarlanır. Bu işlem ölçekleri ve korelasyonları birlikte dikkate alır.

Çözümlü Mahalanobis örneği. $\mu = (0,0)^T$, $\Sigma = \text{diag}(1,9)$, $x = (1,3)^T$ olsun. Öklid uzaklığı $\sqrt{1^2+3^2} = \sqrt{10} \simeq 3.16$'dır. Mahalanobis uzaklığının karesi:

$$D_M^2 = [1 \;\; 3] \begin{bmatrix} 1 & 0 \\ 0 & 1/9 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = 1 + 1 = 2.$$

Dolayısıyla $D_M = \sqrt{2} \simeq 1.41$. İkinci boyuttaki 3 birimlik fark, o boyutun standart sapması da 3 olduğu için yalnızca bir standart sapmaya eşittir.

İki değişkenli durumda elipsler

Görselleştirmek için $d = 2$ seçelim. Bağımsız değişkenlerde eş yoğunluk elipslerinin ana eksenleri koordinat eksenlerine paraleldir. Varyanslar farklıysa elipsler uzar; kovaryansın işareti elipsi döndürür. Ortalama $\mu = (\mu_1, \mu_2)^T$ ve kovaryans:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

Ortak iki değişkenli yoğunluk:

$$p(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{z_1^2 - 2\rho z_1 z_2 + z_2^2}{2(1-\rho^2)}\right], \quad z_i = \frac{x_i - \mu_i}{\sigma_i}. \tag{5.11}$$

Buradaki z_i, **z-normalizasyonu** ile elde edilen standartlaştırılmış değerdir. Örneğin $x = 80$, $\mu = 70$, $\sigma = 10$ ise $z = (80-70)/10 = 1$; gözlem ortalamanın bir standart sapma üzerindedir.

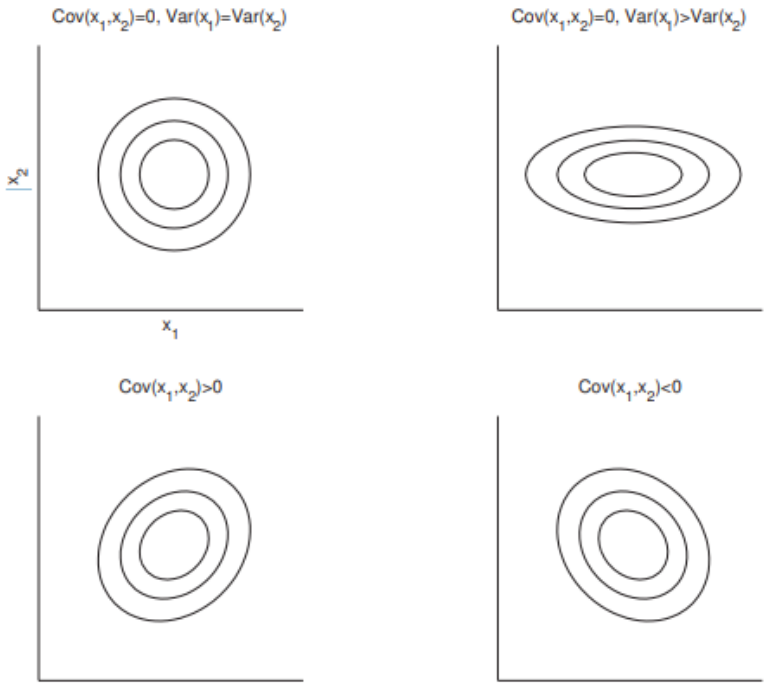


Figure 5.2 Isoprobability contour plot of the bivariate normal distribution. Its center is given by the mean, and its shape and orientation depend on the covariance matrix.

Şekil 5.2 (özgün). İki değişkenli normal dağılımın eş yoğunluk konturları. Üst sol: eşit varyans ve sıfır kovaryans; üst sağ: farklı varyans ve sıfır kovaryans; alt sol: pozitif kovaryans; alt sağ: negatif kovaryans. Merkez ortalamayla, şekil ve yön Σ ile belirlenir.

Elipsler $|\rho| < 1$ altında, bir eş yoğunluk düzeyinde $z_1^2 - 2\rho z_1 z_2 + z_2^2 = c$ denklemini sağlar. $\rho > 0$ ise uzun eksen pozitif, $\rho < 0$ ise negatif eğimlidir. Standartlaştırılmış Mahalanobis biçimindeki çapraz terim, korelasyon etkisini düzeltir.

> **Kaynak satırı düzeltmesi.** Kullanıcının gönderdiği kaynak metinde elips denkleminin çapraz terimi bir satırda $+2\rho z_1 z_2$ olarak geçiyor; hemen önceki (5.11) numaralı yoğunlukla tutarlı doğru işaret $-2\rho z_1 z_2$'dir. Bu not yanlış formül öğrenilmesini önlemek için eklendi.

Tekillik, korelasyon ve alt dağılımlar

İki değişkenli normal yoğunluk iki ortalama, iki varyans ve bir korelasyon olmak üzere beş parametreye bağlıdır. Varyanslar sıfırdan büyük ve $|\rho| < 1$ ise kovaryans matrisi pozitif tanımlı ve terslenebilirdir. $\rho = \pm 1$ olduğunda değişkenler tam doğrusal ilişkilidir; gözlemler etkin olarak tek boyutlu hâle gelir. $\rho = 0$ ise normal dağılım altında değişkenler bağımsızdır ve ortak yoğunluk iki tek değişkenli yoğunluğun çarpımıdır.

Küçük $|\Sigma|$ değeri gözlemlerin ortalamaya yakın toplanmasına veya boyutlar arasında güçlü korelasyona işaret edebilir. Σ tekilse determinantı 0'dır; bunun nedeni doğrusal bağımlılık ya da bir boyutun sıfır varyanslı olması olabilir. Böyle durumda boyut azaltma gerekebilir (Bölüm 6). Eğer $x \sim \mathcal{N}_d(\mu, \Sigma)$ ise her bileşen tek değişkenli normaldir ve herhangi $k < d$ alt küme k değişkenli normaldir. Bunun tersi genel olarak doğru değildir: Her bileşenin ayrı normal dağılması, ortak dağılımın çok değişkenli normal olmasını garanti etmez.

Bağımsız bileşenlerin özel durumu

Tüm farklı i, j için $\text{Cov}(X_i, X_j) = 0$ ve bileşenler bağımsız olsun. O zaman Σ köşegendir; ortak yoğunluk bireysel yoğunlukların çarpımına ayrılır:

$$p(x) = \prod_{i=1}^{d} p_i(x_i) = \frac{1}{(2\pi)^{d/2} \prod_{i=1}^{d} \sigma_i} \exp\left[-\frac{1}{2} \sum_{i=1}^{d} \left(\frac{x_i - \mu_i}{\sigma_i}\right)^2\right]. \tag{5.12}$$

Doğrusal izdüşümler

$x \sim \mathcal{N}_d(\mu, \Sigma)$ ve $w \in \mathbb{R}^d$ olsun. $w^T x = w_1 x_1 + \cdots + w_d x_d$ tek değişkenli normaldir:

$$w^T x \sim \mathcal{N}(w^T \mu, w^T \Sigma w).$$

Bunun beklenen değeri ve varyansı şu eşitlikleri sağlar:

$$E[w^T x] = w^T E[x] = w^T \mu, \tag{5.13}$$

$$\text{Var}(w^T x) = E[(w^T (x - \mu))^2] = w^T E[(x - \mu)(x - \mu)^T] w = w^T \Sigma w. \tag{5.14}$$

W, $d \times k$ boyutlu ve rütbesi $k < d$ olan bir matris ise daha genel olarak:

$$W^T x \sim \mathcal{N}_k(W^T \mu, W^T \Sigma W). \tag{5.15}$$

Yani normal dağılımı daha düşük boyutlu uzaya yansıttığımızda ortaya çıkan dağılım da normaldir.

Çözümlü izdüşüm. $\mu = (2,3)^T$, $\Sigma = \left[\begin{smallmatrix} 1 & .5 \\ .5 & 1 \end{smallmatrix}\right]$ ve $w = (1,1)^T$ olsun. $Y = w^T x = X_1 + X_2$ için $E[Y] = 1 \cdot 2 + 1 \cdot 3 = 5$. Varyans:

$$\text{Var}(Y) = [1\ 1] \begin{bmatrix} 1 & .5 \\ .5 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = [1\ 1] \begin{bmatrix} 1.5 \\ 1.5 \end{bmatrix} = 3.$$

Bu yüzden $Y \sim \mathcal{N}(5, 3)$; ikinci parametre varyanstır.

5.5 Çok Değişkenli Sınıflandırma (Multivariate Classification)

$x \in \mathbb{R}^d$ ve sınıfa koşullu yoğunluklar $p(x \mid C_i)$, $\mathcal{N}_d(\mu_i, \Sigma_i)$ olarak modellensin. Bu durumda:

$$p(x \mid C_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i)\right]. \tag{5.16}$$

Normal yoğunluğun kullanılması öncelikle matematiksel işlenebilirliğine dayanır (Duda, Hart ve Stork, 2001). Ayrıca birçok doğal olgu, örneklerin tek bir prototip μ_i çevresinde rastgele değiştiği bir modelle yaklaşık olarak açıklanabilir. Σ_i, her değişkendeki gürültü miktarını ve gürültülerin korelasyonunu tanımlar. Gerçek veri genellikle tam normal olmasa da bu kullanışlı bir yaklaşımdır; kimi normal olmayan sapmalara dayanıklılığı da gösterilmiştir (McLachlan, 1992). Bununla birlikte bir sınıfın gözlemleri tek grup oluşturmalıdır. Aynı sınıf birden çok ayrık kümeye bölünüyorsa karışım modeli (Bölüm 7) daha uygun olabilir.

Örneğin, bir müşterinin ilgilenebileceği otomobil türünü tahmin edelim. Sınıflar otomobil türleri; özellikler müşterinin yaşı ve geliri olsun. μ_i, i türündeki otomobili satın alanların ortalama yaş ve gelirini; Σ_i ise bu grubun yaş ve gelir varyanslarını ve aralarındaki kovaryansı içerir.

Bayes tabanlı ayırt edici fonksiyon

Ayırt edici (discriminant) işlev:

$$g_i(x) = \log p(x \mid C_i) + \log P(C_i)$$

olarak tanımlanır. Normal yoğunluğu yerine koyarsak:

$$\begin{aligned} g_i(x) = &-\frac{d}{2}\log(2\pi) - \frac{1}{2}\log|\Sigma_i| \\ &-\frac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) + \log P(C_i). \end{aligned} \tag{5.17}$$

Buradaki $P(C_i)$, sınıfın **önsel olasılığıdır**. Bayes teoremine göre $P(C_i \mid x) \propto p(x \mid C_i)P(C_i)$. Logaritma artan bir işlev olduğundan, sıfır-bir kayıp altında en yüksek $g_i(x)$ değerine sahip sınıf seçilir: $\hat{C} = \arg\max_i g_i(x)$.

Sınıflara göre parametre tahmini

$K \geq 2$ sınıflı eğitim kümesinde $r_i^{(t)}$, t örneğinin C_i sınıfındaysa 1, değilse 0 olsun. Sınıf önseli, ortalama ve kovaryans için maksimum olabilirlik tahminleri:

$$\begin{aligned} \hat{P}(C_i) &= \frac{\sum_t r_i^{(t)}}{N}, \\ m_i &= \frac{\sum_t r_i^{(t)} x^{(t)}}{\sum_t r_i^{(t)}}, \\ S_i &= \frac{\sum_t r_i^{(t)}(x^{(t)}-m_i)(x^{(t)}-m_i)^T}{\sum_t r_i^{(t)}}. \end{aligned} \tag{5.18}$$

Burada yalnızca ilgili sınıfa ait gözlemler, o sınıfın m_i ve S_i değerine katkıda bulunur.

Sınıf ortalaması ve önseli. Üç "ekonomik" otomobil alıcısının (yaş, gelir bin TL) özellikleri $(20,30),(25,40),(30,50)$; üç "lüks" alıcınınki $(40,80),(45,90),(50,100)$ olsun. $N = 6$ ve her sınıfta 3 örnek bulunduğu için $\hat{P}(C_1) = \hat{P}(C_2) = 0.5$; ortalamalar $m_1 = (25,40)^T$, $m_2 =$

$(45, 90)^T$'dir. İlk sınıfta merkezlenmiş vektörler $(-5, -10), (0, 0), (5, 10)$'dur. Dolayısıyla:

$$S_1 = \frac{1}{3}\begin{bmatrix} 50 & 100 \\ 100 & 200 \end{bmatrix}.$$

Özellikler bu küçük örnekte tam doğrusal ilişkili olduğu için matris tekildir. Bu, kovaryans tahmini için hem örnek sayısının hem de özellik çeşitliliğinin neden önemli olduğunu gösterir.

Karesel ayırt edici: QDA

Tahminler işlevde kullanılıp bütün sınıflar için ortak $-d \log(2\pi)/2$ terimi çıkarılırsa:

$$g_i(x) = -\frac{1}{2}\log|S_i| - \frac{1}{2}(x - m_i)^T S_i^{-1}(x - m_i) + \log \hat{P}(C_i). \tag{5.19}$$

İkinci dereceden terim açıldığında:

$$g_i(x) = -\tfrac{1}{2}\log|S_i| - \tfrac{1}{2}\left(x^T S_i^{-1} x - 2x^T S_i^{-1} m_i + m_i^T S_i^{-1} m_i\right) + \log \hat{P}(C_i).$$

Bu **karesel ayırt edici** (quadratic discriminant) biçiminde yazılabilir:

$$g_i(x) = x^T W_i x + w_i^T x + w_{i0}, \tag{5.20}$$

$$W_i = -\frac{1}{2} S_i^{-1}, \qquad w_i = S_i^{-1} m_i,$$

$$w_{i0} = -\frac{1}{2} m_i^T S_i^{-1} m_i - \frac{1}{2}\log|S_i| + \log \hat{P}(C_i).$$

Her sınıfın farklı kovaryans matrisi olması, sınıf ayırma sınırının genellikle *eğrisel* çıkmasına izin verir. Bu yöntem **QDA** olarak bilinir.

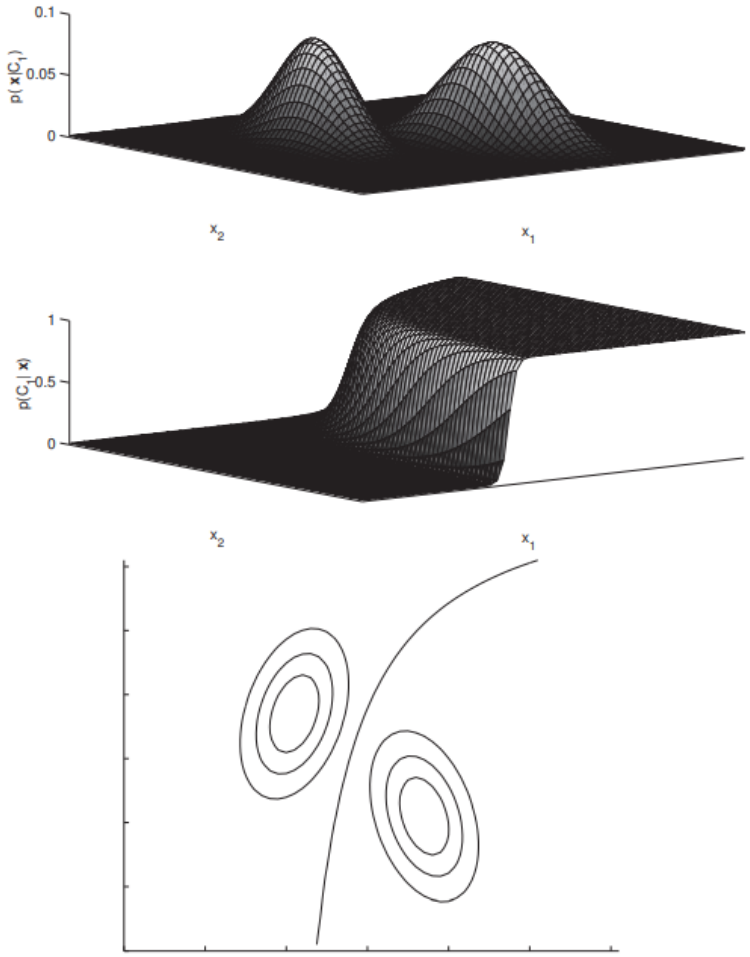


Figure 5.3 Classes have different covariance matrices. Likelihood densities and the posterior probability for one of the classes (top). Class distributions are indicated by isoprobability contours and the discriminant is drawn (bottom).

Şekil 5.3 (özgün). Sınıfların farklı kovaryans matrisleri vardır. Üstte sınıfa koşullu yoğunluklar ve bir sınıfın sonsal olasılığı; altta eş yoğunluk konturları ile karesel karar sınırı gösterilmiştir.

> **Şekli adım adım oku:** İlk yüzeyde iki tepe, iki sınıfın yoğunluklarını temsil eder. İkinci yüzey $P(C_1 \mid x)$ değerini 0 ile 1 arasında verir; 0.5 civarı iki sınıf arasında geçiştir (eşit kayıplarda). En alttaki eğik elipsler sınıf dağılımlarıdır. Eğri karar sınırı, kovaryansların sınıflara göre değişmesinin sonucudur.

Kovaryans parametreleri için $K\,d(d+1)/2$, ortalamalar için Kd sayı tahmin edilir. d büyük, sınıf örnekleri az ise S_i tekil olabilir; determinantı çok küçük olduğunda S_i^{-1} kararsızlaşabilir. Giriş özelliklerinin yeniden tasarlanması, seçilmesi veya birleştirilmesi yoluyla boyut azaltılabilir (Bölüm 6).

> **Parametre sayısı.** $K=3$, $d=10$ ise QDA'nın kovaryans parametreleri $3\times 10\times 11/2 = 165$, ortalama parametreleri $3\times 10 = 30$'dur. Sınıf önselleri için ayrıca $K-1=2$ bağımsız olasılık gerekir. Çok sayıda parametre, küçük veri kümesinde güvenilir tahmini zorlaştırabilir.

Bütün sınıflar için ortak kovaryans: LDA

Bir diğer yaklaşım, bütün sınıfların verilerini bir araya getirerek ortak kovaryans tahmin etmektir:

$$S = \sum_i \hat{P}(C_i) S_i. \tag{5.21}$$

Bu durumda sınıflandırma fonksiyonu:

$$g_i(x) = -\frac{1}{2}(x - m_i)^T S^{-1}(x - m_i) + \log \hat{P}(C_i). \tag{5.22}$$

Ortalama parametre sayısı yine Kd, ancak kovaryans için yalnızca $d(d+1)/2$ parametre bulunur. Önsel olasılıklar eşitse Mahalanobis uzaklığı en küçük olan sınıf seçilir. Önsel olasılıkları farklıysa sınır, daha az olası sınıfa doğru kayar. Tüm sınıflarda ortak olan $x^T S^{-1} x$ karesel terimi karşılaştırmadan kaldırılabildiğinden ayırt edici işlev *doğrusal* olur:

$$g_i(x) = w_i^T x + w_{i0}, \qquad w_i = S^{-1} m_i, \quad w_{i0} = -\frac{1}{2} m_i^T S^{-1} m_i + \log \hat{P}(C_i). \tag{5.23}$$

Bu yöntem **LDA** olarak adlandırılır. Karar bölgeleri konvekstir: Bir bölgenin iki noktasını birleştiren doğru parçası bütünüyle o bölgede kalır.

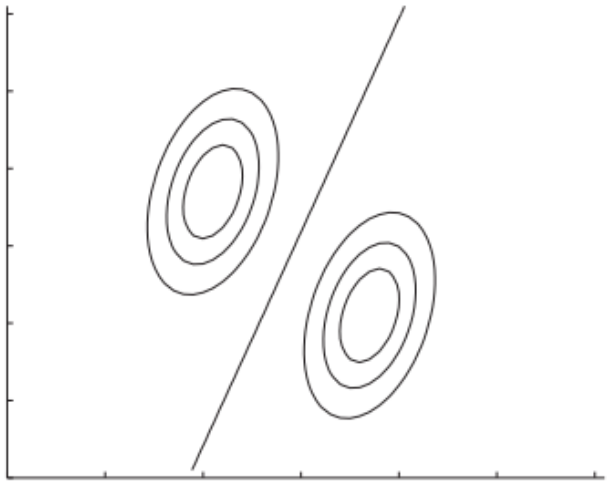
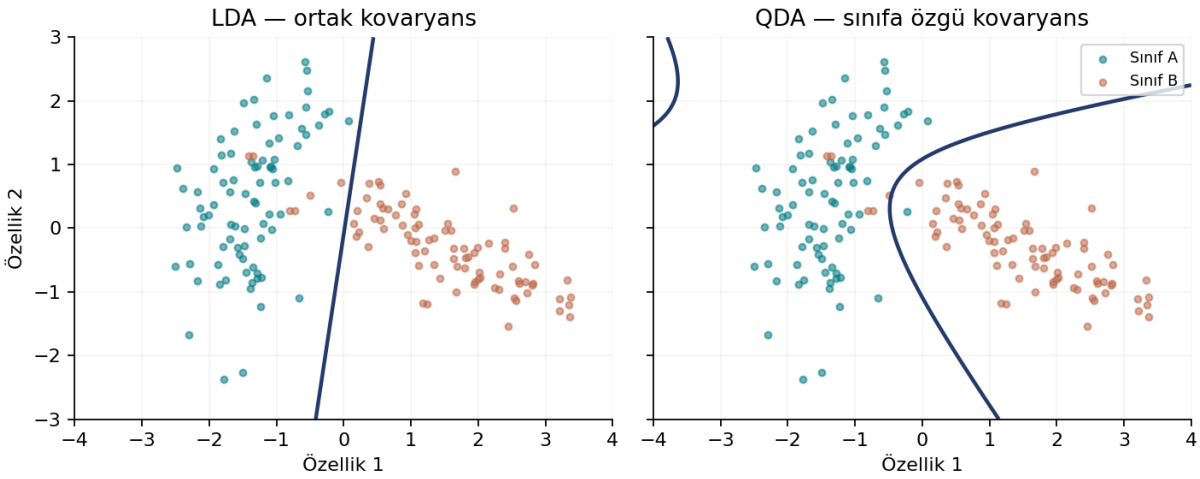


Figure 5.4 Covariances may be arbitary but shared by both classes.

Şekil 5.4 (özgün). Kovaryans matrisinin biçimi serbest olabilir, ancak iki sınıf onu ortak kullanır. Konturlar aynı yönlü ve aynı biçimlidir; karar sınırı doğrusaldır.

> **Neden doğru?.** İki sınıf için $g_1(x) = g_2(x)$ eşitliği, ortak kovaryans sayesinde $(w_1 - w_2)^T x + (w_{10} - w_{20}) = 0$ biçimindedir. İki boyutta bu bir doğru, daha yüksek boyutta bir hiperdüzlemdir.



Ek grafik. Aynı örnek veri üzerinde ortak kovaryans (LDA) doğrusal, sınıfa özgü kovaryans (QDA) eğrisel karar sınırı üretebilir.

Adım adım karar hesabı. $m_1 = (1,3)^T$, $m_2 = (3,1)^T$, $S = I$ ve gözlem $x = (1.5, 2.5)^T$ olsun. Karesel Mahalanobis uzaklıkları $D_1^2 = (.5)^2 + (-.5)^2 = .5$ ve $D_2^2 = (-1.5)^2 + (1.5)^2 = 4.5$'tir. Önsel olasılıklar eşitse C_1 seçilir. Ancak $P(C_1) = .1$, $P(C_2) = .9$ olsaydı $g_1 = -.25 + \log(.1) \simeq -2.553$ ve $g_2 = -2.25 + \log(.9) \simeq -2.355$ olduğundan C_2 seçilirdi. *Önsel olasılıklar sınırı kaydırabilir.*

Köşegen ortak kovaryans: bağımsız özellikler

Kovaryans matrisinin köşegen dışındaki tüm elemanlarını 0 kabul edersek, normal dağılım modeli altında sınıfa koşullu bağımsızlık varsayarız. Bu, özellik başına tek değişkenli Gaussian kullanan Naive Bayes yaklaşımının basitleştirilmiş bir biçimidir. Ortak köşegen S için:

$$g_i(x) = -\frac{1}{2}\sum_{j=1}^{d}\left(\frac{x_j - m_{ij}}{s_j}\right)^2 + \log \hat{P}(C_i). \tag{5.24}$$

$\frac{x_j - m_{ij}}{s_j}$ farkı standart sapma cinsinden ölçer. Geometrik olarak yoğunluk konturları eksenlere paralel elipsoiddir. Kovaryans için d parametre gerekir: $O(d^2)$ yerine $O(d)$ karmaşıklık elde edilir.

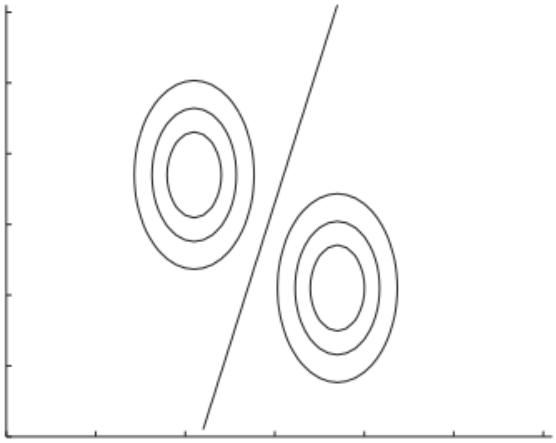


Figure 5.5 All classes have equal, diagonal covariance matrices, but variances are not equal.

Şekil 5.5 (özgün). Sınıflar ortak, köşegen kovaryans matrisine sahiptir; eksenlerdeki varyanslar farklıdır. Bu yüzden elipsler eksenlere paraleldir, fakat daire değildir.

> **Kapsam notu:** Kaynağın (5.24) modeli ortak köşegen kovaryans kullanır. Genel Gaussian Naive Bayes'te sınıfa göre farklı köşegen varyanslar öğrenilebilir; o genel biçimin karar sınırı mutlaka doğrusal değildir.

Eşit varyans: en yakın ortalama sınıflandırıcısı

Tüm özellik varyanslarını eşit varsayarsak $S = s^2 I$ olur ve Mahalanobis uzaklığı, ortak ölçek katsayısı dışında Öklid uzaklığına iner. Yoğunluk konturları merkez m_i çevresinde küreseldir. $|S| = s^{2d}$ ve $S^{-1} = I/s^2$ olduğundan:

$$g_i(x) = -\frac{\|x - m_i\|^2}{2s^2} + \log \hat{P}(C_i) = -\frac{1}{2s^2}\sum_{j=1}^{d}(x_j - m_{ij})^2 + \log \hat{P}(C_i). \tag{5.25}$$

Ortalamalar için Kd ve ortak varyans için tek parametre yeterlidir. Önsel olasılıklar eşitse en yüksek g_i değeri *en yakın sınıf ortalamasına* karşılık gelir. Sınıf ortalaması bir şablon/prototip sayılırsa bu **şablon eşleştirme (template matching)** olarak düşünülebilir.

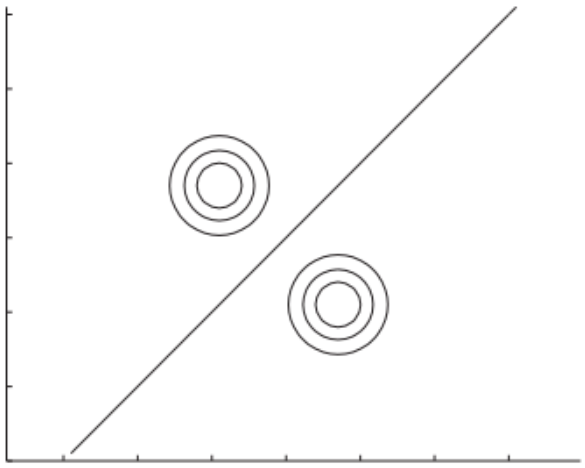


Figure 5.6 All classes have equal, diagonal covariance matrices of equal variances on both dimensions.

Şekil 5.6 (özgün). Bütün sınıflarda köşegen, ortak ve her boyutta eşit varyans bulunur: $S = s^2 I$. Daire biçimli konturlar ve doğrusal karar sınırı elde edilir.

Eşit önselde ortak ölçek kaldırılarak:

$$g_i(x) = -\|x - m_i\|^2 = -(x - m_i)^T(x - m_i) = -(x^T x - 2m_i^T x + m_i^T m_i). \tag{5.26}$$

Bütün sınıflarda aynı $x^T x$ terimi kaldırılıp kalan ifade pozitif $1/2$ katsayısıyla ölçeklenirse:

$$g_i(x) = w_i^T x + w_{i0}, \qquad w_i = m_i, \quad w_{i0} = -\frac{1}{2}\|m_i\|^2. \tag{5.27}$$

Ortalamaların normları yeterince yakın olduğunda bu sabit terim de yaklaşık ihmal edilip $m_i^T x$ benzerliği kullanılabilir:

$$g_i(x) = m_i^T x. \tag{5.28}$$

En yakın merkez hesabı. $m_1 = (2,3)^T$, $m_2 = (8,7)^T$ ve $x = (3,4)^T$ olsun. $D_1 = \sqrt{(3-2)^2 + (4-3)^2} = \sqrt{2} \simeq 1.41$. $D_2 = \sqrt{(3-8)^2 + (4-7)^2} = \sqrt{34} \simeq 5.83$. C_1 seçilir. Öğrencilerden, önsel olasılıkların çok farklı olması durumunda hangi ek bilginin gerektiğini düşünmelerini isteyebilirsiniz.

Uzaklık öğrenmeye geçiş

En iyi ayırt edici fonksiyonu bulma görevi, uygun uzaklık işlevini bulma olarak da düşünülebilir. x_1 ve x_2 aynı sınıftayken x_1 ve x_3 farklı sınıftaysa arzu edilen özellik:

$$D(x_1, x_2) < D(x_1, x_3).$$

Bu bakış açısı, sınıflandırmayı benzerlik/uzaklık öğrenme problemi olarak yeniden ifade eder.

5.6 Model Karmaşıklığının Ayarlanması (Tuning Complexity)

Tablo 5.1, kovaryans için farklı varsayımlarla parametre sayısının nasıl azaltıldığını özetler. Sadelik ve model esnekliği arasında bir ödünleşim vardır. Kısıtlar artırılınca tahmin edilecek parametre sayısı düşer ama yanlılık artabilir. Kısıtlar kaldırılınca karesel ayırt edici model özellikle az veride yüksek varyans gösterebilir. Seçim veri miktarına ve problemin güçlüğüne bağlıdır.

Varsayım	Kovaryans biçimi	Parametre
Ortak, küresel	$S_i = S = s^2 I$	1
Ortak, eksen hizalı	$S_i = S$, köşegen dışı 0	d
Ortak, elipsoidal	$S_i = S$	$d(d+1)/2$
Farklı, elipsoidal	Her sınıfta ayrı S_i	$K\,d(d+1)/2$

Tablo 5.1 (çeviri). Kovaryans hakkında basitleştirici varsayımlarla parametre sayısının azaltılması. Ortalamaların Kd parametresi tabloya dahil değildir.

Küçük örneklemde sınıfların gerçek kovaryansları farklı bile olsa ortak bir kovaryans varsayımı bazen daha iyi genelleme verir: Daha az parametre, bütün sınıfların verisiyle tahmin edilir. Bu durum doğrusal ayırt edicilere karşılık gelir ve Bölüm 10'da ayrıca ele alınır.

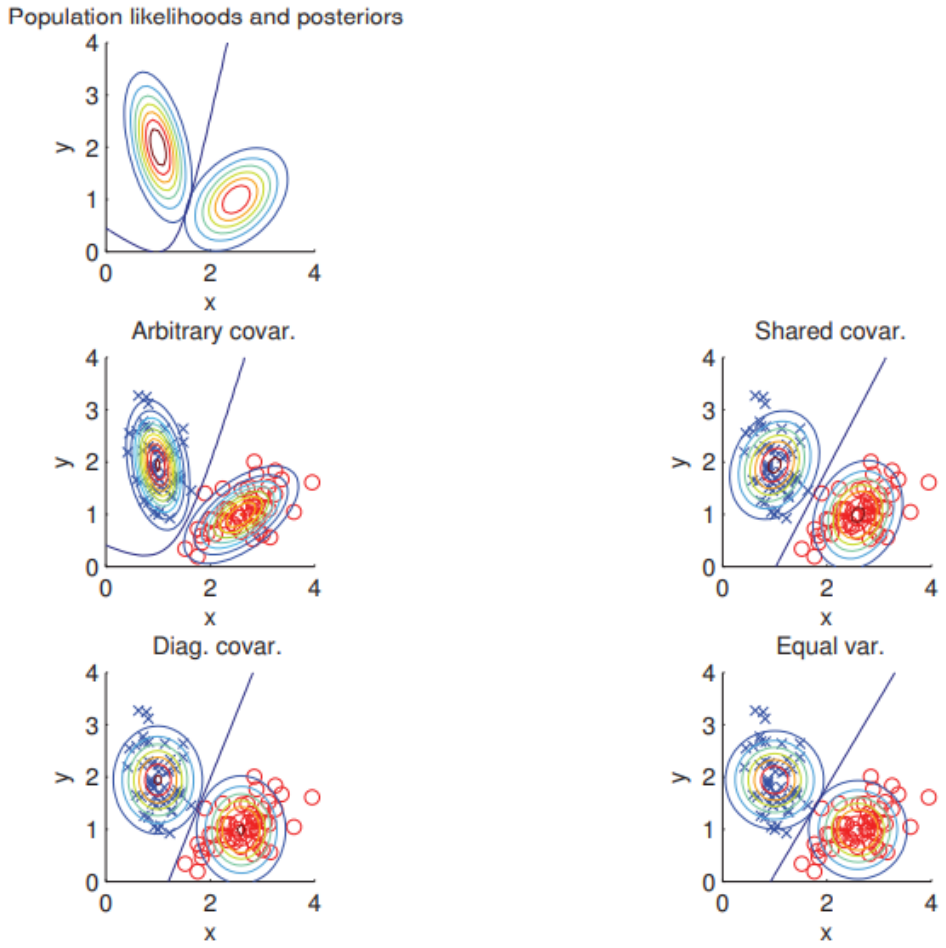


Figure 5.7 Different cases of the covariance matrices fitted to the same data lead to different boundaries.

Şekil 5.7 (özgün). Aynı veriye farklı kovaryans varsayımları uydurulunca karar sınırları değişir. Üst: anakütlenin koşullu yoğunlukları ve sonsal olasılıkları. Alt sol: serbest kovaryans; alt sağ: ortak kovaryans; en alt sol: köşegen kovaryans; en alt sağ: eşit varyans.

> **Şekil 5.7'nin dersi.** Serbest kovaryans (QDA) eğrisel sınır üretebilir; ortak kovaryans (LDA) doğrusal sınır verir; ortak köşegen kovaryans dağılımların eksenlerini koordinatlarla hizalar; ortak ve eşit varyans ise dairesel konturlar oluşturur. Bunlar aynı veri için birbirinden farklı yaklaşımlardır. Daha karmaşık sınırın mutlaka daha iyi test başarısı sağlayacağı söylenemez.

Öklid uzaklığına gizli varsayımlar ve standartlaştırma

Benzerliği Öklid uzaklığıyla ölçmek, bu Gauss modeli çerçevesinde bağımsız ve eşit varyanslı özellikler varsaymakla ilişkilidir. Gerçekte yaş ve yıllık gelir gibi değişkenler farklı birimlerde ve bağımlı olabilir. Bu durumda her girdi $z = (x - \mu)/\sigma$ dönüşümüyle sıfır ortalama ve birim varyansa çekildikten sonra Öklid uzaklığı kullanılabilir. Ancak *z-normalizasyonu korelasyonu yok etmez*. Bağımlılığı güvenilir öğrenmeye yetecek veri olmadığında gerçek özellikler bağımlı bile olsa Naive Bayes faydalı olabilir.

Regularized Discriminant Analysis (RDA)

Friedman (1989), farklı kovaryans özel durumlarını ağırlıklı olarak birleştiren **düzenlileştirilmiş ayırt edici analiz** yaklaşımını önerir. Düzenlileştirme, yüksek varyanslı bir modeli daha güçlü kısıtlarla düşük varyansa çeker; bunun karşılığında yanlılık artabilir. Yeni kovaryans:

$$S_i' = \alpha s^2 I + \beta S + (1-\alpha-\beta) S_i. \tag{5.29}$$

Ağırlıkların negatif olmaması için $\alpha \geq 0$, $\beta \geq 0$, $\alpha + \beta \leq 1$ alınır. Özel durumlar:

- $\alpha = \beta = 0$: $S_i' = S_i$, **QDA**.
- $\alpha = 0$, $\beta = 1$: $S_i' = S$, **LDA**.
- $\alpha = 1$, $\beta = 0$: $S_i' = s^2 I$, **en yakın ortalama**.

Bu uç noktalar arasında başka modeller vardır; α ve β çapraz doğrulamayla seçilebilir. Bir başka düzenlileştirme yaklaşımı μ_i ve S_i üzerine Bayesçi önseller tanımlamak, ya da Tablo 5.1'deki dört seçenek arasından çapraz doğrulamayla en iyisini belirlemektir.

RDA sayısal örneği. $S_i = \left[\begin{smallmatrix} 4 & 2 \\ 2 & 9 \end{smallmatrix}\right]$, $S = \left[\begin{smallmatrix} 5 & 1 \\ 1 & 5 \end{smallmatrix}\right]$, $s^2 I = \left[\begin{smallmatrix} 4 & 0 \\ 0 & 4 \end{smallmatrix}\right]$ ve $\alpha = 0.2$, $\beta = 0.3$ olsun. Üçüncü ağırlık 0.5'tir. Böylece:

$$\begin{aligned} S_i' &= 0.2 \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} + 0.3 \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix} + 0.5 \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \\ &= \begin{bmatrix} 0.8 & 0 \\ 0 & 0.8 \end{bmatrix} + \begin{bmatrix} 1.5 & .3 \\ .3 & 1.5 \end{bmatrix} + \begin{bmatrix} 2 & 1 \\ 1 & 4.5 \end{bmatrix} = \boxed{\begin{bmatrix} 4.3 & 1.3 \\ 1.3 & 6.8 \end{bmatrix}}. \end{aligned}$$

Yeni matris, sınıfa özgü bilgi ve daha basit varsayımları birleştirir.

5.7 Ayrık Özellikler (Discrete Features)

Bazı uygulamalarda bir nitelik n farklı değerden birini alır: Renk $\in$ {kırmızı, mavi, yeşil, siyah}; bir piksel $\in$ {açık, kapalı} olabilir. Önce x_j'nin ikili (Bernoulli) değişken olduğu durumu ele alalım:

$$p_{ij} \equiv p(x_j = 1 \mid C_i).$$

Bu değer, sınıf C_i verildiğinde j özelliğinin 1 olma olasılığıdır. İkili değişkenler sınıfa koşullu bağımsızsa:

$$p(x \mid C_i) = \prod_{j=1}^{d} p_{ij}^{x_j} (1 - p_{ij})^{1-x_j}.$$

Bu da **Naive Bayes** modelinin, koşullu yoğunluklar Bernoulli iken elde edilen özel durumudur. Logaritmalı ayırt edici:

$$\begin{aligned} g_i(x) &= \log p(x \mid C_i) + \log P(C_i) \\ &= \sum_j [x_j \log p_{ij} + (1 - x_j) \log(1 - p_{ij})] + \log P(C_i). \end{aligned} \tag{5.30}$$

Bu ifade x'e göre doğrusaldır. Parametre tahmini:

$$\hat{p}_{ij} = \frac{\sum_t x_j^{(t)} r_i^{(t)}}{\sum_t r_i^{(t)}}. \tag{5.31}$$

Yani i sınıfındaki gözlemlerden kaçında j özelliğinin 1 olduğu sayılır ve o sınıfın örnek sayısına bölünür.

Spam e-postası örneği. x_1 e-postada "bedava", x_2 "ödül" kelimesinin geçmesi olsun. Öğrenilen değerler:

	Spam	Normal
$P(x_1 = 1 \mid C)$	0.80	0.10
$P(x_2 = 1 \mid C)$	0.60	0.05
$P(C)$	0.40	0.60

İki kelimeyi de içeren yeni e-posta için $x = (1, 1)$:

$$p(x \mid Spam)P(Spam) = 0.8 \cdot 0.6 \cdot 0.4 = 0.192,$$

$$p(x \mid Normal)P(Normal) = 0.1 \cdot 0.05 \cdot 0.6 = 0.003.$$

$Spam$ seçilir; bu iki sınıflı örnekte $P(Spam \mid x) = 0.192/(0.192+0.003) \simeq 0.9846$ bulunur. Bu sayı gerçek dünyada garantili güvenilirlik değil, örneğin model varsayımlarından doğan tahmindir.

Belge sınıflandırma ve kelime çantası

Bu yaklaşım **belge sınıflandırmada** kullanılır: Haberlerin politika, spor, moda vb. kategorilere ayrılması buna örnektir. **Bag of Words (kelime çantası)** yaklaşımında, sınıflar hakkında bilgi taşıyacağı düşünülen d kelime önceden seçilir (Manning ve Schütze, 1999). Haberlerde "füze", "atlet" ve "moda tasarımı" gibi kelimeler; "model" gibi belirsiz anlamlı sözcüklere göre bazı sınıflar için daha açıklayıcı olabilir.

Her belge d boyutlu ikili vektöre dönüştürülür: Kelime j varsa $x_j = 1$, yoksa 0. Bu gösterim sözcüklerin sıralamasını kaybeder; adı da buradan gelir. Öğrenilen $\hat{p}_{ij}$, j kelimesinin i belge

sınıfında bulunma olasılığını gösterir. Bir kelime tüm sınıflarda benzer olasılıkla geçiyorsa ayırt ediciliği düşüktür; yararlı kelimeler bazı sınıflarda yüksek, diğerlerinde düşük olasılıkla görülür. Özellik seçimi Bölüm 6'da anlatılacaktır.

Belge sınıflandırmanın başka örneği spam ile meşru e-postayı ayırmaktır. Biyoinformatikte DNA baz çiftleri ve amino asit dizileri de ayrık sembol dizileridir.

Bag of Words. Sözlük $V = \{\text{futbol, seçim, ekonomi}\}$ olsun. "Futbol ekonomisi büyüyor" cümlesi $x = (1, 0, 1)$; "Seçim ve ekonomi tartışıldı" cümlesi $x = (0, 1, 1)$ ile gösterilir. "Ekonomi seçimleri etkiliyor" ile "Seçimleri ekonomi etkiliyor" aynı ikili vektöre dönüşebilir; kelime sırası kaybolmuştur.

İkiden fazla kategori: gösterge değişkenleri

x_j özelliği $\{v_1, v_2, \ldots, v_{n_j}\}$ kümesinden bir değer alsın. Her olası değer için 0/1 gösterge tanımlarız:

$$z_{jk}^{(t)} = \begin{cases} 1, & x_j^{(t)} = v_k, \\ 0, & \text{aksi halde.} \end{cases}$$

C_i sınıfına ait bir gözlemde x_j'nin v_k değerini alma olasılığı:

$$p_{ijk} \equiv p(z_{jk} = 1 \mid C_i) = p(x_j = v_k \mid C_i).$$

Özelliklerin birbirinden sınıfa koşullu bağımsız olduğu durumda:

$$p(x \mid C_i) = \prod_{j=1}^{d} \prod_{k=1}^{n_j} p_{ijk}^{z_{jk}}. \tag{5.32}$$

Logaritmalı ayırt edici fonksiyon:

$$g_i(x) = \sum_j \sum_k z_{jk} \log p_{ijk} + \log P(C_i). \tag{5.33}$$

Maksimum olabilirlik tahmini:

$$\hat{p}_{ijk} = \frac{\sum_t z_{jk}^{(t)} r_i^{(t)}}{\sum_t r_i^{(t)}}. \tag{5.34}$$

Bu değer (5.33)'e yerleştirilerek sınıflandırma yapılır.

One-hot kodlama. Renk kategorileri kırmızı, mavi, yeşil ve siyah ise sırasıyla $(1,0,0,0)$, $(0,1,0,0)$, $(0,0,1,0)$ ve $(0,0,0,1)$ vektörleri kullanılır. Her satırda yalnızca bir değer 1'dir. Farklı başlangıç özellikleri koşullu bağımsız varsayılabilir; *aynı kategorik değişkenin one-hot sütunları* ise birbirinden bağımsız değildir.

5.8 Çok Değişkenli Regresyon (Multivariate Regression)

Çok değişkenli doğrusal regresyonda sayısal çıktı r, birden fazla girdinin ağırlıklı toplamı ve gürültüyle açıklanır. İstatistik terminolojisinde *multiple regression* çoğu kez çok girişli tek çıktılı model, *multivariate regression* ise birden çok çıktılı regresyon için kullanılır. Kitabın kullandığı doğrusal model:

$$\begin{aligned} r^{(t)} &= g(x^{(t)} \mid w_0, w_1, \ldots, w_d) + \epsilon \\ &= w_0 + w_1 x_1^{(t)} + w_2 x_2^{(t)} + \cdots + w_d x_d^{(t)} + \epsilon. \end{aligned} \tag{5.35}$$

Burada w_0 sabit, w_j özellik katsayısı ve ϵ rastgele hatadır.

Sayısal tahmin. Öğrenci notu için $\hat{y} = 10 + 5x_1 + 0.3x_2 + 2x_3$ modeli olsun. $x_1 = 6$ saat çalışma, $x_2 = 80$ devam yüzdesi ve $x_3 = 4$ ödev ise $\hat{y} = 10 + 5(6) + 0.3(80) + 2(4) = 72$'dir. Gerçek değer 75 ise hata $r - \hat{r} = 3$ olur.

Normal gürültü varsayımı ve kareler toplamı

Tek değişkenli modeldeki gibi hatanın sıfır ortalamalı, sabit varyanslı ve normal dağılımlı olduğu kabul edilir. Bu varsayım altında olabilirliği maksimum yapmak, kareli hata toplamını minimum yapmakla eşdeğerdir:

$$E(w_0, w_1, \ldots, w_d \mid X) = \frac{1}{2} \sum_t \left(r^{(t)} - w_0 - \sum_{j=1}^{d} w_j x_j^{(t)} \right)^2. \tag{5.36}$$

Başındaki $1/2$ türev almayı kolaylaştırır. **MSE** ise $\text{MSE} = N^{-1} \sum_t (r^{(t)} - \hat{r}^{(t)})^2$; dolayısıyla $E = (N/2)\,\text{MSE}$'dir. Her iki hedefin en küçük olduğu katsayılar aynıdır.

Normal denklemlerin türetilmesi

w_j katsayılarına göre türev alıp sıfıra eşitleyince normal denklemler oluşur. Sabit terime ilişkin denklem:

$$\sum_t r^{(t)} = N w_0 + w_1 \sum_t x_1^{(t)} + w_2 \sum_t x_2^{(t)} + \cdots + w_d \sum_t x_d^{(t)}. \tag{5.37}$$

Her $j = 1, \ldots, d$ için:

$$\sum_t x_j^{(t)} r^{(t)} = w_0 \sum_t x_j^{(t)} + \sum_{k=1}^{d} w_k \sum_t x_j^{(t)} x_k^{(t)}.$$

Böylece $d + 1$ bilinmeyen katsayı için $d + 1$ denklem elde edilir.

Matris gösterimi ve kapalı form çözüm

Sabit terimi içerme amacıyla tasarım matrisinin ilk sütununu 1'lerden oluştururuz:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(N)} & x_2^{(N)} & \cdots & x_d^{(N)} \end{bmatrix}, \quad w = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix}, \quad r = \begin{bmatrix} r^{(1)} \\ r^{(2)} \\ \vdots \\ r^{(N)} \end{bmatrix}.$$

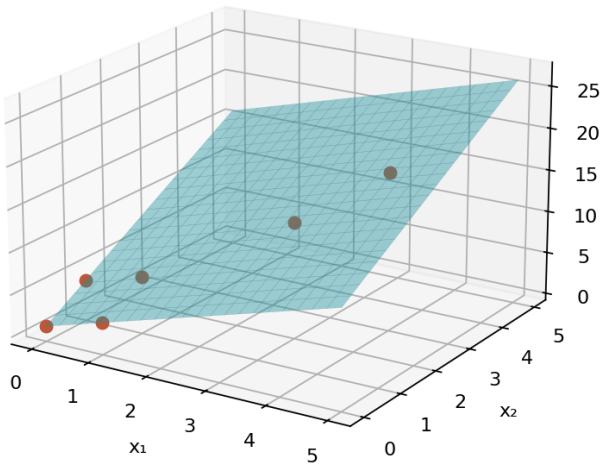
Normal denklemler topluca:

$$X^T X w = X^T r. \tag{5.38}$$

X^TX terslenebilir olduğunda parametre çözümü:

$$w = (X^TX)^{-1}X^Tr. \tag{5.39}$$

Bu, tek özellikli polinom regresyonunda kullandığımız yöntemle aynıdır. Doğrusal cebir araçları bütün parametreleri birlikte hesaplamayı sağlar.



Ek çizim. $\hat{y} = 1 + 2x_1 + 3x_2$ iki girişli regresyonunun tahmin düzlemi. Kırmızı noktalar düzlem üzerindeki örnek gözlemlerdir.

Tam çözüm: Normal denklem yöntemi. Dört örnekte iki özellik ve sayısal hedef olsun:

Gözlem	x_1	x_2	r
1	0	0	1
2	1	0	3
3	0	1	4
4	1	1	6

Adım 1. Model $\hat{r} = w_0 + w_1x_1 + w_2x_2$ ve tasarım matrisi:

$$X = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \quad r = \begin{bmatrix} 1 \\ 3 \\ 4 \\ 6 \end{bmatrix}.$$

Adım 2. X^TX ve X^Tr çarpımlarını hesaplayalım:

$$X^TX = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{bmatrix}, \qquad X^Tr = \begin{bmatrix} 14 \\ 9 \\ 10 \end{bmatrix}.$$

İlk eleman 4, birler sütununun kendisiyle çarpımından; sağdaki 14 ise $1+3+4+6$ toplamından gelir.

Adım 3. Doğrusal denklemleri yazalım:

$$\begin{cases} 4w_0 + 2w_1 + 2w_2 = 14, \\ 2w_0 + 2w_1 + w_2 = 9, \\ 2w_0 + w_1 + 2w_2 = 10. \end{cases}$$

İkinci denklemi 2 ile çarpıp ilkini çıkarınca $2w_1 = 4 \Rightarrow w_1 = 2$ elde edilir. Üçüncüyü 2 ile çarpıp ilkini çıkarınca $2w_2 = 6 \Rightarrow w_2 = 3$ bulunur. Bunları birinci denklemde yerine koyarsak $4w_0 + 4 + 6 = 14$, yani $w_0 = 1$ olur.

Adım 4. Sonuç:

$$\boxed{\hat{r} = 1 + 2x_1 + 3x_2}.$$

Tahminler sırasıyla $(1, 3, 4, 6)$'dır; bu küçük gürültüsüz eğitim kümesinde bütün hata terimleri 0 ve MSE=0'dır. Gerçek hayatta böyle kusursuz uyum genellikle beklenmez.

Sayısal çözüm notu. X^TX tekilse $(X^TX)^{-1}$ yoktur. Pratik uygulamada QR/SVD ayrışımları, pseudoinverse veya düzenlileştirme ile kararlı en küçük kareler çözümleri bulunabilir. Normal denklem, kavramı öğrenmek açısından önemlidir; büyük problemler için ters matrisi açıkça hesaplamak zorunlu değildir.

Polinom ve taban fonksiyonları

Tek girişli polinom regresyonu $x_1 = x$, $x_2 = x^2, \ldots, x_k = x^k$ biçiminde yeni özellikler tanımlanarak aynı doğrusal cebir hesabına dönüştürülebilir. Çok değişkenli regresyonda özellikle d büyükken yüksek dereceli polinomlar seyrek kullanılır.

Üs almak tek seçenek değildir: Sinüs veya üstel dönüşümler gibi taban fonksiyonları kullanılabilir. Örneğin $\phi_1(x) = \sin x$, $\phi_2(x) = e^{x^2}$ ile:

$$\hat{y} = w_0 + w_1 \sin x + w_2 e^{x^2}$$

oluşturulabilir. Orijinal x uzayında doğrusal olmayan bu model, yeni özellikler ϕ_1, ϕ_2 açısından doğrusal kalır. Yapılacak işlem, X'i bu dönüşümlerle genişletilmiş tasarım matrisiyle değiştirmektir. Bu tür doğrusal model genellemeleri çok katmanlı algılayıcılar, destek vektör makineleri ve Gaussian süreçleri gibi konularla bağlantılıdır.

Katsayıların yorumu ve birden fazla çıktı

Doğrusal regresyonun avantajlarından biri w_j katsayılarının bilgi vermesidir. İşaretleri, diğer girdiler sabitken özellik ile tahmin arasındaki pozitif veya negatif ilişkiyi gösterir. Özellikler aynı aralıkta/ölçekteyse $|w_j|$ değerleri göreli önem hakkında ipucu verir ve küçük katsayılı bazı özellikler çıkarılabilir. Bununla birlikte katsayıların nedensellik kanıtı olmadığı ve korelasyonlu özelliklerde önem yorumunun güçleşebileceği unutulmamalıdır.

Birden fazla çıktı varsa model, her çıktı için ayrı tek çıktılı regresyon problemleriyle eşdeğer şekilde kurulabilir. Örneğin aynı öğrenci girdilerinden matematik, fizik ve programlama notları için üç ayrı doğrusal model eğitilebilir.

Kavram Sözlüğü ve Hızlı Karşılaştırma

Terim	Kısa açıklama
Feature / Özellik	Her gözlemin bir ölçümü, yani veri matrisinin sütunu.
Mean vector	Her boyutun ortalamasını içeren vektör μ.
Variance / Varyans	Bir değişkenin ortalama çevresindeki yayılımı.
Covariance / Kovaryans	İki değişkenin birlikte doğrusal değişimi.
Correlation / Korelasyon	Ölçekten bağımsız, $[-1, 1]$ aralığındaki doğrusal ilişki.
Covariance matrix	Varyans ve kovaryansları birlikte saklayan simetrik matris.
Imputation	Eksik değerlerin tahmin edilerek doldurulması.
Gaussian distribution	Ortalama ve kovaryansla tanımlanan normal olasılık yoğunluğu.
Mahalanobis distance	Ölçek ve kovaryans yapısını kullanan uzaklık.
Prior / Önsel	Gözlem görülmeden önceki sınıf olasılığı.
Posterior / Sonsal	Gözlem görüldükten sonraki sınıf olasılığı.
Discriminant	Sınıf puanı veren karar fonksiyonu.
QDA	Sınıflara özel genel kovaryans; çoğunlukla eğrisel sınır.
LDA	Ortak genel kovaryans; doğrusal sınır.
Naive Bayes	Özelliklerin sınıfa koşullu bağımsızlığını varsayar.
RDA	Kovaryans biçimleri arasında düzenlileştirilmiş geçiş.
Bag of Words	Belgeyi kelimelerin varlığı/yokluğu ile temsil eden vektör.
Basis function	Ham girdiyi yeni, potansiyel olarak doğrusal olmayan özelliğe dönüştüren fonksiyon.
Normal equations	En küçük kareler için $X^T X w = X^T r$ sistemi.

Yöntem	Varsayım	Karar geometrisi
QDA	Her sınıfta farklı tam kovaryans	Genellikle eğrisel
LDA	Ortak tam kovaryans	Doğrusal
Ortak köşegen	Ortak, bağımsız bileşenler	Eksenlerle hizalı elipsler; doğrusal sınır
En yakın ortalama	Ortak $s^2 I$	Dairesel yoğunluk; doğrusal sınır
Bernoulli NB	İkili, koşullu bağımsız	Log olasılıklı doğrusal puan
Çoklu regresyon	Sayısal çıktı, doğrusal ağırlıklar	Doğru/düzlem/hiperdüzlem

Ders İçin Tekrar Soruları ve Kısa Yanıtlar

1. $N \times d$ **veri matrisi neyi temsil eder?** N bağımsız gözlemi ve d girdi özelliğini temsil eder. Satırlar örnek, sütunlar özelliktir.
2. **Kovaryans sıfırsa değişkenler bağımsız mıdır?** Genel olarak hayır. Doğrusal olmayan bağımlılık olabilir. İki değişkenli ortak normal dağılımda ise sıfır korelasyon bağımsızlık anlamına gelir.
3. **Kovaryans matrisinde köşegen neden özeldir?** $\text{Cov}(X_i, X_i) = \text{Var}(X_i)$; bu yüzden köşegen varyansları gösterir.
4. **Mahalanobis neden Öklid'den farklıdır?** Her özelliğin yayılımını ve özellikler arası korelasyonu Σ^{-1} ile hesaba katar.
5. **Elips ne zaman daire olur?** İki boyutlu normal dağılımda $\Sigma = s^2 I$ olduğunda bütün yönlerde varyans eşittir.
6. **QDA neden LDA'dan daha karmaşıktır?** QDA K ayrı genel kovaryans tahmin eder; LDA tek ortak genel kovaryans tahmin eder.
7. **LDA neden düz karar sınırı üretir?** Ortak kovaryans nedeniyle sınıflar arasında aynı $x^T S^{-1} x$ karesel terimi iptal olur.
8. **Küçük veride basit model neden üstün olabilir?** Az parametre daha kararlı tahmin anlamına gelebilir; yüksek karmaşıklık aşırı öğrenmeye yol açabilir.
9. **Bag of Words'un temel bilgi kaybı nedir?** Sözcük sırası ve sözdizimsel ilişkiler korunmaz.
10. **Regresyonda neden X matrisine 1 sütunu eklenir?** Sabit terim w_0'ı diğer katsayılarla birlikte matris çarpımında temsil etmek için.
11. $X^T X$ **tekilse ne yapılabilir?** Pseudoinverse, QR/SVD ya da düzenlileştirme gibi yöntemler kullanılabilir.
12. **Z-normalizasyonu korelasyonu yok eder mi?** Hayır. Yalnızca her özelliği sıfır ortalama ve birim standart sapmaya dönüştürür.

> **Ünitenin ana mesajı**
> Verinin merkezini μ, yayılım ve birlikte değişimini Σ tanımlar. Çok değişkenli normal dağılım bu iki yapı üzerinde kurulur. Sınıflandırma modelinin karmaşıklığı büyük ölçüde kovaryans için yapılan varsayımlarla yönetilir; QDA, LDA ve en yakın ortalama sınıflandırıcısı bunun özel durumlarıdır. Ayrık özelliklerde Bernoulli/kategorik Naive Bayes kullanılır. Sürekli bir çıktıyı tahmin ederken çoklu doğrusal regresyon, parametreleri en küçük kareler yoluyla öğrenir.

Kaynak ve kapsam notu: Ethem Alpaydın, *Introduction to Machine Learning*, MIT Press (2014), Bölüm 5.1–5.8 (kullanıcının paylaştığı metinler, s. 93–111). Kitap Şekil 5.1–5.7 görselleri kullanıcı tarafından sağlanmıştır; diğer grafikler bu ders notu için üretilmiştir. Örnekler ve öğretim notları kaynak metne ek anlatımdır. Kaynakta yalnızca kısmi denklem yazımı ya da dizgi sorunu bulunan yerler matematiksel anlamı koruyacak biçimde düzenlenmiştir.