

ÜNİTE 2

Denetimli Öğrenme

Supervised Learning

Türkçe çeviri, formüllerin açıklamaları, orijinal şekiller ve çözümlü alıştırmalar

2.1-2.8

Konu anlatımı

13

Şekil numarası
(2.11 yeniden çizildi)

11

Çözümlü alıştırma

Kaynak: Ethem Alpaydın, *Introduction to Machine Learning*, MIT Press (2014), Bölüm 2.
Hazırlanma tarihi: Eylül 2026

Bu PDF nasıl düzenlendi?

Bu belge, sohbet içinde sağlanan üç bölüm metninin (2.1–2.8) ve ayrıca paylaşılan 2.10 Alıştırmalar metninin Türkçe çevirisini bir araya getirir. Gönderilen Şekil 2.1–2.10 ile 2.12–2.13 görselleri ilgili yerlere eklenmiştir. Şekil 2.11 gönderilmediği için daireyi gösteren basit, yeniden çizilmiş bir öğretim görseli kullanılmıştır.

Kaynak kapsamı notu: Paylaşılan malzemede 2.9 başlıklı bir bölüm yoktur. Bu nedenle 2.9 için içerik üretilmedi; 2.8'den sonra sağlanan 2.10 alıştırmalarına geçildi. Çeviri paragrafları özgün konu sırasını izler; mavi/yeşil açıklama kutuları ve örnekler ek öğretim notudur.

Metne aktarılmış PDF'de bazı matematiksel üsler, eşitsizlik işaretleri ve ϵ karakterleri bozulmuştu. Formüller, çevredeki tanım ve matematiksel bağlam temel alınarak okunabilir biçimde dizildi. Ampirik hata denklemindeki “sayı/oran” farkı ayrıca açıklandı.

İçindekiler

2.1 Örneklerden bir sınıfın öğrenilmesi

2.2 Vapnik–Chervonenkis (VC) boyutu

2.3 Muhtemelen yaklaşık doğru (PAC) öğrenme

2.4 Gürültü

2.5 Birden fazla sınıfın öğrenilmesi

2.6 Regresyon

2.7 Model seçimi ve genelleme

2.8 Denetimli algoritmanın üç temel bileşeni

2.10 Alıştırmalar ve çözümleri

2. Denetimli Öğrenme Supervised Learning

Denetimli öğrenmeyi en basit durumdan, yani bir sınıfın pozitif ve negatif örneklerinden öğrenilmesinden başlayarak ele alacağız. Daha sonra birden fazla sınıfın bulunduğu duruma ve çıktıların sürekli olduğu regresyona geçeceğiz.

2.1 Örneklerden Bir Sınıfın Öğrenilmesi

“Aile arabası” adını verdiğimiz **C** sınıfını öğrenmek istediğimizi varsayalım. Elimizde bazı otomobiller ve bu otomobilleri gösterdiğimiz anket katılımcıları olsun. Katılımcılar aile arabası olduğunu düşündükleri otomobilleri **pozitif**, diğerlerini **negatif** olarak etiketler.

Sınıf öğrenme, pozitif örneklerin tamamının paylaştığı ve negatif örneklerde bulunmayan bir tanım bulmaktır. Bu tanım sayesinde daha önce görmediğimiz bir otomobilin aile arabası olup olmadığını tahmin edebiliriz. Ayrıca bir otomobil üreticisi bu çalışmadan, tüketicilerin aile arabasından ne beklediğini anlamak için bilgi çıkarabilir.

Alan uzmanlarıyla görüştükten sonra aile arabasını ayırmak için özellikle **fiyat** ve **motor gücü** özelliklerini seçtiğimizi varsayalım. Bu giriş gösterimini seçtiğimiz anda koltuk kapasitesi, renk ve benzeri başka özellikleri basitleştirme amacıyla göz ardı ederiz.




Figure 2.1 Training set for the class of a “family car.” Each data point corresponds to one example car, and the coordinates of the point indicate the price and engine power of that car. ‘+’ denotes a positive example of the class (a family car), and ‘-’ denotes a negative example (not a family car); it is another type of car.

Şekil 2.1 — Her nokta bir otomobildir. Yatay koordinat fiyatı, dikey koordinat motor gücünü gösterir; + aile arabası, – diğer otomobil demektir.

Açıklama: Pozitif noktaların belirli bir alanda yoğunlaşması, karar bölgesini fiyat ve motor gücü aralıklarıyla tanımlama düşüncesini doğurur.

Fiyat birinci özellik x_1 (örneğin dolar), motor gücü ikinci özellik x_2 (örneğin motor hacmi, cm^3) olsun. Her araç iki sayıyla temsil edilir:

$$x = [x_1, x_2]^T$$

Etiket, otomobilin hangi sınıfa ait olduğunu bildirir:

$$r = 1 \text{ (pozitif örnek); } r = 0 \text{ (negatif örnek)}$$

Her otomobil (x, r) sıralı çiftiyle gösterilir; N örnekten oluşan eğitim kümesi:

$$X = \{(x^t, r^t)\}_{t=1}^N$$

Buradaki üstte yer alan t , zaman ya da üs değil, eğitim kümesindeki örneğin indisi. Örneğin x^3 üçüncü otomobilin özelliklerini, x_1 ise bir otomobilin birinci özelliğini belirtir.

Öğretim örneği

$x = [30.000, 140]^T$ ve $r = 1$ yazıyorsa, fiyatı 30.000 dolar ve motor gücü 140 birim olan araç anket katılımcıları tarafından aile arabası olarak işaretlenmiştir.

Verileri (x_1, x_2) düzleminde gösterdikten sonra, bir aile arabasının hem fiyatının hem motor gücünün belirli aralıklarda olması gerektiğini varsayabiliriz:

$$(p_1 \leq \text{fiyat} \leq p_2) \text{ VE } (e_1 \leq \text{motor gücü} \leq e_2)$$




Figure 2.2 Example of a hypothesis class. The class of family car is a rectangle in the price-engine power space.

Şekil 2.2 — Aile arabası sınıfını fiyat–motor gücü uzayında bir dikdörtgenle temsil eden hipotez sınıfı. Dikdörtgenin sol/sağ sınırları p_1 ve p_2 ; alt/üst sınırları e_1 ve e_2 'dir.

Denklem 2.4, gerçek sınıf C 'nin dikdörtgen biçimli olduğunu varsayar. **H hipotez sınıfı** bütün olası dikdörtgenler kümesidir. Öğrenme algoritması, C 'ye mümkün olduğunca yaklaşacak belirli $h \in H$ hipotezini arar. Bu hipotez dört sayıyla, $(p_1^h, p_2^h, e_1^h, e_2^h)$ ile tanımlanır. Uzman hangi biçimde model kullanacağımızı belirler; dört sınırın değerleri ise veriden öğrenilir.

H ile h arasındaki fark

H: Seçilebilecek bütün dikdörtgenler. **h:** Modelin öğrendiği belirli bir dikdörtgen. Birincisi model ailesi, ikincisi o ailedeki bir modeldir.

Hipotez bir örneği pozitif ya da negatif olarak sınıflandırır:

$$h(x) = 1 \text{ (pozitif diye sınıflandırılır); } h(x) = 0 \text{ (negatif diye sınıflandırılır)} \quad (2.5)$$

Gerçek yaşamda bütün olası x 'ler için $C(x)$ değerini bilmeyiz. Elimizde yalnızca bütün olası girdilerin küçük bir alt kümesi olan X eğitim verisi vardır. **Ampirik hata**, hipotezin eğitimdeki doğru etiketlerle uyuşmadığı örnekleri sayar:

$$E(h | X) = \sum_{t=1}^N \mathbb{I}[h(x^t) \neq r^t]$$

Gösterge fonksiyonu $\mathbb{I}[a \neq b]$, a ile b farklıysa 1, eşitse 0 döndürür. Kaynağın denklemindeki toplam **hatalı örnek sayısını** verir. Metindeki "hata oranı"nı elde etmek için toplam $1/N$ ile çarpılır: $E_{\text{oran}} = E/N$.




Figure 2.3 C is the actual class and h is our induced hypothesis. The point where C is 1 but h is 0 is a false negative, and the point where C is 0 but h is 1 is a false positive. Other points—namely, true positives and true negatives—are correctly classified.

Şekil 2.3 — C gerçek sınıf, h öğrenilen hipotezdir. $C=1$ ve $h=0$ olan nokta yanlış negatif; $C=0$ ve $h=1$ olan nokta yanlış pozitifdir.

Diğer iki durum doğru pozitif ve doğru negatiftir.

Gerçek sınıf	Model tahmini	Sonuç
Pozitif	Pozitif	TP – Doğru pozitif
Negatif	Negatif	TN – Doğru negatif
Negatif	Pozitif	FP – Yanlış pozitif
Pozitif	Negatif	FN – Yanlış negatif

H bütün olası dikdörtgenler olduğunda, belirli eğitim kümesini hatasız sınıflandıran sonsuz sayıda dikdörtgen bulunabilir. Hepsinin eğitim hatası sıfır olsa bile sınıra yakın yeni bir otomobil konusunda farklı karar verebilirler. Bu, **genelleme** sorunudur: eğitimde görülmeyen örnekler doğru sınıflandırılabilirler midir?

Bir seçenek, bütün pozitifleri içine alan ve hiçbir negatifi içermeyen en dar dikdörtgeni bulmaktır. Buna **en özel hipotez S** denir. Gerçek sınıf S'den büyük olabilir. **En genel hipotez G** ise aynı koşullarla çizilebilen en büyük dikdörtgendir. Bu örneğin iç içe biçimli varsayımında S ile G arasında kalan ve eğitimde hata yapmayan her h, eğitim kümesiyle **tutarlıdır (consistent)**. Bu hipotezlerin kümesine **sürüm uzayı (version space)** denir.




Figure 2.4 S is the most specific and G is the most general hypothesis.

Şekil 2.4 — S en özel, G en genel hipotezdir; çizimde gerçek sınıf C bu iki hipotez arasındadır.

Genel durumda birden fazla en özel S_i ve en genel G_j olabilir. Bunların oluşturduğu S-kümesi ve G-kümesi, sürüm uzayının sınır kümeleridir. **Candidate Elimination (Aday Eleme)** algoritması, örnekler sırayla geldikçe bu sınırları günceller (Mitchell, 1997). Burada örnek sayısının tek bir S ve G belirlemeye yeterli olduğunu varsayıyoruz.

S, G veya aralarındaki herhangi bir tutarlı h kullanılabilir. Sezgisel olarak bu aralığın ortasındaki hipotezi seçmek, **marjı**, yani karar sınırı ile en yakın örnekler arasındaki uzaklığı artırabilir. Bunun için yalnızca 0/1 hata sayısı yetmez: uzaklığı da hesaba katan bir çıktı ve kayıp fonksiyonu gerekir.




Figure 2.5 We choose the hypothesis with the largest margin, for best separation. The shaded instances are those that define (or support) the margin; other instances can be removed without affecting h .

Şekil 2.5 — Daha geniş marj sağlayan hipotez seçilir. Gölgeleştirilmiş veri noktaları marjı belirleyen destekleyici örneklerdir; diğerleri çıkarıldığında h değişmeyebilir.

Yanlış karar vermenin maliyetinin çok yüksek olduğu uygulamalarda, S ile G arasındaki belirsiz bölgedeki örnekler kesin bir sınıfa atanmayabilir; sistem bunları reddederek uzman değerlendirmesine bırakabilir.

Buraya kadar H 'nin C 'yi içerecek kadar esnek olduğunu ve eğitim hatası sıfır olan bir h bulunduğunu varsaydık. H yetersiz kapasiteye sahipse gerçek sınıf öğrenilemeyebilir. Bu nedenle hipotez sınıfı seçilirken hem temsil gücü hem de gereksiz karmaşıklıktan kaçınma dikkate alınmalıdır.

Kavramsal ayırım

Gerçek sınıf C 'nin H içinde tam olarak temsil edilebilmesi, yalnızca eğitim hatasının sıfır olmasından daha güçlü bir koşuldur: eğitimde kusursuz görünen hipotez, görülmemiş verilerde hata yapabilir.

2.2 Vapnik–Chervonenkis Boyutu

N noktadan oluşan bir veri kümesinde her nokta pozitif veya negatif olarak etiketlenebilir. Bu nedenle 2^N **farklı etiketleme** ve aynı noktalar üzerinde 2^N farklı öğrenme problemi vardır.

Bir H hipotez sınıfı, bu N noktanın olası bütün pozitif-negatif etiketlemeleri için hatasız bir hipotez üretebiliyorsa H 'nin bu noktaları **shatter ettiği** söylenir. H tarafından shatter edilebilen maksimum nokta sayısı, sınıfın **VC boyutu** olarak adlandırılır ve $VC(H)$ ile gösterilir. VC boyutu, H 'nin kapasitesini ölçer.




Figure 2.6 An axis-aligned rectangle can shatter four points. Only rectangles covering two points are shown.

Şekil 2.6 — Eksenlere paralel bir dikdörtgen dört uygun konumdaki noktayı shatter edebilir. Görselde yalnızca iki noktayı örten dikdörtgenler çizilmiştir.

İki boyutlu uzayda eksenlere paralel dikdörtgenlerin VC boyutu 4'tür. Bunu kanıtlamak için her dört nokta yerleşimini shatter etmek gerekmez; **uygun yerleştirilmiş en az bir dört nokta kümesi** yeterlidir. Örneğin aynı doğru üzerindeki dört nokta dikdörtgenlerle shatter edilemez. Buna karşılık düzlemde hiçbir beş nokta yerleşimi bütün olası etiketlemeler için eksenlere paralel bir dikdörtgenle ayrılmaz.

$$VC(H_{\text{eksenlere paralel dikdörtgen}}) = 4$$

VC boyutunun 4 olması, modelin dörtten çok örneği öğrenemeyeceği anlamına gelmez. VC boyutu örneklerin geldiği dağılımdan bağımsız, en zor etiketlemeler için bir kapasite ölçüsüdür. Gerçek veri kümeleri düzenlilik gösterebilir: yakın otomobillerin aynı sınıfa ait olması gibi. Bu yüzden dört noktadan çok daha büyük ama dikdörtgenlerle öğrenilebilir veri kümeleri bulunur. Küçük VC boyutuna sahip sınıflar da kullanışlıdır; gereksiz büyük hipotez sınıfları yerine tercih edilebilir.

Öğretim örneği

Dört nokta için $2^4 = 16$ etiketleme vardır. "Shatter" demek, *tek bir dikdörtgenin* 16 etiketi aynı anda üretmesi değil, *her etiketleme için sınıftan uygun bir dikdörtgen bulunabilmesi* demektir.

2.3 Muhtemelen Yaklaşık Doğru Öğrenme (PAC)

En dar dikdörtgen S 'yi hipotez olarak kullanırken kaç eğitim örneğine ihtiyacımız olduğunu sormak isteriz. Hipotezin **yaklaşık doğru** olmasını, yani gerçek hata olasılığının belirlenen bir sınırın altında kalmasını; aynı zamanda bunun **yüksek bir güven olasılığıyla** gerçekleşmesini isteriz.

PAC (Probably Approximately Correct) öğrenmede, C sınıfı ve bilinmeyen fakat sabit $p(x)$ olasılık dağılımından seçilmiş bağımsız örnekler için, en az $(1-\delta)$ olasılıkla hata olasılığı en fazla ϵ olacak bir hipotez bulmak üzere gereken N örnek sayısı araştırılır. Kaynakta $\delta \leq 1/2$, $\epsilon > 0$ alınır.

$$P_X\{ L(h) \leq \varepsilon \} \geq 1 - \delta; \quad L(h) = P_{x \sim p}\{x \in C \triangle h\}$$

$C \triangle h$, C ile h 'nin birbirinden farklı karar verdiği bölgedir. Eşitsizlikte kullanılan büyüklük bu bölgenin **$p(x)$ altındaki olasılık kütle**sidir; dıştaki olasılık eğitim örneklerinin seçimine ilişkindir.




Figure 2.7 The difference between h and C is the sum of four rectangular strips, one of which is shaded.

Şekil 2.7 — C ile h arasındaki fark, dört dikdörtgen şeritten oluşur; bir şerit gölgelendirilmiştir.

S , C içindeki en dar dikdörtgen olduğundan hatalı sınıflandırılan pozitifler, aradaki dört şeride düşer. Her şeridin olasılık kütleini $\varepsilon/4$ ile sınırlandırabilirsek toplam hata en fazla $4(\varepsilon/4)=\varepsilon$ olur. Köşelerdeki örtüşmeler iki kez sayıldığı için bu ifade güvenli bir üst sınırdır.

Olasılık kütlesi $\varepsilon/4$ olan bir şeridin rastgele bir örnek tarafından kaçırılma olasılığı $1-\varepsilon/4$ 'tür. N bağımsız örneğin tamamının şeridi kaçırmaması $(1-\varepsilon/4)^N$ olur. Herhangi bir şeridin kaçırılmasını birleşim sınırı ile en fazla $4(1-\varepsilon/4)^N$ olarak sınırlarız ve bunun δ 'yı aşmamasını isteriz.

$$4(1 - \varepsilon/4)^N \leq \delta$$

$1-u \leq \exp(-u)$ eşitsizliğinden hareketle daha kolay sağlanabilecek yeterli koşul:

$$4 \exp(-\varepsilon N/4) \leq \delta$$

Her iki tarafı 4'e bölüp doğal logaritma alır ve N için çözersek:

$$N \geq (4/\varepsilon) \ln(4/\delta)$$

Böylece en az bu sayıda bağımsız örnek alıp en dar dikdörtgeni kullanırsak, en az $1-\delta$ güven düzeyinde yeni örneğin hata olasılığı en fazla ε olur. ε küçüldüğünde gerekli örnek sayısı $1/\varepsilon$ ile doğrusal, δ küçüldüğünde $1/\delta$ 'nin logaritmasıyla artar.

Öğretim örneği

Hata en fazla %5 ($\epsilon=0,05$), güven en az %95 ($\delta=0,05$) olsun. Teorik alt yeterli örnek sayısı sınırı: $N \geq 4/0,05 \cdot \ln(4/0,05) \approx 350,56$; yani **en az 351 bağımsız örnek**. Bu sonuç her model için evrensel değil, burada incelenen özel dikdörtgen/PAC kurgusu içindir.

2.4 Gürültü (Noise)

Gürültü, verideki istenmeyen anormalliktir. Gürültü sınıf öğrenmesini zorlaştırabilir; basit bir hipotez sınıfıyla sıfır eğitim hatası olanaksız hale gelebilir. Gürültünün farklı kaynakları vardır: (1) giriş özelliklerinin yanlış veya belirsiz ölçülmesi; (2) pozitif örneklerin negatif, negatiflerin pozitif etiketlenmesi (teacher noise); (3) etiketi etkilediği halde gözlenmeyen gizli/örtük özelliklerin etkisi.




Figure 2.8 When there is noise, there is not a simple boundary between the positive and negative instances, and zero misclassification error may not be possible with a simple hypothesis. A rectangle is a simple hypothesis with four parameters defining the corners. An arbitrary closed form can be drawn by piecewise functions with a larger number of control points.

Şekil 2.8 — Gürültü olduğunda sınıflar arasında basit bir ayırıcı bulunmayabilir. Dikdörtgen h_1 dört sınır parametresiyle basittir; dalgalı h_2 ise daha çok kontrol noktası gerektirir.

Gürültülü veriyi hatasız ayırmak için daha yüksek kapasiteli, çok parametrelili bir hipotez gerekebilir. Örneğin dalgalı sınır bütün örnekleri izleyerek sıfır eğitim hatası verebilir. Alternatif yol, modeli basit bırakıp bazı eğitim hatalarını kabul etmektir.

Basit dikdörtgenin, eğitim hatası çok daha yüksek olmadığı sürece, tercih edilebilmesinin nedenleri şunlardır:

- **Kullanım kolaylığı:** Bir noktanın dikdörtgen içinde olup olmadığını sınamak kolaydır.
- **Eğitim kolaylığı:** Dört sınırı bulmak, keyfi şeklin çok sayıdaki kontrol noktasını bulmaktan kolaydır. Küçük veri değişikliklerinde daha az oynayan modelin varyansı düşük olabilir; ancak çok basit modelin yanlışlığı yüksek olabilir.
- **Açıklanabilirlik:** Karar, iki özellik için anlaşılır aralıklarla ifade edilir; ham veriden insanın yorumlayabileceği bilgi çıkarılabilir.
- **Gürültüye dayanıklılık:** Gerçek sınıf basitken rastlantısal yanlış etiketleri birebir taklit etmemek, yeni örneklerde daha iyi sonuç verebilir.

Karşılaştırılabilir eğitim hataları için basit fakat gereğinden basit olmayan modelin daha iyi genelleme yapması beklenebilir. Buna **Occam'ın Usturası (Occam's razor)** ilkesi denir: gereksiz karmaşıklık çıkarılmalıdır.

Yanlılık-varyans dengesi

Yanlılık (bias): Modelin yapısal kısıtlılığı nedeniyle gerçek ilişkiyi sistematik olarak yeterince temsil edememesi. **Varyans (variance):** Eğitim örnekleri biraz değiştiğinde öğrenilen modelin çok değişmesi. Çok basit model eksik öğrenebilir; çok karmaşık model gürültüye aşırı uyabilir. Amaç soruna uygun dengeyi kurmaktır.

2.5 Birden Fazla Sınıfın Öğrenilmesi

Aile arabası örneği başlangıçta iki sınıflıydı: aile arabası ve diğer bütün otomobiller. Genel durumda C_i ($i=1,...,K$) ile gösterilen K sınıf vardır; bu bölümde bir örneğin **tam olarak bir** sınıfa ait olduğu varsayılır. Eğitim kümesi $X=\{(x^t, r^t)\}$ biçiminde kalır, ancak r^t artık K boyutlu ikili bir vektördür:

$$r_i^t = 1 \text{ (} x^t \in C_i \text{); } r_i^t = 0 \text{ (} x^t \text{ diğer sınıflardan birindeyse)}$$

(2.8)




Figure 2.9 There are three classes: family car, sports car, and luxury sedan. There are three hypotheses induced, each one covering the instances of one class and leaving outside the instances of the other two classes. "?" are reject regions where no, or more than one, class is chosen.

Şekil 2.9 — Üç sınıf: aile arabası, spor araba ve lüks sedan. Üç hipotezden her biri kendi sınıfını kapsar, diğerlerini dışarıda bırakır. "?" işaretleri reddetme bölgeleridir.

K -sınıflı bir sınıflandırma problemi, her sınıfın diğer bütün sınıflardan ayrıldığı K ikili problem olarak ele alınabilir. C_i örnekleri h_i için pozitif; diğer bütün sınıfların örnekleri negatiftir:

$$h_i(x^t) = 1 \text{ (} x^t \in C_i \text{); } 0 \text{ (} x^t \in C_j, j \neq i \text{)}$$

Toplam ampirik hata, bütün sınıf-örnek çiftlerindeki yanlış tahminlerin toplamıdır:

$$E(\{h_i\}_{i=1^K} | X) = \sum_{t=1}^N \sum_{i=1^K} \mathbb{I}[h_i(x^t) \neq r^t_i]$$

İdeal olarak belirli x için yalnızca bir $h_i(x)=1$ olur. Hiçbir hipotez 1 üretmez veya birden fazlası 1 üretirse model sınıfı belirleyemez; bu **şüpheli durum** sınıflandırıcı tarafından reddedilebilir. Bu yaklaşım bugün genellikle **one-vs-rest** olarak adlandırılır.

One-hot etiket örneği

Üç sınıf için aile arabası etiketi $[1,0,0]$; spor araba $[0,1,0]$; lüks sedan $[0,0,1]$ olur. $[0,0,0]$ veya $[0,1,1]$ çıktıları, ayrı ikili sınıflandırıcıların kesin ve tek sınıflı cevap vermediği durumlardır.

Aile arabası örneğinde tek bir pozitif hipotez öğrenip dışında kalan her aracı “aile arabası değil” diye adlandırdık. Alternatif olarak pozitif ve negatif sınıf için ayrı hipotez öğrenebiliriz; örneğin aile ve spor arabaları kendi yapılarıyla modelleyince lüks sedan için her iki hipotez de negatif diyebilir ve girdi reddedilebilir.

Sınıfların giriş uzayındaki dağılımları benzerse hepsi için aynı hipotez sınıfı kullanılabilir; el yazısı rakam tanıma örneğinde bu makul olabilir. Sağlıklı/hasta ayrımı gibi başka uygulamalarda sınıfların dağılımı çok farklı olabilir; hastalığın birden fazla biçimde ortaya çıkması “hasta” sınıfını çok çeşitli kılabilir.

2.6 Regresyon (Regression)

Sınıflandırmada çıkış evet/hayır gibi kategorik bir değerdir. Regresyonda ise öğrenilecek nesne $C(x) \in \{0,1\}$ sınıfı değil, sayısal çıktı üreten bir fonksiyondur. Bilinmeyen fonksiyondan gelen eğitim örnekleri $X = \{(x^t, r^t)\}$, $r^t \in \mathbb{R}$ biçimindedir.

Gürültü yoksa görev **interpolasyondur**: verilen bütün noktalardan geçen $f(x)$ fonksiyonunu, $r^t = f(x^t)$ olacak biçimde buluruz. Birbirinden farklı N girişli noktayı en fazla $N-1$. dereceden bir polinomla tam olarak interpolasyonla temsil etmek mümkündür. Eğitimde gözlenen x aralığının dışına tahmin yapıyorsa buna **ekstrapolasyon** denir; zaman serisiyle geleceği tahmin etmek bir örnektir.

Regresyonda bilinmeyen gerçek fonksiyonun çıktısına rastgele gürültü eklenmiş olabilir:

$$r^t = f(x^t) + \varepsilon^t$$

Gürültünün bir açıklaması, girdide gözlemleyemediğimiz z^t gibi gizli değişkenlerin bulunmasıdır:

$$r^t = f^*(x^t, z^t)$$

Bu bilinmeyen çıktıyı $g(x)$ modelimizle yaklaşık hesaplamak isteriz. Eğitim kümesindeki ampirik hata olarak kare farkların ortalamasını kullanabiliriz:

$$E(g | X) = (1/N) \sum_{t=1}^N [r^t - g(x^t)]^2$$

Sayısal tahminlerde eşit/eşit değil bilgisinin ötesinde farkın büyüklüğü de vardır. Bu nedenle kare hata veya mutlak hata gibi kayıp fonksiyonları kullanılabilir. Amacımız E 'yi en aza indiren g modelini bulmaktır.

Önceki yaklaşımımızı izleyerek g için az sayıda parametreye sahip bir hipotez sınıfı seçebiliriz. Doğrusal modeli varsayarsak:

$$g(x) = w_1x_1 + \dots + w_dx_d + w_0 = \sum_{j=1}^d w_jx_j + w_0$$




Figure 2.10 Linear, second-order, and sixth-order polynomials are fitted to the same set of points. The highest order gives a perfect fit, but given this much data it is very unlikely that the real curve is so shaped. The second order seems better than the linear fit in capturing the trend in the training data.

Şekil 2.10 — Aynı noktalara doğrusal, ikinci dereceden ve altıncı dereceden polinomlar uydurulmuştur. En yüksek derece eğitim noktalarına çok iyi uyum sağlarken genel eğilimi doğru temsil etmeyebilir.

Önceki ikinci el otomobil fiyatı örneğinde tek girişli doğrusal model kullanmıştık:

$$g(x) = w_1x + w_0$$

Parametreler w_1 ve w_0 , kare hatayı minimum yapacak biçimde veriden öğrenilmelidir:

$$E(w_1, w_0 | X) = (1/N) \sum_{t=1}^N [r^t - (w_1x^t + w_0)]^2$$

E 'nin w_1 ve w_0 'a göre kısmi türevlerini alıp sıfıra eşitlersek:

$$w_1 = [\sum_t x^t r^t - N \bar{x} \bar{r}] / [\sum_t (x^t)^2 - N(\bar{x})^2] ; \quad w_0 = \bar{r} - w_1 \bar{x} \quad (2.17)$$

Burada $\bar{x} = (1/N)\sum_t x^t$ ve $\bar{r} = (1/N)\sum_t r^t$ 'dir. Bulunan doğru, kitabın önceki bölümündeki Şekil 1.2'de yer almaktadır. Girdi değerleri farklı değilse payda sıfır olur ve eğim benzersiz belirlenemez.

Doğrusal model gerçek ilişki için çok kısıtlıysa yaklaşım hatası büyür. Bu durumda ikinci dereceden bir fonksiyon kullanılabilir:

$$g(x) = w_2x^2 + w_1x + w_0$$

Polinom derecesi artırıldığında eğitim verisine mümkün olan en iyi uyumun hatası artmaz; daha esnek model tek tek örneklerle daha yakından yaklaşabilir. Ne var ki altıncı dereceden polinom gibi çok esnek bir

model genel eğilim yerine gürültüyü takip edebilir. Occam'ın Usturası regresyonda da geçerlidir: model karmaşıklığı, verinin altında yatan ilişkinin karmaşıklığıyla uyumlu seçilmelidir.

Öğretim örneği

İkinci el otomobil fiyatının kilometreyle ilişkisini yalnızca doğruyla temsil etmek yetersiz olabilir. Ancak az sayıda gözleme altıncı dereceden eğri geçirmek, arada veya veri aralığının dışında beklenmedik fiyat sıçramaları yaratabilir. Değerlendirme eğitim noktalarına ne kadar yakından geçildiğine değil, yeni otomobillerin fiyatını ne kadar doğru tahmin ettiğine dayanmalıdır.

2.7 Model Seçimi ve Genelleme

Örneklerden bir Boolean fonksiyon öğrenmeyle başlayalım. Boolean fonksiyonda bütün girdiler ve çıktı ikilidir. d ikili özelliğin 2^d farklı giriş kombinasyonu vardır; her bir kombinasyon 0 veya 1 etiketini alabilir. Bu yüzden d girişli $2^{(2^d)}$ farklı Boolean fonksiyon vardır (Tablo 2.1).

Farklı giriş sayısı = 2^d ; farklı Boolean fonksiyon sayısı = $2^{(2^d)}$

Her yeni **farklı** eğitim örneği, tahminleri yanlış olan hipotezlerin yarısını eler. Örneğin $x_1=0, x_2=1$ için doğru çıktı 0 ise önceki tablodaki $h_5, h_6, h_7, h_8, h_{13}, h_{14}, h_{15}, h_{16}$ elenir. Öğrenmeyi, veriye aykırı hipotezleri aşamalı olarak çıkarma işlemi gibi yorumlayabiliriz.

Bütün olası Boolean fonksiyonları içeren hipotez sınıfında tek fonksiyona ulaşmak için 2^d giriş kombinasyonunun tamamını görmemiz gerekir. N farklı girişin çıktısını biliyorsak $2^{(2^d - N)}$ fonksiyon kalır. Gerçek problemlerde olası girişlerin ancak küçük bir bölümü etiketlendiği için çözüm genellikle benzersiz değildir. Bu, **iyi tanımlanmamış (ill-posed)** öğrenme problemidir.

Sınıflandırma ve regresyonda da aynı sorun vardır: daha çok örnek gördükçe tutarsız hipotezler elenir, ama çoğunlukla birçok geçerli hipotez kalır. Verinin tek başına yeterli olmaması nedeniyle ek varsayımlar gerekir. Öğrenmeyi mümkün kılmak için yaptığımız varsayımların tümüne **inductive bias — tümevarımsal yanlılık** denir.

Hipotez sınıfı H seçimi başlı başına bir tümevarımsal yanlılıktır. Aile arabasının dikdörtgen biçimli olduğunu varsaymak, sonra en büyük marjlı dikdörtgeni seçmek iki farklı tercihtir. Doğrusal regresyonda doğrusallık varsayımı ve kare hatayı en aza indiren doğruyu seçmek de birer tercih oluşturur.

Her hipotez sınıfının belirli kapasitesi vardır. Örneğin iki dikdörtgenin birleşimi, tek dikdörtgenden daha karmaşık biçimleri temsil eder. Polinom derecesini yükseltmek de regresyonda kapasiteyi artırır. Sorun, bu artırmayı hangi noktada durduracağımızdır. Olası hipotez sınıfları H arasından seçim yapma işlemine **model selection — model seçimi** denir.

Makine öğrenmesinin temel amacı eğitim verilerini yeniden üretmek değil, eğitimde bulunmayan girdilerin doğru çıktısını tahmin etmektir. Bir modelin görülmemiş örneklerdeki başarısına **genelleme** denir. İyi genelleme için H 'nin karmaşıklığını veriyi üreten gerçek fonksiyonunkiyle uyumlu tutmak gerekir.

H gerçek fonksiyondan daha basitse **underfitting (eksik öğrenme)** görülür: üçüncü dereceden eğriyle üretilen veriye bir doğru uydurmak gibi. H çok karmaşıksa veri onu yeterince sınırlandıramaz; tek dikdörtgenle üretilen veriye iki dikdörtgen uydurmak veya gürültülü üçüncü dereceden veriye altıncı dereceden polinom geçirmek kötü bir hipoteze yol açabilir. Gürültünün de öğrenilmesine **overfitting (aşırı öğrenme)** denir. Daha çok veri yardımcı olabilir, ancak model seçiminin önemini ortadan kaldırmaz.

Dietterich (2003) bu ilişkiyi **üçlü denge (triple trade-off)** olarak özetler: (1) hipotez sınıfının kapasitesi/ model karmaşıklığı, (2) eğitim örneği sayısı, (3) yeni örneklerdeki genelleme hatası. Veri arttıkça hata genellikle azalır; karmaşıklık artarken hata önce azalabilir, sonra aşırı uyum nedeniyle büyüyebilir. Çok esnek bir polinomun eğitim noktasının olmadığı bölgelerde düzensiz davranabilmesi buna örnektir.

Ek açıklama: Bu bir mutlak yasa değildir

“Veri arttıkça genelleme hatası azalır” ve “karmaşıklığa karşı hata U-şeklindedir” ifadeleri bu bölümün sezgisel genel eğilimleridir. Her yeni örnekte veya her model ailesinde hatanın zorunlu olarak monoton değiştiği anlamına gelmez.

Genelleme yeteneğini ölçmek için eğitim verilerinden ayrı gözlemlere ihtiyaç duyarız. Veri kümesini eğitim ve doğrulama olarak böleriz. Aday H_i sınıflarının her birinde eğitim verisinde en iyi h_i öğrenilir; ardından doğrulama kümesindeki performans karşılaştırılır. Örneğin farklı polinom derecelerinin katsayılarını eğitimde öğrenir, doğrulama hatası en düşük olan dereceyi seçeriz.

Kaynak, bu süreci **cross-validation — çapraz doğrulama** olarak adlandırır. Güncel terminolojide tek bir eğitim/doğrulama bölünmesi sıklıkla **hold-out validation**, birden fazla döngüsel bölünme ise **K-fold cross-validation** diye adlandırılır.

Modeli seçmek için kullandığımız doğrulama hatasını, seçilmiş modelin bağımsız nihai performansı olarak raporlamamalıyız: doğrulama kümesi artık seçimi etkilemiştir. Bunun için eğitim ve doğrulamada kullanılmamış üçüncü bir küme, **test kümesi (test set)**, gerekir. Kaynak bunu bazen “publication set” diye de adlandırır.

Küme	Temel işlev	Öğretim benzetmesi
Training / Eğitim	Model parametrelerini öğrenmek	Derste çözülen örnekler
Validation / Doğrulama	Modeli ve ayarlarını seçmek	Çalışma sınavı soruları
Test	Seçimden ayrı son performansı ölçmek	Meslek hayatında karşılaşılan yeni problemler

Aynı doğrulama ayırımını durmadan yeniden kullanmak da tehlikelidir: sistem, her yıl aynı sınav sorularını çözen öğrencinin cevapları ezberlemesi gibi doğrulama kümesine uyabilir. Eğitim verileri rastgele örneklemdir; veriyi yeniden topladığımızda veya farklı bölüştürdüğümüzde h ve ölçülen hatalar değişebilir. Bu nedenle aday modelleri birden fazla eğitim/doğrulama bölünmesinde karşılaştırmak ve ortalama farkların rastlantısal değişkenlikten büyük olup olmadığını incelemek gerekir. Kitabın 19. bölümü deney tasarımını ve istatistiksel anlamlılığı ayrıntılı işler.

K-fold örneği

5-fold doğrulamada veri beş parçaya ayrılır. Her turda bir parça doğrulama, kalan dördü eğitimidir. Böylece beş doğrulama hatası elde edilir. Bunların ortalaması ve değişkenliği model seçimini destekler. Nihai test kümesi model seçimi döngüsünün dışında kalır.

2.8 Denetimli Makine Öğrenmesi Algoritmasının Bileşenleri

Şimdi çerçeveyi özetleyip genelleştirelim. Örneklem:

$$X = \{(x^t, r^t)\}_{t=1}^N$$

Örneklerin **iid (independent and identically distributed)**, yani bağımsız ve özdeş dağılımlı olduğu varsayılır: sıralama önemli değildir ve bütün örnekler aynı ortak $p(x, r)$ dağılımından çekilir. t örneğin indisi; x^t herhangi boyuttaki girdi; r^t istenen çıktıdır. İki sınıfta $r^t \in \{0, 1\}$; $K > 2$ sınıfta tek bileşeni 1 olan K -boyutlu ikili vektör; regresyonda $r^t \in \mathbb{R}$ olur.

Amaç, $g(x^t | \theta)$ modeliyle r^t 'ye iyi ve yararlı bir yaklaşım bulmaktır. Bunun için üç temel karar verilir:

1. Model: $g(x | \theta)$

g model ailesini, x girdiyi, θ parametreleri gösterir. g 'nin seçimi H hipotez sınıfını tanımlar; θ 'nın belirli değeri $h \in H$ hipotezini oluşturur. Dikdörtgen için θ dört sınır koordinatıdır; doğrusal regresyonda eğim ve sabit terimdir. Sistem tasarımcısı uygulama bilgisine göre H 'yi (tümevarımsal yanlılığı) belirler; öğrenme algoritması eğitim verisi kullanarak θ 'yı ayarlar.

2. Kayıp fonksiyonu: L

Mevcut θ parametreleriyle elde edilen tahmin $g(x^t | \theta)$ ve hedef r^t arasındaki farkı L ölçer. Toplam yaklaşım hatası:

$$E(\theta | X) = \sum_t L(r^t, g(x^t | \theta))$$

Sınıflandırmada 0/1 çıktı için eşitlik kontrolü kullanılabilir; regresyonda sayısal uzaklık bulunduğu kare fark gibi bir kayıp seçilebilir.

3. Optimizasyon prosedürü

Toplam hatayı minimum yapan parametreler aranır:

$$\theta^* = \arg \min_{\theta} E(\theta | X)$$

$\arg \min$, en küçük fonksiyon değerini değil, o değeri veren parametreyi döndürür. Polinom regresyon gibi bazı problemlerde analitik çözüm vardır. Başka modellerde optimizasyonun güçlüğü ve tek küresel minimum yerine birden fazla yerel minimum bulunup bulunmadığı önem kazanır.


Bu sistemin iyi çalışabilmesi için üç koşul aranır: H bilinmeyen gerçek ilişkiyi yaklaşık temsil edecek kapasitede olmalı; H içinden iyi bir h seçebilecek kadar veri bulunmalı; optimizasyon yöntemi veriler üzerinde doğru/yeterince iyi parametreleri bulabilmelidir. Makine öğrenmesi algoritmaları seçtikleri model ailesi, kayıp ölçüsü veya optimizasyon yöntemi bakımından ayrılır.

Ünitenin ana formülü

Model $g(x|\theta)$ + **kayıp** $L(r,g)$ + **optimizasyon** $\theta^* = \arg \min E \rightarrow$ **öğrenilmiş hipotez** $h(x)=g(x|\theta^*)$.

2.10 Alıştırmalar ve Çözümleri

Bu bölüm, paylaştığın 11 alıştırmanın tamamının Türkçe çevirisini içerir. Kaynakta 1–5. alışırtmaların çözümlü verilmiştir; bunlar çevrilerek açıklanmıştır. 6–11. alıştırtmaların çözümleri ise öğretim amaçlı olarak ayrıca hazırlanmıştır.



Şekil 2.11 — Hipotez sınıfı bir dairedir; merkez $c=(c_1, c_2)$ ve yarıçap r ile tanımlanır. Kaynakta Şekil 2.11 görseli yüklenmediği için burada öğretim amaçlı yeniden çizilmiştir.

Alıştırma 1 — Daire ve elips

Sorunun çevirisi. Hipotez sınıfı dikdörtgen yerine daire olursa parametreler nelerdir ve nasıl hesaplanır? Elips olursa ne değişir; daire yerine elips kullanmak neden anlamlı olabilir?

Çözüm (kitaptaki yanıtın çevirisi ve açıklama).

Daire merkezi $c=(c_1, c_2)$ ve yarıçap r ile tanımlanır: $(x_1 - c_1)^2 + (x_2 - c_2)^2 \leq r^2$. S bütün pozitifleri içeren en dar tutarlı daire; G bütün pozitifleri içerirken negatifleri dışarıda bırakan en genel daire fikridir. İkisinin arasında kalabilen tutarlı daireler adaydır.

Parametreler eğitim verisine göre belirlenir. Örneğin dar daire ararken r^2 minimize edilip pozitifler için $(x_1^t - c_1)^2 + (x_2^t - c_2)^2 \leq r^2$, negatifler için karşıt dışarıda kalma koşulu uygulanabilir.

Elips: $(x_1 - c_1)^2/a^2 + (x_2 - c_2)^2/b^2 \leq 1$. Yatay ve düşey genişliklerin ayrı a, b parametreleri vardır; dönmeye izin verilirse açı ϕ eklenir. Fiyat ve motor gücünün ölçekleri farklıdır ve aralarında pozitif ilişki beklenebildiği için eğik elips daha uygun olabilir.

Ek açıklama. Daire hipotezleri her zaman iç içe tek S/G zinciri oluşturmaz; bu açıklama kitabın geometrik sezgisidir. Eksene paralel elipsin dört, döndürülmüş elipsin beş temel parametresi vardır.




Figure 2.12 Hypothesis class is a union of two rectangles.

Şekil 2.12 — Hipotez sınıfı iki dikdörtgenin birleşiminden oluşur. Pozitif örnekler birbirinden ayrık iki kümede bulunabilir.

Alıştırma 2 — İki veya m dikdörtgenin birleşimi

Sorunun çevirisi. Tek dikdörtgen yerine iki veya $m > 1$ dikdörtgenin birleşimini kullanmanın avantajını açıklayınız. m yeterince büyükken sonlu örneklemde herhangi bir sınıf etiketlemesini nasıl temsil edebileceğimizi gösteriniz.

Çözüm (kitaptaki yanıtın çevirisi ve açıklama).

Tek dikdörtgen pozitifleri tek sürekli bölgede toplar; iki dikdörtgen iki ayrık pozitif kümeyi kapsayabilir. Her dikdörtgen sınır aralıklarının mantıksal VE birleşimidir; birden fazla dikdörtgen mantıksal VEYA ile birleştirilir: $h(x) = h_1(x) \vee \dots \vee h_m(x)$.

Her mantıksal formül, VE terimlerinin VEYA ile birleşimi biçiminde yazılabilir. Ayrı ayrı gözlenen sonlu ve çakışmayan giriş noktalarının her pozitifine yeterince küçük bir dikdörtgen yerleştirilirse en kötü durumda pozitif sayısı kadar, dolayısıyla $m \leq N$ dikdörtgenle bütün örnekler doğru etiketlenebilir.

Ek açıklama. Bu iddia sonlu örneklem içindir. Sabit sayıda dikdörtgen, sürekli uzaydaki her keyfî geometrik bölgeyi tam olarak ifade etmez.

Alıştırma 3 — Yanlış pozitif ve negatifin maliyeti

Sorunun çevirisi. Yanlış pozitif (FP) ve yanlış negatif (FN) kararların parasal maliyeti farklı olabilir. h'nin S ve G arasındaki konumu maliyetle nasıl ilişkilidir?

Çözüm (kitaptaki yanıtın çevirisi ve açıklama).

Kitabın iç içe sınıflar örneğinde dar S yanlış pozitif üretmez, ama gerçek C'nin bir kısmını kaçırmak yanlış negatif verebilir; geniş G yanlış negatifi önler ama yanlış pozitif verebilir. Maliyetler eşitse ortada bir hipotez sezgisel tercihtir. FP daha pahalıysa S'ye, FN daha pahalıysa G'ye yakın seçim yapılır.

Maliyetli risk $E[\text{maliyet}] = c_{FP}P(FP) + c_{FN}P(FN)$ ile ifade edilebilir.

Ek açıklama. Geometrik tam orta noktanın her veri dağılımında beklenen toplam maliyeti minimize etmesi garanti değildir.

Alıştırma 4 — Gereksiz örneklerin filtrelenmesi

Sorunun çevirisi. Birçok öğrenme algoritmasının karmaşıklığı eğitim kümesine bağlıdır. Gereksiz eğitim örneklerini saptayacak bir filtreleme yöntemi öneriniz.

Çözüm (kitaptaki yanıtın çevirisi ve açıklama).

Kitabın önerisi: karar sınırını genellikle farklı etiketli örneklerin yakınındakiler belirler. Çok sayıda aynı etiketli örnekle çevrili iç bölge örnekleri sınırı etkilemeyebilir. Her örneğin k en yakın komşusunu bulun, aynı sınıfların ortasındaki örnekleri kaldırılabilir aday olarak işaretleyin ve çıkarıldığında model sınırı/validasyon başarısı değişmiyorsa kaldırın.

Ek açıklama. Gürültü, küçük alt gruplar ve nadir durumlar nedeniyle bütün “iç nokta”ların gelişigüzel silinmesi doğru değildir.

Alıştırma 5 — Daha az sorguyla etiket öğrenme

Sorunun çevirisi. Herhangi bir x noktasının gerçek etiketini söyleyen bir öğretmenimiz varsa daha az sorgu yapabilmek için hangi x noktalarını seçmeliyiz?

Çözüm (kitaptaki yanıtın çevirisi ve açıklama).

Belirsizlik S ile G arasındadır. Sorguları bu bölgeden seçmek, sürüm uzayını küçültmeye yardımcı olur. Sorgulanan nokta pozitif çıkarsa S bu noktayı kapsayacak şekilde genişletilir; negatif çıkarsa G'nin bu noktayı pozitif sayan adayları elenir ve sınır daralır.

Ek açıklama. Bu yaklaşım **aktif öğrenme** mantığıdır: etiketi bilinen noktaları tekrar sormak yerine belirsiz noktaları seçmek.

Alıştırma 6 — Dayanıklı regresyon kaybı

Sorunun çevirisi. Denklem 2.13'te farkların kareleri toplanır. Aykırı değerlere duyarlı olan bu fonksiyon yerine dayanıklı regresyonda hangi kayıp kullanılabilir?

Çözüm (hazırlanan çözüm).

Mutlak hata (MAE): $L(r, \hat{g}) = |r - \hat{g}|$; $E = (1/N) \sum |r^t - g(x^t)|$. Kare hata büyük sapmaları karesel cezalandırırken MAE doğrusal cezalandırır. Örneğin hata 100 ise kare kaybın katkısı 10.000, mutlak kaybın katkısı 100'dür.

Diğer bir seçenek **Huber kaybı**dır: $|e| \leq \kappa$ olduğunda $\frac{1}{2}e^2$, $|e| > \kappa$ olduğunda $\kappa(|e| - \kappa/2)$. Küçük hatada karesel, büyük hatada doğrusal davranır.

Alıştırma 7 — Doğrusal regresyon katsayılarının türetilmesi

Sorunun çevirisi. Denklem 2.17'yi, kare hata fonksiyonunun kısmi türevlerinden yola çıkarak türetiniz.

Çözüm (hazırlanan çözüm).

$E = (1/N) \sum (r^t - w_1 x^t - w_0)^2$. $\partial E / \partial w_0 = -(2/N) \sum (r^t - w_1 x^t - w_0) = 0$. Böylece $Nw_0 = \sum r^t - w_1 \sum x^t$; $w_0 = \bar{r} - w_1 \bar{x}$.

$\partial E / \partial w_1 = -(2/N) \sum x^t (r^t - w_1 x^t - w_0) = 0$. Açınca $\sum x^t r^t = w_1 \sum (x^t)^2 + w_0 \sum x^t$. $w_0 = \bar{r} - w_1 \bar{x}$ ve $\sum x^t = N\bar{x}$ yerine yazılır:

$$w_1 = [\sum x^t r^t - N \bar{x} \bar{r}] / [\sum (x^t)^2 - N(\bar{x})^2]$$

Ardından $w_0 = \bar{r} - w_1 \bar{x}$ bulunur. Eğimin tekil olmayan çözümü için girişlerde varyasyon gereklidir.




Figure 2.13 A line separating positive and negative instances.

Şekil 2.13 — Pozitif ve negatif noktaları ayıran doğrusal karar sınırı.

Alıştırma 8 — Doğruların VC boyutu

Sorunun çevirisi. Pozitifleri kapsayan dikdörtgen yerine pozitif ve negatif örnekleri bir doğruyla ayırdığımızda iki boyutta VC boyutunun 3 olduğunu gösteriniz.

Çözüm (hazırlanan çözüm).

Aynı doğru üzerinde olmayan üç nokta üçgen oluşturur. Üç noktanın $2^3=8$ etiketlemesinin her birinde tek bir pozitif/negatif köşe, diğer iki köşeden bir doğruyla ayrılabilir; hepsi aynı sınıfta olduğunda doğru üçgenin dışından seçilir. Bu yüzden $VC \geq 3$.

Dört nokta ya birinin diğer üçünün konveks zarfında kaldığı durumu içerir (üç dış noktayı pozitif, içtekini negatif yapmak olanaksızdır) ya da dört nokta konveks dörtgen oluşturur (karşılıklı pozitif ve karşılıklı negatif köşelerin konveks zarfları kesişir). Her durumda en az bir etiketleme doğrusal ayrılamaz. O hâlde $VC < 4$ ve $VC = 3$.

Alıştırma 9 — Üçgenlerin VC boyutu

Sorunun çevirisi. İki boyutta üçgen hipotez sınıfının VC boyutunun 7 olduğunu gösteriniz. İpucu: Yedi noktayı bir çember üzerine eşit aralıklarla yerleştirin.

Çözüm (hazırlanan çözüm).

Yedi noktayı çember üzerinde konveks konumda seçelim. Her etiketlemede negatif noktalar, çevre boyunca en fazla üç ayrı ardışık gruba ayrılır; üçgenin üç kenarı bu grupları dışarıda bırakacak şekilde kurulabilir. Böylece bütün 2^7 etiketlemeler üçgenlerle gerçekleştirilebilir: $VC \geq 7$.

Sekiz nokta için ya bir nokta diğerlerinin konveks zarfında kalır (dıştakiler +, içteki – ayrımı olanaksızdır) ya da sekizi konveks konumdadır. İkinci durumda $+-+-+-$ dönüşümlü etiketlemede dört ayrı negatif grup oluşur; üçgenin üç kenarı bunların tümünü ayıramaz. $VC < 8$; sonuç $VC = 7$.

Ek açıklama. Sınır üstündeki noktaların nasıl etiketleneceği önemliyse geometrik sınır çok küçük oynatılabilir; ispat katı ayrılabirlik yaklaşımıyla okunmalıdır.

Alıştırma 10 — Hem sınıflandırma hatası hem maksimum marj

Sorunun çevirisi. Hipotez sınıfı doğrulardan oluşsun. Yanlış sınıflandırmaları azaltırken marjı büyüten bir hata fonksiyonu yazınız.

Çözüm (hazırlanan çözüm).

Etiketleri $y_i \in \{-1, +1\}$, karar fonksiyonunu $f(x) = w^T x + b$ seçelim. Geometrik marj $\min_i y_i(w^T x_i + b) / \|w\|$ 'dür. Tam ayrılabir veriler için **hard-margin SVM**: $\min \frac{1}{2} \|w\|^2$, koşul $y_i(w^T x_i + b) \geq 1$.

Hata ve marj ihlaline izin veren bir amaç fonksiyonu: $J(w, b) = \frac{1}{2} \|w\|^2 + C \sum \max(0, 1 - y_i(w^T x_i + b))$. İlk terim marjı artırma yönünde, ikincisi yanlış etiketleme ve marj ihlallerini azaltma yönündedir.

Ek açıklama. Hinge loss doğrudan yanlış örnek sayısı değildir; 0-1 kaybının hesaplanabilir bir üst sınırı ve marj cezasıdır.

Alıştırma 11 — Muhtemel yanlış etiketlerin bulunması

Sorunun çevirisi. Gürültü kaynaklarından biri hatalı sınıf etiketidir. Yanlış etiketlenmiş olma olasılığı yüksek noktaları bulmak için yöntem öneriniz.

Çözüm (hazırlanan çözüm).

Her örneğin k en yakın komşusunun çoğunluk etiketini bulun. Örneğin etiketi komşularının büyük çoğunluğuyla uyuşmuyorsa “şüpheli” işaretleyin. Ek olarak out-of-fold (örneğin K-fold) model tahminini elde edip örneğin verilen etiketiyle karşılaştırın. Hem komşular hem model yüksek güvenle karşıt etiketi öneriyorsa uzman incelemesinde öncelik verin.

Yanlış etiket olduğuna otomatik hükmetmeyin: örnek gerçek bir sınıf sınırı, nadir alt grup veya modelin kendi hatası olabilir.

Ünite 2 — Hızlı Tekrar

Kavram	Kısa anlam
H / h	Olası hipotez sınıfı / seçilen belirli hipotez
S / G	En özel / en genel tutarlı hipotez sınırı
Version space	Eğitim kümesiyle tutarlı bütün hipotezler
Margin	Karar sınırıyla en yakın eğitim örnekleri arasındaki uzaklık
VC(H)	Shatter edilebilen maksimum nokta sayısı
PAC	Belirli hata ve güven sınırını sağlayan öğrenme çerçevesi
Noise	Ölçüm, etiket veya gizli değişken kaynaklı düzensizlik
Bias / variance	Yapısal yetersizlik / veri örneklemesine duyarlılık
Model selection	Hipotez sınıfı ve model ayarlarını belirleme
Training / validation / test	Parametre öğrenme / seçme / bağımsız son değerlendirme
Regression	Sayısal hedef tahmini
Model + loss + optimization	Denetimli öğrenmenin üç temel tasarım kararı

Öğretim için kapanış

Makine öğrenmesi yalnızca eğitim kümesindeki noktaları doğru etiketlemek değildir. Öğrenilebilir hipotezlerin kapsamını seçmek, hata türlerini ve maliyetlerini tanımlamak, doğru miktarda veri toplamak, parametreleri optimize etmek ve bütün bunların yeni veriye genellenip genellenmediğini bağımsız biçimde ölçmektir.

Kaynak ve kapsam

Alpaydın, E. (2014). *Introduction to Machine Learning*. MIT Press. Bölüm 2: “Supervised Learning”. Çeviri ve açıklamalar, bu konuşmada kullanıcının sağladığı 2.1–2.8 bölüm metinlerine, 2.10 alıştırma metnine ve ilgili görsellere dayanır. Kaynakta mevcut olmayan 2.9 metni bu PDF’de çevrilmiş gibi gösterilmemiştir.