

Ünite 3

Bayesçi Karar Teorisi

Türkçe Çeviri, Ayrıntılı Açıklamalar, Şekiller, Örnekler ve Çözümlü Alıştırmalar

Bu çalışma notu, Ethem Alpaydın'ın *Introduction to Machine Learning* (2014) kitabındaki 3. bölümün kullanıcı tarafından sağlanan metnine dayanılarak hazırlanmıştır. Metin Türkçeye çevrilmiş, ders anlatımına uygun biçimde açıklamalar ve yeni sayısal örnekler eklenmiş, paylaşılan Şekil 3.1 ve Şekil 3.2 kullanılmış ve bölüm sonu alıştırmaları adım adım çözülmüştür.

İçindekiler

Bu Ünite Ne Öğreneceğiz?	2
1 Bayesçi Karar Teorisine Giriş	3
2 3.1 Giriş	3
2.1 İstatistik ile bilgisayar biliminin kesişimi	3
2.2 Neden rastgele süreç modeli kullanıyoruz?	3
2.3 Bernoulli dağılımı ve yazı-tura	3
2.4 Dağılım bilinmiyorsa: örneklemden tahmin	4
3 3.2 Sınıflandırma	5
3.1 Kredi riski örneği	5
3.2 Bayes kuralı	5
3.3 Sayısal Bayes örneği	6
3.4 K sınıflı genel durum	6
4 3.3 Kayıplar ve Riskler	7
4.1 Neden sadece en yüksek posterior yetmeyebilir?	7
4.2 0/1 kayıp fonksiyonu	7
4.3 Reject (kararı erteleme) seçeneği	7
4.4 Şekil 3.1: karar bölgeleri ve reject bölgesi	8
5 3.4 Ayırt Edici Fonksiyonlar (Discriminant Functions)	10
5.1 Karar bölgeleri ve karar sınırları	10
5.2 İki sınıflı durumda tek discriminant	10
5.3 Şekil 3.2: kayıp değişince sınır neden kayıyor?	11
6 3.5 Birliktelik Kuralları (Association Rules)	12
6.1 Support	12
6.2 Confidence	12
6.3 Lift	12
6.4 Apriori algoritmasının iki aşaması	13
7 3.6 Notlar: Birliktelik Nedensellik Değildir	14
7.1 Gizli değişkenler	14
8 3.7 Çözümlü Alıştırmalar	15
Alıştırma 1 - Nadir hastalık ve pozitif test	15
Alıştırma 2 - Likelihood ratio	15
Alıştırma 3 - Log odds	15
Alıştırma 4 - Asimetrik kayıp ve reject	16

Alıştırma 5 - Üç seviyeli cascade	17
Alıştırma 6 - Para oyununun adil fiyatı	17
Alıştırma 7 - Sepet verisinde support ve confidence	17
Alıştırma 8 - k bağımlılığına genelleme	18
Alıştırma 9 - Confidence eşitsizliği	18
Alıştırma 10 - Beğeni puanını öneriye katma	18
Alıştırma 11 - Support/confidence kombinasyonları	19
Ünite 3 - Hızlı Tekrar Özeti	20
Kaynak	20

Bu Ünite Ne Öğreneceğiz?

Bayesçi karar teorisi, **belirsizlik altında rasyonel karar verme** problemine olasılık teorisi üzerinden yaklaşır. Bu bölümün sonunda öğrenci:

- gözlenebilir ve gözlenemeyen değişkenler arasındaki farkı,
- Bernoulli rastgele değişkenini ve olasılık tahminini,
- sınıflandırmada prior, likelihood, evidence ve posterior kavramlarını,
- Bayes sınıflandırıcısını,
- kayıp fonksiyonu ve beklenen risk kavramlarını,
- eşit olmayan hata maliyetlerinin karar sınırını nasıl değiştirdiğini,
- reject (kararı erteleme/uzmana bırakma) mekanizmasını,
- discriminant function, karar bölgesi ve karar sınırı kavramlarını,
- association rule, support, confidence ve lift ölçülerini,
- Apriori algoritmasının temel budama mantığını

uygulamalı olarak anlayacaktır.

Ünitenin ana fikri

Makine öğrenmesinde amaç her zaman “en yüksek olasılığı seçmek” değildir. Eğer yanlış kararların maliyetleri farklıysa, doğru hedef **beklenen riski en küçük yapan eylemi** seçmektir.

1 Bayesçi Karar Teorisine Giriş

Olasılık teorisi, sonucundan emin olmadığımız durumlarda karar vermek için matematiksel bir çerçeve sağlar. Sınıflandırma problemlerinde Bayes kuralı ile sınıfların olasılıkları hesaplanabilir. Daha genel durumda ise farklı eylemlerin maliyetleri hesaba katılarak **beklenen riskin en küçük olduğu karar** seçilir.

Bölümün son kısmında ise sınıflandırmadan farklı ama yine olasılıksal bir problem olan **birliktelik kuralları** ele alınır. Örneğin bir markette “süt alan müşterilerin muz alma olasılığı nedir?” gibi sorular support, confidence ve lift ile yanıtlanabilir.

2 3.1 Giriş

2.1 İstatistik ile bilgisayar biliminin kesişimi

Bilgisayarlara veriden çıkarım yaptırmak, istatistik ile bilgisayar biliminin kesişiminde yer alır. İstatistik, veriden çıkarımın matematiksel temelini kurar; bilgisayar bilimi ise bu yöntemlerin büyük veri üzerinde etkin ve hızlı uygulanmasını sağlar.

Basit ayırım

İstatistik: “Bu veriden ne kadar güvenilir bir sonuç çıkarabilirim?”

Bilgisayar bilimi: “Bu hesabı nasıl etkin biçimde gerçekleştirebilirim?”

Makine öğrenmesi: Bu iki bakış açısını bir araya getirir.

2.2 Neden rastgele süreç modeli kullanıyoruz?

Veriyi üreten gerçek süreç çoğu zaman tam olarak bilinmez. Süreç gerçekte deterministik olsa bile, sonucu belirleyen bütün etkenleri ölçemeyebiliriz. Bu bilgi eksikliğini olasılık teorisi ile temsil ederiz.

Para atışı klasik örnektir. Sonucu etkileyen paranın başlangıç konumu, uygulanan kuvvet, dönme hızı, hava direnci ve yakalanma biçimi gibi çok sayıda fiziksel değişken vardır. Bunların tamamını bilmiyorsak sonuç bize rastgele görünür.

Gözlenemeyen değişkenleri z , gözlediğimiz sonucu x ile gösterirsek, ideal dünyada

$$x = f(z)$$

gibi deterministik bir ilişki bulunabilir. Fakat z gözlenemediği için doğrudan f' 'yi kullanamayız. Bunun yerine X sonucunu bir rastgele değişken olarak ele alır ve

$$P(X = x)$$

dağılımı ile modelleriz.

2.3 Bernoulli dağılımı ve yazı-tura

İki olası değer alan bir rastgele değişken için Bernoulli modeli kullanılır. Örneğin

$$X = \begin{cases} 1, & \text{yazı} \\ 0, & \text{tura} \end{cases}$$

olsun. Yazı gelme olasılığı p_0 ise

$$P(X = 1) = p_0, \quad P(X = 0) = 1 - p_0.$$

Eğer p_0 biliniyorsa, bir sonraki atış için minimum hata kararı:

$$\hat{X} = \begin{cases} 1, & p_0 > 0.5 \\ 0, & p_0 \leq 0.5 \end{cases}$$

şeklindedir.

Neden daha olası sonucu seçiyoruz?

$P(\text{yazı}) = 0.8$ ve $P(\text{tura}) = 0.2$ olsun. Yazı dersek hata olasılığımız 0.2; tura dersek 0.8 olur. Dolayısıyla minimum hata için yazıyı seçmek gerekir.

Adil para da $p_0 = 0.5$ olduğundan her iki seçimin de hata olasılığı aynıdır.

2.4 Dağılım bilinmiyorsa: örneklemden tahmin

Gerçek dağılım $p(x)$ bilinmiyorsa, elimizdeki örneklemden bir tahmin $\hat{p}(x)$ oluştururuz. Para atışında bilinmeyen parametre p_0 için doğal tahmin:

$$\hat{p}_0 = \frac{\#\{\text{yazı gelen atış}\}}{\#\{\text{toplam atış}\}} = \frac{\sum_{t=1}^N x_t}{N}.$$

Örneklem

$$\mathcal{X} = \{1, 1, 1, 0, 1, 0, 0, 1, 1\}$$

ise, 9 atışın 6'sı yazıdır:

$$\hat{p}_0 = \frac{6}{9} = 0.6667.$$

Bu tahmin, gözlenen verilere göre bir sonraki atışın yazı olma olasılığının yaklaşık %66.7 olduğunu söyler.

Önemli not

$\hat{p}_0$ gerçek fiziksel olasılığın kendisi değildir; eldeki örneklemden hesaplanan tahmin-dir. Örneklem büyüdükçe tahmin genellikle daha kararlı hale gelir.

3 3.2 Sınıflandırma

3.1 Kredi riski örneği

Bir bankanın geçmiş müşterilerinden bazıları kredilerini geri ödemiş, bazıları ise temerrüde düşmüş olsun. Yeni bir başvuru geldiğinde amaç, müşterinin **düşük riskli** mi yoksa **yüksek riskli** mi olduğunu tahmin etmektir.

Gözlenen iki özellik seçelim:

$$X_1 = \text{yıllık gelir}, \quad X_2 = \text{birikim}.$$

Özellik vektörü:

$$X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

olsun. Sınıf değişkeni ise:

$$C = \begin{cases} 1, & \text{yüksek risk} \\ 0, & \text{düşük risk} \end{cases}$$

şeklinde tanımlansın.

Yeni başvuruda $x = [x_1, x_2]^T$ gözlenince aradığımız temel büyüklük

$$P(C | x)$$

yani gözlemi gördükten sonraki sınıf olasılığıdır.

İki sınıf için minimum hata kuralı:

$$C = 1 \text{ seç, eğer } P(C = 1 | x) > P(C = 0 | x).$$

Eşdeğer olarak, çünkü iki olasılık 1'e toplanır:

$$P(C = 1 | x) > 0.5 \Rightarrow C = 1.$$

Hata olasılığı:

$$P(\text{hata} | x) = 1 - \max\{P(C = 1 | x), P(C = 0 | x)\}.$$

3.2 Bayes kuralı

Posterior olasılık Bayes kuralı ile hesaplanır:

$$P(C | x) = \frac{P(C) p(x | C)}{p(x)}.$$

Bayes formülündeki dört kavram

Prior $P(C)$	Gözlemi görmeden önce sınıf hakkında sahip olduğumuz olasılık.
Likelihood $p(x C)$	Sınıf C ise x gözlemini görmenin ne kadar olası olduğu.
Evidence $p(x)$	x gözleminin sınıftan bağımsız toplam görülme olasılığı.
Posterior $P(C x)$	x gözlendikten sonra sınıf hakkındaki güncellenmiş olasılık.

İki sınıfta evidence:

$$p(x) = p(x | C = 1)P(C = 1) + p(x | C = 0)P(C = 0).$$

Posteriorlar normalize oldukları için:

$$P(C = 0 | x) + P(C = 1 | x) = 1.$$

3.3 Sayısal Bayes örneği

Bir bankada müşterilerin %30'u yüksek riskli olsun:

$$P(H) = 0.30, \quad P(L) = 0.70.$$

Yeni müşterinin özelliklerinin yüksek riskli kişilerde görülme olasılığı 0.60, düşük risklilerde 0.10 olsun:

$$p(x | H) = 0.60, \quad p(x | L) = 0.10.$$

Evidence:

$$p(x) = 0.60(0.30) + 0.10(0.70) = 0.18 + 0.07 = 0.25.$$

Posteriorlar:

$$P(H | x) = \frac{0.60(0.30)}{0.25} = 0.72,$$

$$P(L | x) = \frac{0.10(0.70)}{0.25} = 0.28.$$

Sonuç: minimum hata kuralıyla müşteri **yüksek riskli** seçilir.

3.4 K sınıflı genel durum

K adet birbirini dışlayan ve bütün olasılıkları kapsayan sınıf $C_1, \dots, C_K$ için:

$$P(C_i) \geq 0, \quad \sum_{i=1}^K P(C_i) = 1.$$

Posterior:

$$P(C_i | x) = \frac{p(x | C_i)P(C_i)}{\sum_{k=1}^K p(x | C_k)P(C_k)}.$$

Minimum hata Bayes sınıflandırıcısı:

$$\hat{C} = \arg \max_i P(C_i | x).$$

Üç sınıflı örnek

Bir görüntü için $P(C_1 | x) = 0.15$, $P(C_2 | x) = 0.70$, $P(C_3 | x) = 0.15$ hesaplandıysa C_2 seçilir. Minimum hata olasılığı $1 - 0.70 = 0.30$ 'dur.

4 3.3 Kayıplar ve Riskler

4.1 Neden sadece en yüksek posterior yetmeyebilir?

Gerçek uygulamalarda her yanlış kararın maliyeti aynı değildir. Bankacılıkta yüksek riskli müşteriye kredi vermek ile düşük riskli müşteriye reddetmek aynı maliyete sahip olmayabilir. Tıbbi tanıda hasta kişiyi sağlıklı ilan etmek, sağlıklı kişiyi şüpheli bulmaktan çok daha ağır sonuç doğurabilir.

Bir girdiyi C_i sınıfına atama eylemine α_i , gerçekte sınıf C_k iken α_i eylemini seçmenin kaybına λ_{ik} diyelim.

Beklenen koşullu risk:

$$R(\alpha_i | x) = \sum_{k=1}^K \lambda_{ik} P(C_k | x).$$

Optimal karar:

$$\alpha^* = \arg \min_i R(\alpha_i | x).$$

Eşit olmayan hata maliyeti

$P(C_1 | x) = 0.70$, $P(C_2 | x) = 0.30$ olsun. Doğru kararın kaybı 0, C_2 gerçekte doğruyken C_1 seçmenin maliyeti 10, tersi hatanın maliyeti 1 olsun.

$$R(\alpha_1 | x) = 0(0.70) + 10(0.30) = 3,$$

$$R(\alpha_2 | x) = 1(0.70) + 0(0.30) = 0.7.$$

Posterioru daha düşük olmasına rağmen C_2 seçilir; çünkü beklenen maliyeti daha düşüktür.

4.2 0/1 kayıp fonksiyonu

Özel durumda tüm doğru kararların maliyeti 0, tüm hataların maliyeti 1 olsun:

$$\lambda_{ik} = \begin{cases} 0, & i = k \\ 1, & i \neq k. \end{cases}$$

O zaman

$$R(\alpha_i | x) = \sum_{k \neq i} P(C_k | x) = 1 - P(C_i | x).$$

Riski azaltmak, $P(C_i | x)$ 'i artırmakla aynıdır. Dolayısıyla 0/1 kayıp altında:

$$\alpha^* = \arg \max_i P(C_i | x).$$

Bu sonuç, “en yüksek posterioru seç” kuralının aslında simetrik 0/1 kaybın özel sonucu olduğunu gösterir.

4.3 Reject (kararı erteleme) seçeneği

Yanlış kararın çok pahalı olduğu uygulamalarda sistem düşük güvenle otomatik karar vermek yerine **reject** diyebilir ve örneği insan uzmana veya daha güçlü bir sisteme aktarabilir.

K sınıfa ek olarak α_{K+1} reject eylemini tanımlayalım. Basit bir kayıp fonksiyonu:

$$\lambda_{ik} = \begin{cases} 0, & i = k \\ \lambda, & i = K + 1 \\ 1, & \text{aksi halde} \end{cases}, \quad 0 < \lambda < 1.$$

Reject riskinin hesabı:

$$R(\alpha_{K+1} | x) = \sum_{k=1}^K \lambda P(C_k | x) = \lambda.$$

Sınıf C_i 'yi seçmenin riski:

$$R(\alpha_i | x) = 1 - P(C_i | x).$$

Dolayısıyla sınıfı otomatik seçmek için:

$$1 - P(C_i | x) < \lambda$$

ve buradan

$$P(C_i | x) > 1 - \lambda$$

şartı elde edilir. Aksi halde reject edilir.

Reject eşiği

$\lambda = 0.20$ ise otomatik karar eşiği $1 - \lambda = 0.80$ 'dir. En yüksek posterior 0.84 ise karar verilir; 0.62 ise sistem en olası sınıfı bilse bile yeterince emin olmadığı için reject verir.

4.4 Şekil 3.1: karar bölgeleri ve reject bölgesi




Figure 3.1 Example of decision regions and decision boundaries.

Şekil 1: Kullanıcının paylaştığı Şekil 3.1. Kareler C_1 , üçgenler C_2 , daireler C_3 sınıfını; eğri çizgiler karar sınırlarını; ortadaki alan ise reject bölgesini gösterir.

Şekilde yatay eksen x_1 , dikey eksen x_2 özelliğidir. Özellik uzayı, modelin en uygun gördüğü sınıfa göre bölgelere ayrılır. Sınırlar üzerinde iki veya daha fazla sınıfın karar skoru eşitlenir. Reject bölgesi, en iyi sınıfın bile kabul eşiğini geçemediği yerleri temsil eder.

Görseli okumak için üç soru

1. Yeni nokta hangi karar bölgesine düşüyor?
2. O bölgede hangi sınıfın skoru/posterioru en büyük?
3. En yüksek skor reject eşiğini de geçiyor mu?

5 3.4 Ayırt Edici Fonksiyonlar (Discriminant Functions)

Sınıflandırma, her sınıf için bir skor üreten $g_i(x)$ fonksiyonları üzerinden de ifade edilebilir:

$$C_i \text{ seçilir eğer } g_i(x) = \max_k g_k(x).$$

Bayes riskini bu biçime çevirmek için:

$$g_i(x) = -R(\alpha_i | x)$$

seçilebilir. Böylece en büyük discriminant fonksiyonu, en küçük riske karşılık gelir.

0/1 kaybıta:

$$g_i(x) = P(C_i | x).$$

Bayes kuralındaki tüm sınıflar için ortak olan $p(x)$ normalizasyonu ihmal edilirse:

$$g_i(x) = p(x | C_i)P(C_i).$$

5.1 Karar bölgeleri ve karar sınırları

Özellik uzayındaki i . karar bölgesi:

$$R_i = \{x | g_i(x) = \max_k g_k(x)\}.$$

İki sınıfın en yüksek discriminant değerleri eşitlendiğinde karar sınırı oluşur. Örneğin C_i ve C_j sınırı üzerinde:

$$g_i(x) = g_j(x).$$

5.2 İki sınıflı durumda tek discriminant

İki sınıfta:

$$g(x) = g_1(x) - g_2(x)$$

tanımlanırsa:

$$\hat{C} = \begin{cases} C_1, & g(x) > 0 \\ C_2, & g(x) \leq 0. \end{cases}$$

Karar sınırı:

$$g(x) = 0$$

eşitliğidir.

$K = 2$ için sistem bir **dichotomizer**; $K \geq 3$ için bir **polychotomizer** olarak adlandırılır.

5.3 Şekil 3.2: kayıp değişince sınır neden kayıyor?




Figure 3.2 The boundary changes as the misclassification losses change. (a) The boundary is where the two posteriors are equal when both misclassifications are equally costly. (b) When the losses are not symmetric, the boundary shifts toward the class that incurs higher risk when misclassified. (c) When there is the option of reject, a region around the boundary is the region of reject.

Şekil 2: Kullanıcının paylaştığı Şekil 3.2. (a) Eşit hata maliyetinde sınır posteriorların eşit olduğu yerde; (b) asimetrik kayıpta sınır kayar; (c) reject eklendiğinde sınır çevresinde kararsızlık bölgesi oluşur.

(a) Simetrik kayıp: Yanlış C_1 ve yanlış C_2 aynı maliyette ise sınır

$$P(C_1 | x) = P(C_2 | x) = 0.5$$

noktasındadır.

(b) Asimetrik kayıp: Örneğin C_2 gerçekte doğruyken C_1 seçmenin maliyeti daha büyükse, C_1 demek için daha yüksek güven gerekir. Sınır C_1 tarafına kayar.

(c) Reject: Reject'in maliyeti sınıflandırma hatasından küçükse tek bir sınır yerine iki eşik oluşur; aradaki bölgede sistem karar vermez.

6 3.5 Birliktelik Kuralları (Association Rules)

Bir birliktelik kuralı

$$X \rightarrow Y$$

biçimindedir. X öncül (antecedent), Y sonuç (consequent) kısmıdır. Sepet analizinde X ve Y ürün veya ürün kümeleridir.

6.1 Support

$$Support(X, Y) = P(X, Y) = \frac{\#\{X \text{ ve } Y \text{ birlikte}\}}{\#\{\text{tüm işlemler}\}}.$$

Support kuralın veri içinde ne kadar yaygın olduğunu ölçer.

6.2 Confidence

$$Confidence(X \rightarrow Y) = P(Y | X) = \frac{P(X, Y)}{P(X)}.$$

Sayım biçiminde:

$$Confidence(X \rightarrow Y) = \frac{\#\{X \text{ ve } Y \text{ birlikte}\}}{\#\{X\}}.$$

Confidence, X görüldüğünde Y 'nin ne kadar sık görüldüğünü söyler.

6.3 Lift

$$Lift(X \rightarrow Y) = \frac{P(X, Y)}{P(X)P(Y)} = \frac{P(Y | X)}{P(Y)}.$$

Yorum:

- $Lift \approx 1$: X ve Y yaklaşık bağımsızdır.
- $Lift > 1$: X varlığı Y 'yi daha olası hale getirir.
- $Lift < 1$: X varlığı Y 'yi daha az olası hale getirir.

Support, confidence ve lift birlikte

1000 müşterinin 200'ü ekmek, 250'si tereyağı, 100'ü ikisini birden alsın.

$$Support = \frac{100}{1000} = 0.10,$$

$$Confidence(\text{ekmek} \rightarrow \text{tereyağı}) = \frac{100}{200} = 0.50,$$

$$P(\text{tereyağı}) = 0.25, \quad Lift = \frac{0.50}{0.25} = 2.$$

Yani ekmek alanların tereyağı alma olasılığı genel ortalamanın iki katıdır.

6.4 Apriori algoritmasının iki aşaması

Büyük satış verilerinde tüm ürün alt kümelerini denemek hesaplama açısından pahalıdır. Apriori algoritması iki temel aşama kullanır:

1. **Sık öge kümelerini (frequent itemsets) bul:** minimum support eşiğini geçen kümeleri bul.
2. **Kuralları üret:** sık öge kümelerini antecedent/consequent olarak böl ve minimum confidence eşiğini geçen kuralları sakla.

Apriori'nin temel budama ilkesi:

Bir küme sık ise bütün alt kümeleri de sık olmalıdır.

Örneğin $\{X, Y, Z\}$ sık ise $\{X, Y\}$, $\{X, Z\}$ ve $\{Y, Z\}$ de sık olmalıdır. Tersini açıdan, $\{X, Y\}$ sık değilse onu içeren hiçbir üst kümeyi kontrol etmeye gerek yoktur.

Neden support ürün eklendikçe artmaz?

X ve Y 'yi birlikte alan müşteri sayısı, X , Y ve Z 'yi birlikte alan müşteri sayısından en az o kadar büyüktür. Bu nedenle

$$\text{Support}(X, Y, Z) \leq \text{Support}(X, Y).$$

Bu monotonluk, Apriori'nin budama gücünün temelidir.

7 3.6 Notlar: Birliktelik Nedensellik Değildir

Bir kuralın

$$X \rightarrow Y$$

biçiminde bulunması, X 'in Y 'ye **neden olduğu** anlamına gelmez. Kural yalnızca veri içinde bir birliktelik olduğunu söyler.

Association $\neq$ Causation

“Şemsiye taşıyan insanların ıslanma olasılığı yüksek” gözlemi, şemsiyenin ıslanmaya neden olduğu anlamına gelmez. Her ikisinin ortak nedeni yağmur olabilir.

7.1 Gizli değişkenler

Bazı ilişkiler gözlenemeyen ortak nedenlerle açıklanabilir. Örneğin “bebek maması”, “bebek bezi” ve “süt” birlikte alınabiliyor olsun. Üç ürün arasında ayrı ayrı ilişki kurmak yerine gizli bir değişken tanımlanabilir:

$$H = \text{“evde bebek var”}.$$

H doğrudan gözlenmese de üç ürünün tüketimini ortak biçimde açıklayabilir. Grafikselleştirilen modeller, ilerleyen bölümlerde bu tür gizli değişkenleri temsil etmeyi sağlar.

8 3.7 Çözümlü Alıştırmalar

Alıştırma 1 - Nadir hastalık ve pozitif test

Soru: Hastalık her 1.000.000 kişiden 1'inde görülüyor. Hasta kişide testin pozitif olma olasılığı %99, sağlıklı kişide yanlış pozitif olasılığı binde 1. Pozitif test alan birinin gerçekten hasta olma olasılığı nedir?

Çözüm

$d = 1$ hasta, $t = 1$ pozitif test olsun.

$$P(d = 1) = 10^{-6}, \quad P(t = 1 | d = 1) = 0.99, \quad P(t = 1 | d = 0) = 10^{-3}.$$

Bayes kuralı:

$$P(d = 1 | t = 1) = \frac{0.99 \cdot 10^{-6}}{0.99 \cdot 10^{-6} + 10^{-3}(1 - 10^{-6})}.$$

Sayısal sonuç:

$$P(d = 1 | t = 1) \approx 0.000989 \approx 0.0989\%.$$

Yani pozitif test, hastalık olasılığını milyonda 1'den yaklaşık binde 1'e yükseltmiştir; fakat hastalık çok nadir olduğu için pozitif sonuç hâlâ “neredeyse kesin hasta” anlamına gelmez.

1 milyon kişiyle sezgisel kontrol

Yaklaşık 1 gerçek hasta vardır ve bunun 0.99'u pozitif çıkar. Yaklaşık 999.999 sağlıklı'nın binde 1'i, yani yaklaşık 1000 kişi yanlış pozitif çıkar. Pozitiflerin yaklaşık 1/1001'i gerçekten hastadır.

Alıştırma 2 - Likelihood ratio

İki sınıfta likelihood ratio:

$$L(x) = \frac{p(x | C_1)}{p(x | C_2)}.$$

Posterior oranını discriminant olarak seçelim:

$$g(x) = \frac{P(C_1 | x)}{P(C_2 | x)}.$$

Bayes ile:

$$g(x) = \frac{p(x | C_1) P(C_1)}{p(x | C_2) P(C_2)}.$$

Karar:

$$g(x) > 1 \Rightarrow C_1, \quad g(x) \leq 1 \Rightarrow C_2.$$

Priorlar eşitse discriminant yalnızca likelihood ratio olur.

Alıştırma 3 - Log odds

$$g(x) = \log \frac{P(C_1 | x)}{P(C_2 | x)}.$$

Logaritma çarpımı toplam yaptığı için:

$$g(x) = \log \frac{p(x | C_1)}{p(x | C_2)} + \log \frac{P(C_1)}{P(C_2)}.$$

Karar eşiği artık 0'dır:

$$g(x) > 0 \Rightarrow C_1, \quad g(x) \leq 0 \Rightarrow C_2.$$

Priorlar eşitse ikinci terim $\log 1 = 0$ olur.

Alıştırma 4 - Asimetrik kayıp ve reject

Verilen kayıplar:

$$\lambda_{11} = \lambda_{22} = 0, \quad \lambda_{12} = 10, \quad \lambda_{21} = 5.$$

	Gerçek C_1	Gerçek C_2
α_1 : C_1 seç	0	10
α_2 : C_2 seç	5	0

Riskler:

$$R(\alpha_1 | x) = 10P(C_2 | x) = 10[1 - P(C_1 | x)],$$

$$R(\alpha_2 | x) = 5P(C_1 | x).$$

C_1 için:

$$10(1 - P(C_1 | x)) < 5P(C_1 | x)$$

$$10 < 15P(C_1 | x)$$

$$P(C_1 | x) > \frac{2}{3}.$$

Eşit maliyetli durumda eşik $1/2$ olacaktı; burada C_1 'i yanlış seçmenin maliyeti daha yüksek olduğu için C_1 demek için daha fazla güven gerekir.

Reject maliyeti 1 eklensin:

$$R(\alpha_r | x) = 1.$$

C_1 seçmek için:

$$10(1 - P(C_1 | x)) < 1 \Rightarrow P(C_1 | x) > 0.9.$$

C_2 seçmek için:

$$5P(C_1 | x) < 1 \Rightarrow P(C_1 | x) < 0.2.$$

Dolayısıyla:

$$\begin{cases} C_1, & P(C_1 | x) > 0.9 \\ Reject, & 0.2 \leq P(C_1 | x) \leq 0.9 \\ C_2, & P(C_1 | x) < 0.2. \end{cases}$$

Kaynak metindeki küçük dizgi hatası

Paylaşılan çözümde C_2 kararı için bir yerde "eşdeğer olarak $P(C_1 | x) > 4/5$ " ifadesi geçiyor. Doğru eşdeğer ifade $P(C_2 | x) > 4/5$ veya $P(C_1 | x) < 1/5$ olmalıdır.

Alıştırma 5 - Üç seviyeli cascade

Öneri:

1. Seviye 1: ucuz ve hızlı model. Çok emin değilse reject.
2. Seviye 2: daha pahalı ama daha doğru model. Emin değilse reject.
3. Seviye 3: insan uzman veya en güçlü model. Nihai karar.

Örnek eşikler: birinci seviyede $\lambda_1 = 0.10$ için $P_{\max} > 0.90$; ikinci seviyede $\lambda_2 = 0.30$ için $P_{\max} > 0.70$. Reject maliyeti, bir sonraki seviyenin işlem/insan maliyeti ve yanlış kararın iş maliyeti dikkate alınarak doğrulama verisi üzerinde seçilebilir.

Alıştırma 6 - Para oyununun adil fiyatı

Adil para atılıyor. Yazıda 0 dolar, turada 5 dolar kazanılıyor:

$$E[X] = 0.5(0) + 0.5(5) = \boxed{2.50 \text{ dolar}}.$$

Risk-nötr oyuncu için adil fiyat 2.50 dolardır.

Kazanç 500 dolar olursa:

$$E[X] = 0.5(0) + 0.5(500) = \boxed{250 \text{ dolar}}.$$

Gerçek insanların riskten kaçınması nedeniyle ödemek isteyecekleri miktar beklenen değerden düşük olabilir; bu, fayda (utility) kavramına götürür.

Alıştırma 7 - Sepet verisinde support ve confidence

İşlem	Sepet
1	süt, muz, çikolata
2	süt, çikolata
3	süt, muz
4	çikolata
5	çikolata
6	süt, çikolata

Toplam 6 işlem vardır. Süt 4, muz 2, çikolata 5 işlemde; süt+muz 2, süt+çikolata 3 işlemde görülür.

Kural	Support	Confidence
süt $\rightarrow$ muz	$2/6 = 0.333$	$2/4 = 0.50$
muz $\rightarrow$ süt	$2/6 = 0.333$	$2/2 = 1.00$
süt $\rightarrow$ çikolata	$3/6 = 0.50$	$3/4 = 0.75$
çikolata $\rightarrow$ süt	$3/6 = 0.50$	$3/5 = 0.60$

Önemli sonuç: support X ve Y için yönsüzdür, fakat confidence yönlüdür. Bu nedenle “süt $\rightarrow$ muz” ile “muz $\rightarrow$ süt” aynı confidence’a sahip olmak zorunda değildir.

Alıştırma 8 - k bağımlılığına genelleme

$X_1, \dots, X_k \rightarrow Y$ kuralı için:

$$\text{Support}(X_1, \dots, X_k, Y) = P(X_1, \dots, X_k, Y)$$

ve

$$\text{Confidence}(X_1, \dots, X_k \rightarrow Y) = P(Y \mid X_1, \dots, X_k) = \frac{P(X_1, \dots, X_k, Y)}{P(X_1, \dots, X_k)}.$$

Alıştırma 9 - Consequent'tan antecedent'a taşıma

Gösterilecek ifade:

$$\text{Confidence}(ABC \rightarrow D) \geq \text{Confidence}(AB \rightarrow CD).$$

Sol taraf:

$$\text{Confidence}(ABC \rightarrow D) = \frac{P(ABCD)}{P(ABC)}.$$

Sağ taraf:

$$\text{Confidence}(AB \rightarrow CD) = \frac{P(ABCD)}{P(AB)}.$$

$ABC \subseteq AB$ olduğundan:

$$P(ABC) \leq P(AB).$$

Paylar eşit ve ilk payda daha küçük olduğundan:

$$\text{Confidence}(ABC \rightarrow D) \geq \text{Confidence}(AB \rightarrow CD).$$

Sözel ifadeye dikkat

Verilen eşitsizlik, bir öğeyi consequent'tan antecedent'a taşıdığımızda confidence'ın **azalmayacağını** (artabileceğini veya aynı kalabileceğini) gösterir. Paylaşılan soru metnindeki "asla artamaz" ifadesi eşitsizlikle uyumlu değildir.

Alıştırma 10 - Beğeni puanını öneriye katma

Her ürün için müşterinin 0-10 arası beğeni puanı r_Y olsun. Sadece satın alma olasılığına değil, beklenen beğeniye de bakılabilir:

$$E[r_Y \mid X].$$

Basit bir öneri skoru:

$$\text{Score}(Y \mid X) = P(Y \mid X) E[r_Y \mid X].$$

Örneğin $P(Y \mid X) = 0.8$ ve beklenen puan 9 ise skor 7.2; başka bir ürünün olasılığı 0.9 ama beklenen puanı 5 ise skor 4.5 olur. Bu yaklaşım, birliktelik sinyalini tercih şiddetiyle birleştirir.

Alıştırma 11 - Support/confidence kombinasyonları

10 işlem üzerinden örnekler:

Durum	$\#X$	$\#(X, Y)$	Support / Confidence	Yorum
(a) ikisi de yüksek	8	7	0.70 / 0.875	Yaygın ve güçlü kural.
(b) support yüksek, confidence düşük	10	4	0.40 / 0.40	X çok yaygın ama Y çoğunlukla gelmiyor.
(c) support düşük, confidence yüksek	2	2	0.20 / 1.00	Güçlü görünür fakat az gözleme dayanır.
(d) ikisi de düşük	5	1	0.10 / 0.20	Ne yaygın ne güçlü.

Ünite 3 - Hızlı Tekrar Özeti

Kavram	Temel fikir / formül
Bernoulli	$X \in \{0, 1\}$, $P(X = 1) = p$, $P(X = 0) = 1 - p$.
Prior	$P(C_i)$: veri görülmeden önce sınıf olasılığı.
Likelihood	$p(x C_i)$: sınıf biliniyorken gözlemin olabilirliği.
Evidence	$p(x) = \sum_k p(x C_k)P(C_k)$.
Posterior	$P(C_i x) = \frac{p(x C_i)P(C_i)}{p(x)}$.
Bayes sınıflandırıcısı	0/1 kayıpta $\arg \max_i P(C_i x)$.
Beklenen risk	$R(\alpha_i x) = \sum_k \lambda_{ik}P(C_k x)$.
Optimal karar	$\arg \min_i R(\alpha_i x)$.
0/1 loss	$R(\alpha_i x) = 1 - P(C_i x)$.
Reject	Basit simetrik durumda $P(C_i x) > 1 - \lambda$ değilse reject.
Discriminant	C_i seçilir eğer $g_i(x) = \max_k g_k(x)$.
Karar sınırı	İki en iyi discriminant'ın eşit olduğu yüzey.
Support	$P(X, Y)$.
Confidence	$P(Y X) = P(X, Y)/P(X)$.
Lift	$P(Y X)/P(Y)$.
Apriori	Sık olmayan bir kümenin hiçbir üst kümesi sık olamaz; budama yapılır.

Sınavlık ana zincir

Prior + Likelihood $\xrightarrow{\text{Bayes}}$ Posterior $\xrightarrow{\text{Loss}}$ Risk $\xrightarrow{\arg \min}$ Karar

Eğer bütün hatalar eşit maliyetliyse, risk minimizasyonu doğrudan en büyük posterioru seçmeye indirgenir.

Kaynak

Alpaydın, E. (2014). *Introduction to Machine Learning*. MIT Press. Bu PDF, kullanıcının paylaştığı 3. bölüm metni ve şekilleri temel alınarak hazırlanmış Türkçe ders/çalışma notudur; açıklamalar ve ek örnekler eğitim amacıyla eklenmiştir.